

自然语言处理

王刚

统计与数据科学学院

2026 年春季学期

目录

第四章 语义分析

4.1 语义学概述

4.2 语义表示

4.3 分布式表示

第四章语义分析

4.1 语义学概述

语义分析

► 语言的意义与语义学

掌握一种语言，不仅仅是记住词汇和语法规则，更重要的是能够产生并理解数量无限的该语言句子的意义。这种对意义的理解和运用，是语言能力的核心体现。研究语言意义的科学被称为**语义学 (Semantics)**。语义学不仅关注词语和句子的字面意义，还涉及上下文、语境以及语言使用者的意图。

► 语义学的重要性

语义问题被大多数语言学家认为是语言研究的核心问题。这是因为语言的意义是沟通的基础，没有意义，语言就失去了其功能。语义学不仅受到语言学的关注，还吸引了哲学、逻辑学、心理学以及计算机科学等多个学科的研究兴趣。例如：哲学：探讨语言与真实世界的关系。逻辑学：研究语言的形式化表达和推理。心理学：分析人类如何理解和产生意义。计算机科学：致力于让机器理解和生成自然语言。

► 自然语言处理中的语义问题

自然语言处理 (NLP) 的目标是使计算机具备理解和运用自然语言的能力。因此，语义问题是 NLP 的核心问题和难点问题。为什么语义问题如此具有挑战性呢？因为自然语言的意义往往依赖于上下文、语境以及背景知识。例如，同一个词在不同语境中可能有完全不同的含义（如‘苹果’可以指水果，也可以指科技公司）。要让计算机理解这些细微差别，需要复杂的语义分析和表示方法。

► 语义表示：形式化结构的基础

为了研究语义问题，我们需要一种形式化的方法来表示语言的意义。这种形式化结构被称为**语义表示 (Semantic Representation)**。语义表示是语义研究的基础，它试图将语言的意义转化为计算机可以处理的结构。常见的语义表示方法包括：
逻辑形式：使用逻辑表达式表示句子的意义。
语义图：通过图结构表示词语和句子之间的关系。
向量表示：将词语或句子的意义映射到高维向量空间（如词嵌入）。
这些表示方法为计算机理解语言意义提供了基础，但如何设计更精确、更全面的语义表示仍然是 NLP 领域的重要研究方向。

语义分析

► 意义的本质：一个古老而深刻的问题

什么是意义？这个问题困扰了哲学家和语言学家数千年。我们能够轻松地理解自己的母语，用词语组成对他人来说也有意义的句子；我们能够判断某个词语或句子是否有意义，甚至能够从一个句子推导出另一个句子。然而，意义从何而来？语言的意义的本质又是什么？这些问题至今仍然没有定论，但它们却是理解语言和沟通的核心。

► 语言意义的直观体验

让我们从日常语言现象出发，思考意义的本质。例如：为什么‘猫在垫子上’这句话对我们来说有意义，而‘垫子在猫上’却显得奇怪？为什么‘绿色的思想在愤怒地睡觉’这句话听起来没有意义，尽管它的语法是正确的？为什么我们可以从‘所有的鸟都会飞’和‘企鹅是鸟’推导出‘企鹅会飞’，尽管这个结论在现实中是错误的？这些例子表明，意义不仅仅是词语的组合，还涉及语法、逻辑、常识以及语境等多重因素。

► 意义研究的哲学与语言学传统

意义问题在东西方的哲学和语言学传统中都有着悠久的探讨历史。

中国古代的训诂学：中国古代以‘字’为核心的训诂释义研究达到了很高的水准。早在公元前2世纪，就有了专门解释词义的专著《尔雅》。先秦时期，荀子和墨子就开始对‘名’与‘实’的关系进行讨论，探讨词语与其所指对象之间的关系。

古希腊哲学：在西方，古希腊哲学家苏格拉底、亚里士多德等也在其哲学著作中探讨过语言的意义。例如，亚里士多德提出了‘符号’与‘意义’的关系，认为语言是思想的符号。

这些早期的探讨为后来的语义学研究奠定了基础。

语义分析

► 语义学的研究目标

语义学的研究目标是发现和阐述关于意义的知识。意义是语言的核心，理解意义不仅有助于我们更好地掌握语言，还能为自然语言处理、心理学、哲学等领域提供理论基础。1883年，法国语言学家 Michel Br é al 在其发表的论文中首次提出了‘语义学’这一概念，标志着语义学作为一门独立学科的诞生。从那时起，语义学逐渐发展成为语言学中一个重要的分支。

► 语义学的层次划分

► (1) 词汇语义学 (Lexical Semantics)

主要研究词汇的意义及其相互关系。具体包括：词义问题：探讨词语的多义性、同义性、反义性等。词汇间关系：分析词语之间的上下位关系、部分整体关系等。词汇场：研究同一语义场中词语的分布和关系，例如颜色词、亲属词等。成语的语义：探讨成语、惯用语等固定表达的意义及其文化背景。词汇语义学的研究对于词典编纂、机器翻译、信息检索等应用具有重要意义。

► (2) 句子语义学 (Sentential Semantics)

主要研究句子的意义及其内部关系。其理论基础包括：真值条件语义理论：通过句子的真值条件来分析其意义。配价理论：研究动词与其他句子成分之间的语义关系。生成理论：探讨句子的生成过程及其语义解释。句子语义学关注的问题包括：句义关系：分析句子之间的蕴含、矛盾、预设等关系。语序问题：研究语序对句子意义的影响。句子语义学的研究为句法分析、语义角色标注等任务提供了理论支持。

► (3) 话语语义学 (Discourse Semantics)

主要研究句子以上层次结构的意义，关注语篇的整体意义及其内部关系。具体包括：话语衔接：分析语篇中句子之间的连接方式，如代词指代、省略等。话语连贯：探讨语篇的逻辑结构和主题发展。语用过程解释：研究语境、说话者意图等对语篇意义的影响。话语语义学的研究对于机器阅读理解、对话系统、文本生成等任务具有重要意义。

词汇语义学

► 词：语言的基本单位

词是语言中能够独立运用的最小单位，也是音、形、义的结合体。每个词都有其特定的发音（音）、书写形式（形）和意义（义）。例如，‘猫’这个词的发音是 ‘māo’，书写形式是 ‘猫’，意义是指一种常见的家养动物。词是语言构建的基础，通过词的搭配和组合，我们可以构建出短语、句子、篇章等复杂的语言结构。

► 词汇语义学的研究目标

语义学自创建之初，就将词汇语义作为重要的研究目标。这是因为词是语言意义的基本载体，理解词的意义是理解更大语言单位（如句子、篇章）意义的基础。词汇语义学主要研究单个词语的意义以及词汇之间的相互关系。它试图回答以下问题：一个词的意义是什么？词与词之间有哪些语义关系？词的意义如何随着语境的变化而变化？这些问题不仅是语言学的核心问题，也对自然语言处理、词典编纂等应用领域具有重要意义。

► 词汇语义学的研究对许多实际应用具有重要意义。

词汇语义学——词汇语义理论

► 词汇语义理论的多样性

词义 (Word Meaning) 是一个复杂的概念，可以从不同的角度进行分析和定义。因此，词汇语义学领域涌现出了多种理论，包括语义场理论、语义成分分析、并置理论、框架语义理论等。这些理论从不同的视角探讨词义的本质及其相互关系，为我们理解词汇的意义提供了丰富的工具和方法。

► 语义场理论 (Semantic Field Theory)

也称为词义场理论 (Lexical Field Theory)，认为语言中词汇的意义并不是孤立的，而是相互联系的，构成一个完整的系统和网络。具有某些相同语义特征的一组词可以聚合成一个‘场’。例如，颜色词（红、黄、蓝等）构成一个语义场，亲属词（父亲、母亲、兄弟等）构成另一个语义场。根据语义场理论，我们不能孤立地研究一个词的意义，只有通过分析比较词与词之间的关系，才能确定一个词的真正意义。例如，‘红’的意义不仅由其自身定义，还通过与‘黄’、‘蓝’等其他颜色词的对比得以明确。

词汇语义学——词汇语义理论

► 语义成分分析 (Componential Analysis) 理论

理论认为，词义可以由最小的语义成分组合而成。这些最小的语义成分被称为语义特征 (Semantic Features)。通过将词义分解为更小的语义特征，我们可以更精确地描述和比较词语的意义。例如，我们可以定义以下语义特征：ADULT：成年、YOUNG：年轻、MALE：男性、FEMALE：女性，利用这些语义特征，我们可以清晰地表达词汇的意义。

► 语义成分分析的示例

man : ADULT + MALE (成年 + 男性)

woman : ADULT + FEMALE (成年 + 女性)

boy : YOUNG + MALE (年轻 + 男性)

girl : YOUNG + FEMALE (年轻 + 女性)

通过这种方式，我们可以清晰地看到这些词语之间的相似性和差异性。例如，‘man’和‘woman’共享‘ADULT’这一特征，但在‘MALE’和‘FEMALE’上有所不同；而‘boy’和‘girl’共享‘YOUNG’这一特征，但在性别特征上有所区别。

词汇语义学——词汇语义理论

► 义元理论 (Theory of Lexcial Primitives)

核心思想是，自然语言中包含非常少量的基本词语，这些词语被称为义元 (Lexical Primitives)。义元可以用来解释绝大部分词汇的意义。例如，‘man’和‘fish’可以被视为义元，而‘fishy’和‘manliness’则是从这些义元衍生出来的词。通过义元，我们可以对其他词语进行解释，从而简化词义的分析 and 理解。

► 义元理论的优势 vs 局限性

优势：简洁性：通过少量的义元解释大量词汇，简化了词义分析的过程。系统性：义元理论提供了一种系统的方法来解释词汇的意义，有助于构建统一的语义框架。跨语言适用性：义元理论的基本思想可以应用于不同语言，为跨语言语义研究提供了可能性。

局限性：义元的选取：如何确定哪些词语可以作为义元，仍然是一个有争议的问题。解释的复杂性：某些复杂词汇的意义可能难以用简单的义元组合来解释。文化依赖性：义元的定义和解释可能受到文化背景的影响，难以完全通用。

词汇语义学——词汇语义理论

▶ 知网 (HowNet) 的背景与意义

由董振东教授创建的一个基于义元理论的语义知识库。它结合了义元理论的核心思想，构建了一个包含 2540 多个义元的精细语义描述体系，并为 237,974 个汉语和英语词汇所代表的概念进行了标注。知网不仅是语义学研究的重要成果，也为自然语言处理、机器翻译、信息检索等领域提供了宝贵的资源。

▶ 知网中的义元采用中英双语的形式进行描述，这使得它能够同时支持汉语和英语的语义分析。这种双语描述方式不仅增强了知网的跨语言适用性，还为多语言语义研究提供了便利。

▶ 示例 1：美味：edible| 食物:modifier=GoodTaste| 好吃 ‘美味’的核心义元是 ‘edible| 食物’，表示它与食物相关； 附加描述义元是 ‘GoodTaste| 好吃’，表示它的味道好。

▶ 示例 2：难题：problem| 问题:modifier=difficult| 难 ‘难题’的核心义元是 ‘problem| 问题’，表示它是一个问题； 附加描述义元是 ‘difficult| 难’，表示它的难度高。 通过这种方式，知网能够精确地描述词汇的语义结构，揭示词义的核心特征及其附加属性。

词汇语义学——词汇语义理论

► 框架语义学 (Frame Semantics)

认为词义只能在相应的知识框架背景中才能得到理解。换句话说，理解一个词的意义需要激活与之相关的背景知识和场景。框架语义学强调，概念并不是孤立存在的，而是以一种有组织的方式相互关联。许多概念在意义理解过程中具有一种同现的趋势，即某些概念往往会同时出现在特定的语境中。

► 例如：定义“危险”的框架是由如下成分组成：

机会（关于未来的不确定性）

伤害（可能发生的负面结果）

受害者（受到伤害的人）

有价值的物品（可能受到风险威胁）

情境（导致风险的情况）

行为（引起情境的行为）

行为者（行为的执行者）

获得（行为者在冒险中获得的利益）

目的（行为者执行该行为的目的）

受益人和动机（行为者的受益人和动机）

通过这个框架，我们可以看到，‘危险’不仅仅是一个抽象的概念，而是与一系列相关的背景知识和场景紧密相连。理解‘危险’的意义需要激活这些相关的成分。

词汇语义学——词汇间的关系

- ▶ 词汇间的关系 (Lexical Relations) 是词汇语义学研究的重点问题。

- ▶ 理解词汇之间的关系不仅有助于我们更好地掌握词汇的意义，还能为自然语言处理应用提供理论基础。

关系类型可以分为三大类：

形体关系 (Form Relations)

主要研究词汇的声音形体和拼写之间的关系。

意义关系 (Sense Relations)

主要关注词汇意义之间的关联性、相似性、对立性等关系。

实体关系 (Object Relations)

主要研究词汇之间的客观关系。(因果关系、功能关系、空间关系)

词汇之间的关系类型			示例
形体关系	Homonymy	同音异义关系	ring 与 wring 发音相同
		同形异义关系	bank (银行) 与 bank (河岸) 词形相同
意义关系	Synonymy	同义关系	“电脑”与“计算机”是同义词
	Antonymy	反义关系	“大”与“小”之间是反义关系
	Hyponymy	下位关系	“燕子”是“鸟”的下位词
	Hypernymy	上位关系	“动物”是“老虎”的上位词
实体关系	Meronymy	部分整体关系	“发动机”与“汽车”

词汇语义学——词汇间的关系

- ▶ WordNet 是目前最常用的英语词汇知识资源库¹。

它由普林斯顿大学开发，旨在通过语义网络的形式组织英语词汇。在 WordNet 中，词汇按照义项 (Sense) 组合成同义集 (Synset)，每个同义集表达一个独立的概念。WordNet 将名词、动词、形容词和副词分别组织成独立的网络，为词汇语义研究提供了丰富的资源。

- ▶ WordNet 的结构与特点

WordNet 的核心特点在于，它的语义关系不是在单词之间建立的，而是在义项之间建立的。每个义项代表一个特定的词义，而同义集则是由意义相同或相近的义项组成的集合。例如，‘car’ 和 ‘automobile’ 属于同一个同义集，因为它们表达相同的概念。WordNet 通过这种方式，将词汇的意义以网络的形式组织起来，形成一个结构化的语义知识库。

- ▶ WordNet 中的语义关系同义关系、反义关系、上下位关系、部分与整体关系、对等关系 (Coordinate Terms)、继承关系 (Entailment)：主要针对动词，表示一个动作隐含另一个动作，例如 ‘snore’ 隐含 ‘sleep’。

这些语义关系为词汇语义分析提供了丰富的结构化信息。

- ▶ 截至 WordNet 3.1 版本，它包含了 155,327 个单词，175,979 个同义集，共组成了 207,016 对单词和义项对。WordNet 的规模庞大，覆盖了英语中大部分常用词汇及其义项。随着版本的更新，WordNet 不断扩展其词汇量和语义关系，为语义研究和自然语言处理提供了更全面的支持。

¹<https://wordnet.princeton.edu/>

句子语义学

► 句子语义学的研究对象

句子语义学主要是在句子层面对意义的研究。与词汇语义学不同，句子语义学关注的是如何通过句子来表达完整的语义。句子是语言表达的基本单位，相较于词汇，句子的结构和意义更加复杂。因此，句子语义学的研究涉及多个学科，包括语音学、语法学、逻辑学、认知科学和心理学等。这些学科从不同角度探讨句子的意义，为我们理解语言的运作机制提供了多维度的视角。

► 句子作为对外部世界的编码

语言是对外部世界的编码，而句子则是人们对客观世界的概念表征。换句话说，句子不仅仅是词语的组合，更是对现实世界中事件、状态和关系的描述。人们对句子意义的认知通常始于真假判断。例如，当我们听到‘今天下雨了’这句话时，会下意识地判断这句话是否为真。这种真假判断是理解句子意义的基础，也是句子语义学研究的重要内容。

句子语义学

► 真值条件语义学 (Truth-conditional Semantics)

真值条件语义学是句子语义学中的一个重要理论，其核心思想是将意义定义为一个句子或句子所表达的命题为真时所必须满足的一系列条件。换句话说，真值条件语义学试图通过解释句子何时为真来定义句子的意义。该理论提出了一个检验句子真值的通用公式：

$$S \text{ is true iff } P$$

其中，S 代表某个句子，P 代表句子的真值条件。

例如，对于句子‘他是学生’，S 表示这个句子，P 表示‘他所代表的人确实是学生的列表’。

通过这种方式，真值条件语义学将句子的意义与其真值条件紧密联系起来。

句子语义学

► 语义格 (Semantic Case)

在词汇语义理论中，语义成分分析理论认为词义可以由最小的语义成分组合而成。类似地，在句子层面也存在语义成分，这种语义成分通常称为语义格。语义格，也称为语义角色 (Semantic Roles) 或主题关系 (Thematic Relations)，用于描述句子中名词短语与动词之间的语义关系。

► 格语法 (Case Grammar)

格语法是一种语法理论，其核心思想是句子中名词短语总是与动词相关，并且以唯一可以识别的方式表示名词短语的语义格。格语法认为，传统的‘主语’、‘宾语’等语法关系只是表层结构上的概念，而语言的底层是由‘施事’、‘受事’、‘工具’等语义格所表示的句法语义关系。

句子 ‘The key opened the door’ 中，‘key’ 是 ‘工具’。

句子 ‘The boy opened the door with a key’ 中，‘key’ 仍然是 ‘工具’，尽管它在表层结构中是介词 ‘with’ 的宾语。

► 通过这种方式，格语法揭示了句子深层结构与表层结构之间的关系。

句子语义学

► 格语法中的词汇标注

在格语法中，词库中的每个词条都需要标明其格特征。对于名词，需要标明它可以充当的语义格；对于动词，则需要标明其对应的格框架。这种标注方式帮助我们更系统地描述词汇的语义属性，并为句子语义分析提供基础。

例如，名词‘街道’需要标明 [+LOCATION]，表示它可以作为‘处所’这一语义格；动词‘BREAK’则需要放入一个格框架，标明它可以与哪些语义格搭配。

► 动词的格框架标注：是格语法的核心内容之一。

例如，在句子‘他在房间里用锤子打破了玻璃杯’

$$\text{BREAK} \left[\text{Case-frame:} \begin{cases} \text{AGENT: 施事格 (他)} \\ \text{PATIENT: 受事格 (玻璃杯)} \\ \text{INSTRUMENT: 工具格 (锤子)} \\ \text{LOCATION: 方位格 (房间)} \end{cases} \right]$$

‘BREAK’可以与‘施事’、‘受事’、‘工具’和‘处所’等语义格搭配。根据‘BREAK’的格框架进行分析，可以系统地描述动词的语义属性，并为句子语义分析提供支持。

句子语义学

► 句子间语义关系的重要性

在自然语言中，句子之间也存在各种语义关系。将句子作为一个整体，研究句子与句子之间的语义关系，有助于我们更全面地理解文本的意义。句子间的语义关系主要包括同义关系、反义关系、蕴含关系和预设关系。这些关系不仅揭示了句子之间的逻辑联系，还为自然语言处理任务（如文本推理、问答系统）提供了重要的理论基础。

- **同义关系 (Synonymy)** 表示两个不同的句子表达相同的意义。句子 a：他打碎了玻璃杯。句子 b：玻璃杯被他打碎了。这两个句子虽然在语法结构上有所不同，但表达的意义完全相同。
- **反义关系 (Inconsistency)** 表示两个句子的意义只能有一个与客观事实相符。句子 a：他打碎了玻璃杯。句子 b：玻璃杯完好的放在橱窗里。这两个句子的意义是矛盾的，如果句子 a 为真，那么句子 b 必然为假，反之亦然。
- **蕴含关系 (Entailment)** 表示两个句子的意义之间存在逻辑上的包含关系。具体来说，如果句子 a 为真，那么句子 b 必然为真；但如果句子 a 为假，句子 b 可能为真也可能为假。例如：句子 a：他拿着一本书去了校门口。句子 b：书在他手里。如果句子 a 为真，那么句子 b 必然为真；但如果句子 a 为假（例如他没有拿书），句子 b 可能为真（例如书在他手里，但他没有去校门口）也可能为假（例如书不在他手里）。蕴含关系的研究对于文本推理、问答系统等任务具有重要意义。
- **预设关系 (Presupposition)** 表示一个句子的意义是另一个句子的前提。换句话说，句子 a 的成立依赖于句子 b 所表达的事实。例如：句子 a：上海财经大学武东路校区举办了迎新活动。句子 b：上海财经大学有多个校区。句子 a 的成立预设了句子 b 所表达的事实（即上海财经大学有多个校区）。

4.2 语义表示

语义表示

- ▶ **语义表示 (Semantic Representation)** 是语义的符号化和形式化的过程，主要研究如何用计算机可处理的方式表示自然语言的语义。为了让计算机能够理解和处理自然语言，我们需要用恰当的模式对语义进行表示。因此，语义表示方法是自然语言理解的基础，也是实现机器翻译、问答系统、文本生成等任务的关键技术。
- ▶ 目前，关于意义的定义和本质还没有定论，大量的语义学理论从不同角度对意义进行了探讨。例如，真值条件语义学、框架语义学、义元理论等都提出了各自的意义解释方法。然而，已有的语义表示方法大多是根据不同的语义学理论针对某项具体研究提出的，具有一定的针对性和局限性。因此，如何设计一种适用于词汇、句子、篇章等各个层面，并能广泛应用于各种任务的通用语义表示方法，仍然是一个亟待解决的问题。
- ▶ 常见的语义表示方法
 - 一阶谓词逻辑**：通过逻辑公式表示句子的语义，具有较强的表达能力，但难以处理复杂的语言现象。
 - 框架**：通过定义语义框架来表示句子的语义，能够捕捉句子的背景知识，但需要人工定义框架。
 - 语义网**：通过节点和边表示语义关系，如 WordNet，能够直观地表示词汇间的关系，但难以处理动态变化的语境。
 - 分布式表示**：通过向量空间模型表示语义，如词嵌入，能够捕捉语义的相似性和上下文信息，但缺乏可解释性。

谓词逻辑表示法

- ▶ **数理逻辑 (Mathematical Logic)** 是数学的一个分支，主要研究逻辑推理的形式化方法。它在知识的形式化表示和机器的自动定理证明方面有着广泛的应用和出色的表现。在自然语言处理中，数理逻辑也被用于语义表示，特别是在真值条件语义学中，数理逻辑被用来研究自然语言的语义。通过数理逻辑，我们可以将自然语言的语义转化为计算机可以处理的形式化表示。
- ▶ 在自然语言的语义表示中，数理逻辑的方法被广泛采用，其中最常用的是**谓词逻辑 (Predicate Logic)**和**命题逻辑 (Propositional Logic)**。这两种逻辑方法为我们提供了形式化工具，能够精确地描述自然语言的语义结构。
- ▶ 命题逻辑是数理逻辑中最基础的形式系统，它通过命题（即可以判断真假的陈述句）和逻辑连接词（如‘与’、‘或’、‘非’等）来表示语义。
- ▶ 谓词逻辑是命题逻辑的扩展，它能够更细致地刻画语义。谓词逻辑不仅可以表示事物的状态、属性和概念，还可以表示因果关系等规则性语义。

谓词逻辑表示法

- ▶ 在谓词逻辑中，谓词 (Predicate) 用于描述事物的属性或事物之间的关系。谓词一般用 $P(x_1, x_2, \dots, x_n)$ 表示，其中 P 是谓词名， $x_1, x_2, \dots, x_n$ 表示某个独立存在的事物或某个抽象的概念。例如， $Teacher(x)$ 表示 ‘ x 是教师’，其中 $Teacher$ 是谓词名， x 是个体。
- ▶ 一阶谓词 (First-order Predicate)

一阶谓词是指谓词中的所有个体都是常量、变量或函数。换句话说，一阶谓词中的个体不能是谓词本身。例如：句子 ‘老张是一名老师’ 可以表示为 $Teacher(\text{老张})$ ，其中 ‘老张’ 是常量， $Teacher$ 是一阶谓词。一阶谓词逻辑是谓词逻辑中最常用的形式，具有较强的表达能力，能够描述大多数自然语言的语义。

- ▶ 二阶谓词 (Second-order Predicate)

二阶谓词是指某个个体本身又是一个一阶谓词。换句话说，二阶谓词允许谓词作为其他谓词的参数。例如：谓词 $IsProperty(P, x)$ 表示 ‘ P 是 x 的属性’，其中 P 是一个一阶谓词， x 是个体。句子 ‘红色是苹果的属性’ 可以表示为 $IsProperty(\text{Red}, \text{Apple})$ ，其中 Red 是一个一阶谓词， Apple 是个体。二阶谓词逻辑的表达能力更强，但也更加复杂，通常用于描述更高层次的语义关系。

谓词逻辑表示法

在谓词逻辑中，公式 (Formula) 是语义表示的基本单位。除了直接使用单个谓词和指代对象的常量、变量或函数组成原子公式 (Atomic Formula) 外，我们还可以使用逻辑连接词和量词构造更复杂的公式。原子公式是谓词演算的基本组块，而逻辑连接词和量词则为我们提供了组合和扩展这些基本组块的工具，从而能够表示更复杂的语义关系。

► (1) 连接词

$\neg$ ：“否定” (Negation) 或 “非”

$\vee$ ：“析取” (Disjunction) 或 “或”

$\wedge$ ：“合取” (Conjunction) 或 “与”

$\rightarrow$ ：“蕴含” (Implication) 或 “条件”

$\leftrightarrow$ ：“等价” (Equivalence) 或 “双向蕴含”

► (2) 量词

$\forall$ ：全称量词 (Universal Quantifier)，表示对个体域中的所有（或任意一个）个体。

$\exists$ ：存在量词 (Existential Quantifier)，表示在个体域中存在个体 x 。

谓词逻辑表示法

- ▶ 示例 1：“有机器人是红色的”

谓词定义：ROBOT(X) 表示 X 是机器人；COLOR(X,Y) 表示 X 的颜色为 Y

谓词公式： $(\exists X)[\text{ROBOT}(X) \wedge \text{COLOR}(X, \text{RED})]$

- ▶ 示例 2：“人人都爱护环境”

谓词定义：MAN(X) 表示 X 人；PROTECT(X,Y) 表示 X 保护 Y

谓词公式： $(\forall X)[\text{MAN}(X) \rightarrow \text{PROTECT}(X, \text{ENVIRONMENT})]$

- ▶ 示例 3：“小明不在 3 号房间”

谓词定义：INROOM(X,Y) 表示 X 在 Y 中

谓词公式： $\neg \text{INROOM}(\text{XIAOMING}, \text{ROOM3})$

谓词逻辑表示法

- ▶ **蕴含**：对于语句 p 和 q ， $p \rightarrow q$ 表示如果 p 成立，则 q 也成立。

如果 p 蕴含 q ，则当 p 为真时， q 一定为真；当 p 为假时， q 可以为真也可以为假。

例如，语句 p ：‘今天下雨’，语句 q ：‘我会带伞’。 $p \rightarrow q$ 表示‘如果今天下雨，那么我会带伞’。如果今天确实下雨（ p 为真），那么我一定会带伞（ q 为真）；如果今天没有下雨（ p 为假），我可能带伞也可能不带伞（ q 可以为真也可以为假）。

- ▶ **蕴含关系的逻辑性质**

必要条件与充分条件：如果 p 蕴含 q ，我们可以说 q 是 p 的必要条件，而 p 是 q 的充分条件。例如，‘今天下雨’是‘我会带伞’的充分条件，而‘我会带伞’是‘今天下雨’的必要条件。

逆否命题：蕴含关系 $p \rightarrow q$ 的逆否命题是 $\neg p \rightarrow \neg q$ ，两者具有相同的真值。例如，‘如果今天下雨，那么我会带伞’的逆否命题是‘如果我没有带伞，那么今天没有下雨’。

这些性质在逻辑推理和数学证明中具有重要应用。

谓词逻辑表示法

- **等价**：或“当且仅当”。对于两个语句 p 和 q ， $p \leftrightarrow q$ 表示 p 与 q 具有相同的真值。

如果 p 与 q 等价，则 p 是 q 的充分必要条件， q 也是 p 的充分必要条件。

等价关系意味着 p 和 q 在逻辑上可以互相替代。

例如，语句 p ：‘今天是星期一’，语句 q ：‘明天是星期二’。
 $p \leftrightarrow q$ 表示 ‘今天是星期一当且仅当明天是星期二’。这两个语句在逻辑上是等价的。”

谓词逻辑表示法

► 连接词真值表

P	Q	$\neg P$	$P \vee Q$	$P \wedge Q$	$P \rightarrow Q$	$P \leftrightarrow Q$
T	T	F	T	T	T	T
T	F	F	T	F	F	F
F	T	T	T	F	T	F
F	F	T	F	F	T	T

- 在逻辑中，蕴含关系 $P \rightarrow Q$ 等价于 $\neg P \vee Q$ 。这种等价形式为我们提供了一种新的视角来理解蕴含关系。具体来说：如果 P 是假的，那么 $\neg P$ 就是真的。由于 $\neg P \vee Q$ 中的 $\vee$ 是“或”运算符，所以无论 Q 是真是假， $\neg P \vee Q$ 都是真的。这种等价形式揭示了蕴含关系的一个重要性质：当 P 为假时， $P \rightarrow Q$ 总是为真，无论 Q 的真值如何。
- 让我们通过一个例子来说明蕴含关系的真值表分析。假设 P 是一个明显错误的命题：‘所有的鸟都会飞’，Q 是‘太阳会升起’。尽管 P 是假的，但我们不能说 P 能够推出 Q，因为这两个命题之间没有逻辑上的联系。然而，根据逻辑中蕴含的定义，‘所有的鸟都会飞 $\rightarrow$ 太阳会升起’这个蕴含是真的。这是因为 P 为假，根据蕴含关系的等价形式 $\neg P \vee Q$ ，整个表达式为真。
- 这种定义提供了一种一致的方式来处理假命题，避免了逻辑系统中的一些悖论。通过将蕴含关系转化为 $\neg P \vee Q$ ，我们可以简化逻辑推理过程。这种定义确保了逻辑系统的一致性，避免了因假命题导致的矛盾。尽管这种定义在直觉上可能看起来有些奇怪，但它在逻辑系统中是非常有用的。

谓词逻辑表示法

- ▶ 谓词逻辑具有扎实的数学基础，特别是一阶谓词逻辑，它具备充分的表达能力和完备的逻辑推理算法。这些特性使得谓词逻辑在语义表示中具有以下优点：

精确性：谓词逻辑能够精密地表达语义，确保推理过程和结果的准确性。

形式化：通过谓词、量词和逻辑连接词，谓词逻辑提供了一种形式化的方法来表示复杂的语义关系。

- ▶ **缺点**：在实际应用中，使用谓词逻辑表示语义并不简单。通常需要以下步骤：

1) 定义谓词及个体：首先需要确定每个谓词及个体的确切含义。例如，定义谓词 $\text{Teacher}(x)$ 表示‘ x 是教师’，个体‘老张’表示具体的人。

2) 变量赋值：根据所要表达的事物或概念，为每个谓词中的变量赋予特定的值。例如，将 x 赋值为‘老张’，得到 $\text{Teacher}(\text{老张})$ 。

3) 谓词公式构造：根据所表达的语义，用适当的逻辑连接词和量词将各谓词连接起来。例如，‘所有教师都是人’可以表示为 $\forall x (\text{Teacher}(x) \rightarrow \text{Human}(x))$ 。这些步骤虽然确保了语义表示的精确性，但也增加了使用的复杂性。”

框架表示法

- ▶ **框架 (Frame) 表示法**是以框架语义理论 (Frame Semantics) 为基础发展起来的一种语义表示方法。框架语义理论认为，理解语言的意义需要激活与之相关的背景知识和场景，即框架 (Frame)。框架表示法通过结构化的方式描述这些背景知识，为语义表示提供了一种形式化工具。
- ▶ 框架用来表示所讨论对象（一个事物、概念或事件）的语义。每个框架由若干**槽 (Slot)** 组成，每个槽描述框架所讨论对象的某一方面的属性。例如，一个‘购买’框架可能包含以下槽：买家：购买商品的人。卖家：出售商品的人。商品：被购买的商品。价格：商品的交易价格。
- ▶ 示例：‘在位于巴黎 11 区的巴塔克兰剧院，多名武装分子在巴黎当地时间 13 日晚劫持了正在剧院观看演出的大约 1500 名观众并与警方展开对峙。’我们可以用框架表示法将其语义表示为：
事件发生时间：巴黎当地时间 13 日晚
事件类型：劫持
事件种类：恐怖袭击
人目标：
类型：观众
数量：约 1500
事件发生地点：巴黎 11 区的巴塔克兰剧院
通过这种方式，我们可以清晰地描述事件的语义结构。

语义网表示法


- ▶ **语义网络 (Semantic Network)** 是一种用实体及其语义关系来表达知识和语义的网络图。它通过节点和弧的形式，直观地表示事物、概念、属性、动作等之间的关系。语义网络不仅能够清晰地展示语义结构，还为知识表示和推理提供了形式化工具。

- ▶ 语义网络由节点和弧组成：

节点：表示各种事件、事物、概念、属性、动作等，也可以是一个语义子网络。例如，‘猫’、‘动物’、‘颜色’等都可以作为节点。


弧：表示节点之间的语义关系，并且是有方向和标注的。方向表示节点间的主次关系，且方向不能随意调换。例如，‘猫’和‘动物’之间的关系可以用一条标注为‘是一种’的弧表示，方向从‘猫’指向‘动物’。

通过这种方式，语义网络能够系统地描述实体之间的语义关系。



语义网表示法


- ▶ **语义网络 (Semantic Network)** 不仅可以描述事物之间的简单关系 (如类属关系、聚集关系), 还可以表示更复杂的语义关系, 包括时间关系、位置关系、推论关系等。此外, 语义网还可以通过增加节点的方法表示合取、析取、蕴含等逻辑连接词。这种灵活性使得语义网能够处理多种复杂的语义结构。
- ▶ 例如, “如果明天下雨, 就去看电影或者唱歌” 的语义网表示



语义网表示法

► 语义网中的量词表示

在自然语言中，复杂的语义常常涉及量词，例如‘每一个’、‘有一个’等。为了在语义网中表示这些量词，我们可以引入**分区技术**。分区技术通过将语义网划分为不同的区域，来表示量词所限定的范围。例如，句子‘所有的学生都完成了课程设计’可以通过分区技术表示为：分区 1：表示‘所有的学生’。分区 2：表示‘完成了课程设计’。通过这种方式，语义网能够清晰地表示量词所限定的语义范围。




图：“所有的学生都完成了课程设计”的语言网表示样例

语义网表示法

► 语义网的语义检索

语义网的一个显著优势是能够比较容易地实现语义检索。通过语义网，我们可以根据事物的属性及其之间的语义联系进行检索。例如：检索‘完成了课程设计的学生’：可以通过查找与‘课程设计’节点相连的‘学生’节点来实现。



► 局限性：

形式表示体系不统一：语义网没有公认的形式表示体系，不同的系统可能采用不同的表示方法。

语义解释依赖算法：语义网所表达的语义需要依赖分析算法进行解释，这在实际应用中可能带来一定的复杂性。

表示形式不唯一：同一个语义可能有多种表示形式，这进一步增加了语义网处理的复杂性。

4.3 分布式表示


背景

▶ 向量空间模型的背景

现代文本表示学习，很大程度上受到 Salton 等人在 1975 年提出的[向量空间模型 \(Vector Space Model, VSM\)](#) 的影响。向量空间模型阐述了将单词和篇章表示为向量的思想，为自然语言处理中的文本表示和相似度计算提供了理论基础。这一模型不仅推动了信息检索领域的发展，也为后来的统计机器学习算法在自然语言处理中的应用奠定了基础。

▶ 向量空间模型的基本思想

向量空间模型的核心思想是将文本（如单词、句子或文档）表示为向量空间中的点。具体来说：每个文本被表示为一个高维向量，向量的每个维度对应一个特征（通常是单词或短语）。向量的值可以是单词的频率、权重或其他统计量。通过这种方式，文本的处理可以直观地映射到向量空间，体现为对文本向量的加法、减法、距离度量等操作。例如，两个文本的相似度可以通过计算它们对应向量的余弦相似度来衡量。



背景

► 独热表示的基本概念

在分布式表示提出之前，许多自然语言处理算法采用独热表示（One-hot Representation）来表示文本数据。独热表示是一种简单的编码方式，其中每个维度表示某个单词是否在文本中出现。例如，假设有一个类别变量‘颜色’，该变量包含三个可能的取值：‘红色’、‘蓝色’和‘绿色’。对于每个颜色值，我们可以用独热编码表示：‘红色’： $[1, 0, 0]$ ‘蓝色’： $[0, 1, 0]$ ‘绿色’： $[0, 0, 1]$ 通过这种方式，每个类别值被表示为一个唯一的向量。

► 独热表示的特点

唯一性：每个类别值被表示为一个唯一的向量，向量中只有一个维度为 1，其余维度为 0。

高维稀疏性：独热表示的维度与词表的大小一致，因此对于大规模词表，独热表示会导致高维稀疏向量。例如，如果词表包含 10,000 个单词，每个单词的独热表示将是一个 10,000 维的向量，其中只有一个维度为 1，其余维度为 0。

语义无关性：独热表示无法表示单词之间的语义相似度。例如，‘红色’和‘蓝色’在独热表示中是完全独立的向量，无法反映它们在语义上的相似性。这些特点使得独热表示在某些任务中表现有限。

分布式表示

► 分布式表示 (Distributed Representation) 的基本概念

是一种将文本表示为低维空间下稠密向量的方法。与传统的独热表示 (One-hot Representation) 不同，分布式表示通过将文本映射到低维连续向量空间，能够有效地捕捉文本之间的语义关联。这种方法不仅解决了独热表示的高维稀疏性问题，还为自然语言处理任务提供了更强大的语义表示工具。

► 分布式表示的优势

低维稠密性：分布式表示将文本映射到低维连续向量空间，避免了独热表示的高维稀疏性问题，提高了计算效率。

语义关联性：在低维表示空间中，分布式表示能够通过向量之间的计算关系（如余弦相似度、欧氏距离）体现文本间的语义关联。例如，语义相似的词语在向量空间中距离较近，而语义无关的词语距离较远。

泛化能力：分布式表示能够有效地编码任务所需的语法和语义信息，从而在下游任务（如文本分类、机器翻译）中表现出良好的泛化能力。

- 让我们通过一个例子来说明分布式表示的应用。假设我们有以下词语：‘国王’、‘女王’、‘男人’、‘女人’。在分布式表示中，这些词语被映射到低维向量空间，例如：‘国王’：[0.8, 0.2, 0.1] ‘女王’：[0.7, 0.3, 0.1] ‘男人’：[0.6, 0.1, 0.2] ‘女人’：[0.5, 0.2, 0.2] 通过计算这些向量之间的相似度，我们可以发现‘国王’和‘女王’在语义上更接近，而‘男人’和‘女人’在语义上也更接近。这种语义关联性为自然语言处理任务提供了重要的支持。

单词分布式表示

▶ 单词分布式表示 (Word Distributed Representation)

是一种将单词表示为定长低维稠密向量的方法。

▶ 单词分布式表示的目标是建立一个单词嵌入矩阵

$\mathbf{W} \in \mathbb{R}^{|V| \times d}$, 其中: $|V|$ 是词表的大小, d 是词向量的维度 (通常远小于 $|V|$)。

矩阵的每一行对应一个单词, 为单词的向量表示, 即词向量。
例如:

‘计算机’ 表示为 $[0.16, 0.19, -0.28, \dots, 0.87]$

‘电脑’ 表示为 $[0.20, 0.17, -0.21, \dots, 0.97]$

‘冰激凌’ 表示为 $[-0.90, 0.72, 0.65, \dots, 0.06]$

通过这种方式, 单词分布式表示能够编码不同单词之间的语义关联。

▶ 相比于独热表示, 分布式表示可以编码不同单词之间的语义关联。如果采用独热表示, “计算机” 与 “电脑” 以及 “计算机” 与 “冰激凌” 之间的相似度都相同。但是采用分布式表示可以使得 “计算机” 和 “电脑” 在大多数维度上相近, 这样 “计算机” 和 “电脑” 的向量之间的距离可以远小于 “计算机” 和 “冰激凌” 之间的距离。

单词分布式表示

- ▶ 单词分布式表示的目标
- ▶ 单词分布式表示的核心目标是在向量空间中建构单词之间的语义关联，使得含义相近的单词具有相似的向量表示。这一目标自然地引出了两个关键问题：
 - (1) 如何衡量单词语义的相近；
 - (2) 如何衡量表示的相似。

解决这两个问题是实现高质量单词分布式表示的基础。

- ▶ 衡量单词语义的相近
 - 1 针对第一个问题——如何衡量单词语义的相近，大部分单词分布式表示方法遵从分布式假设 (Distributional Hypothesis)。分布式假设认为，出现在相同上下文中的单词往往具有相似的语义。例如，‘计算机’和‘电脑’经常出现在相似的上下文中，因此它们的语义相近。

在分布式假设的基础上，这些方法侧重于还原单词之间的共现关系，即为频繁出现在相同上下文中的词语之间赋予较高的表示相似度。例如，Word2Vec 模型通过预测单词的上下文 (Skip-gram) 或根据上下文预测单词 (CBOW) 来学习词向量，从而捕捉单词之间的共现关系。

- 2 针对第二个问题——如何衡量表示向量的相似，根据下游应用场景的不同，可以采用多种方法来衡量表示向量的相似性。常见的相似度度量方法包括：

余弦相似度 (Cosine Similarity)：计算两个向量之间的夹角余弦值，取值范围为 $[-1, 1]$ ，值越接近 1 表示向量越相似。

L2 范数距离 (Euclidean Distance)：计算两个向量之间的欧氏距离，距离越小表示向量越相似。

点积 (Dot Product)：计算两个向量的点积，值越大表示向量越相似。

这些方法为衡量表示向量的相似性提供了形式化工具，能够有效地支持语义检索、文本分类等任务。

基于共现矩阵奇异值分解的词向量模型

- ▶ 分布式假设与共现矩阵
- ▶ 在分布式假设 (Distributional Hypothesis) 下, 我们希望单词之间的相似度能够体现为两个词出现在相同上下文的频率。为了实现这一目标, 可以采用共现矩阵 (Co-occurrence Matrix) 来表示单词之间的共现关系。

共现矩阵 $A \in \mathbb{R}^{|V| \times |V|}$ 是一个对称矩阵, 其中 A_{ij} 表示词表 V 中下标为 i 和 j 的单词出现在相同上下文中的次数。通过共现矩阵, 我们可以捕捉单词之间的语义关联。

- ▶ 共现矩阵的类型
 - 1 单词-文档共现矩阵 (Term-Document Co-occurrence Matrix) : 表示单词在文档中的共现关系。例如, 矩阵的每一行对应一个单词, 每一列对应一个文档, 矩阵元素表示单词在文档中出现的频率。
 - 2 基于窗口的共现矩阵 (Window-based Co-occurrence Matrix) : 表示单词在固定窗口大小内的共现关系。例如, 矩阵的每一行和每一列都对应一个单词, 矩阵元素表示两个单词在固定窗口大小内共同出现的次数。

基于共现矩阵奇异值分解的词向量模型

► 隐式语义分析 (Latent Semantic Analysis, LSA)

LSA 模型采用奇异值分解 (Singular Value Decomposition, SVD) 方法, 将共现矩阵转换为低维的单词向量表示。具体来说:

- (1) 对共现矩阵 A 进行奇异值分解, 得到 $A = U\Sigma V^T$, 其中 U 和 V 是正交矩阵, Σ 是对角矩阵。
- (2) 选择前 k 个最大的奇异值及其对应的奇异向量, 将共现矩阵 A 近似为 $A_k = U_k \Sigma_k V_k^T$ 。
- (3) 矩阵 U_k 的每一行对应一个单词的低维向量表示。

通过这种方式, LSA 能够将高维稀疏的共现矩阵转换为低维稠密的单词向量表示, 从而捕捉单词之间的语义关联。

基于共现矩阵奇异值分解的词向量模型

- “I like deep learning. I like NLP. I enjoy flying.”

counts	I	like	enjoy	deep	learning	NLP	flying	.
I	0	2	1	0	0	0	0	0
like	2	0	0	1	0	1	0	0
enjoy	1	0	0	0	0	0	1	0
deep	0	1	0	0	1	0	0	0
learning	0	0	0	1	0	0	0	1
NLP	0	1	0	0	0	0	0	1
flying	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0

输入: 共现矩阵 $A \in \mathbb{R}^{|\mathcal{V}| \times |\mathcal{V}|}$, 嵌入维度 d

输出: 词表示矩阵 $W \in \mathbb{R}^{|\mathcal{V}| \times d}$

$U, \Sigma, V = \text{SVD}(A)$

// 由 A 是对称方阵, 可知 $U = V$, Σ 是对角方阵

$U, \Sigma = U_{:, :d}, \Sigma_{:, :d}$

// 特征降维, 保留最重要的 d 维, $A \approx U \Sigma U^T$

$\text{diag}(\sigma_1, \dots, \sigma_d) = \Sigma$

// Σ 包含最重要的 d 个奇异值 $\{\sigma_i\}_{i=1}^d$

$\sqrt{\Sigma} = \text{diag}(\sqrt{\sigma_1}, \dots, \sqrt{\sigma_d})$

// $\sqrt{\Sigma} \sqrt{\Sigma}^T = \Sigma$

$W = U \sqrt{\Sigma}$

// $W W^T = U \Sigma U^T \approx A$

return W

基于共现矩阵奇异值分解的词向量模型

► 低秩矩阵近似

$$\begin{array}{ccccccc} \begin{array}{c} m \\ \boxed{} \\ n \\ A \end{array} & = & \begin{array}{c} r \\ \boxed{\begin{array}{c} | \\ U_1 \\ | \\ U_2 \\ | \\ U_3 \\ | \\ \vdots \end{array}} \\ n \\ U \end{array} & \begin{array}{c} r \\ \boxed{\begin{array}{ccc} S_1 & & \\ & S_2 & 0 \\ & & \ddots \\ 0 & & & S_r \end{array}} \\ r \\ \Sigma \end{array} & \begin{array}{c} m \\ \boxed{\begin{array}{c} \text{---} V_1 \text{---} \\ \text{---} V_2 \text{---} \\ \text{---} V_3 \text{---} \\ \vdots \end{array}} \\ r \\ V^T \end{array} \\ \begin{array}{c} m \\ \boxed{\phantom{\hat{A}}} \\ n \\ \hat{A} \end{array} & = & \begin{array}{c} k \\ \boxed{\begin{array}{c} | \\ U_1 \\ | \\ U_2 \\ | \\ U_3 \\ | \\ \vdots \end{array}} \\ n \\ \hat{U} \end{array} & \begin{array}{c} k \\ \boxed{\begin{array}{ccc} S_1 & & \\ & S_2 & 0 \\ & & \ddots \\ 0 & & & S_k \end{array}} \\ k \\ \hat{\Sigma} \end{array} & \begin{array}{c} m \\ \boxed{\begin{array}{c} \text{---} V_1 \text{---} \\ \text{---} V_2 \text{---} \\ \text{---} V_3 \text{---} \\ \vdots \end{array}} \\ k \\ \hat{V}^T \end{array} \end{array}$$

图: A 为对称方阵, 图中 $m = n$, $U = V$

基于共现矩阵奇异值分解的词向量模型

► LSA 的优势

- 1 降维能力：通过奇异值分解，LSA 能够将高维稀疏的共现矩阵转换为低维稠密的单词向量表示，提高了计算效率。
- 2 语义捕捉：LSA 能够捕捉单词之间的语义关联，例如同义词、上下位关系等。

► 然而，LSA 模型也存在一些局限性：


- 1 上下文缺失：LSA 忽略了单词的上下文信息，难以处理多义词和复杂语义。
- 2 计算复杂性：对于大规模词表，奇异值分解的计算复杂度较高。

这些局限性促使研究者提出了更先进的单词分布式表示方法，例如 Word2Vec、GloVe 等。


基于上下文单词预测词向量模型

- ▶ **Word2vec**是一种用于学习单词分布式表示的模型，由 Google 在 2013 年提出。它大幅简化了以往的神经网络语言模型 (Neural Probabilistic Language Model, NPLM)，去除了非线性隐藏层，并使用自监督的方式从大量无监督文本中训练词表示模型。Word2vec 的核心思想是通过预测上下文或目标词来学习单词的低维稠密向量表示，从而捕捉单词之间的语义关联。
- ▶ Word2vec 构建了两种神经网络模型结构
 - 1 **连续词袋模型 (Continuous Bag of Words, CBOW)**：CBOW 模型通过上下文词预测目标词。例如，给定句子 ‘猫在垫子上’，CBOW 模型会利用 ‘猫’、‘在’、‘上’ 这些上下文词来预测目标词 ‘垫子’。
 - 2 **跳字模型 (Skip-Gram, SG)**：Skip-Gram 模型通过目标词预测上下文词。例如，给定目标词 ‘垫子’，Skip-Gram 模型会预测其上下文词 ‘猫’、‘在’、‘上’。

这两种模型结构都通过自监督学习的方式，从大量无监督文本中学习单词的分布式表示。



(a) CBOW 模型



(b) Skip-Gram 模型

基于上下文单词预测词向量模型

- Skip-Gram模型的优化目标是通过最大化上下文词的条件概率来学习单词的分布式表示。具体来说，Skip-Gram 模型以负对数概率形式的损失函数作为优化目标：

$$\mathcal{L}(w_1 \cdots w_T) = - \sum_{t=1}^T \sum_{-n \leq i \leq n, i \neq 0} \log P(w_{t+i} | w_t)$$

词嵌入矩阵 $\mathbf{U} \in \mathbb{R}^{|V| \times d}$ 表示词表中每个单词作为上下文词时的词向量；
词嵌入矩阵 $\mathbf{V} \in \mathbb{R}^{|V| \times d}$ 表示词表中每个单词作为中心词时的词向量。
Skip-Gram 模型通过上下文词和中心词向量的相似度估计上下文词的出现概率：

$$P(w_o | w_c) = \frac{\exp(\mathbf{u}_o^\top \mathbf{v}_c)}{\sum_{i \in V} \exp(\mathbf{u}_i^\top \mathbf{v}_c)}$$

w_o 和 w_c 分别表示特定的上下文词和中心词， $\mathbf{u}_o$ 是 w_o 用作上下文词的表示， $\mathbf{v}_c$ 是 w_c 用作中心词的表示， $\mathbf{u}_i$ 是词表中每个词用作上下文词的表示。

- 在优化上述目标函数后，Skip-Gram 模型通常采用训练好的中心词表示 $\mathbf{V}$ 作为最终的词表示。具体来说：通过梯度下降法或其他优化算法，最小化损失函数 $\mathcal{L}$ 。在训练过程中，模型会不断更新词嵌入矩阵 $\mathbf{U}$ 和 $\mathbf{V}$ ，使得中心词能够更好地预测其上下文词。训练完成后，矩阵 $\mathbf{V}$ 的每一行对应一个单词的词向量，这些词向量能够捕捉单词之间的语义关联。

基于上下文单词预测词向量模型

- **CBoW 模型** 假设文本中的词可以通过其在文本中的上下文词推导出来。换句话说，CBoW 模型通过上下文词来预测中心词。CBoW 模型以负对数概率形式的损失函数作为优化目标：

$$\mathcal{L}(w_1 \cdots w_T) = - \sum_{t=1}^T \log P(w_t | w_{t-n}, \cdots, w_{t-1}, w_{t+1}, \cdots, w_{t+n})$$

用 $\mathbf{U} \in \mathbb{R}^{|\mathcal{V}| \times d}$ 表示中心词词向量矩阵， $\mathbf{V} \in \mathbb{R}^{|\mathcal{V}| \times d}$ 表示上下文词向量。CBoW 模型通过计算上下文词的平均向量 $\mathbf{v}_0$ 来预测中心词

$$\mathbf{v}_0 = \frac{1}{2m} \sum_{-n \leq i \leq n, i \neq 0} \mathbf{v}_{c+i}$$

CBoW 模型通过上下文词的平均向量 $\mathbf{v}_0$ 和中心词向量 $\mathbf{u}_c$ 的相似度来计算中心词的条件概率

$$P(w_c | w_{c-n}, \cdots, w_{c-1}, w_{c+1}, \cdots, w_{c+n}) = \frac{\exp(\mathbf{u}_c^\top \mathbf{v}_0)}{\sum_{i \in \mathcal{V}} \exp(\mathbf{u}_i^\top \mathbf{v}_0)}$$

$\mathbf{v}_0$ 是平均的上下文词向量，用于计算和中心词的相似度； $\mathbf{u}_c$ 是 w_c 用作中心词的表示， $\mathbf{u}_i$ 是词表中每个词用作中心词的表示。

基于上下文单词预测词向量模型

► 大规模词表的计算开销问题

在实际应用中，词表通常包含数万甚至数十万单词。Skip-Gram 和 CBoW 模型在基于 Softmax 计算上下文词和中心词的出现概率时，需要对整个词表进行相似度计算，这会产生非常大规模的计算开销。例如，对于一个包含 10 万单词的词表，每次梯度更新都需要计算 10 万次相似度，这在实际训练中是不可行的。

► 负采样 (Negative Sampling)

为了降低计算开销，通常使用负采样的方法。负采样将目标函数中全体词表范围的相似度计算修正为目标词和 K 个负例的相似度计算，其中 K 是远小于词表大小的超参数。具体来说：

对于每个正例（目标词和上下文词），随机采样 K 个负例（非上下文词）。通过计算目标词与正例和负例的相似度，更新模型参数。

通过这种方式，负采样使得训练的计算开销与词表大小无关，而只与超参数 K 相关，从而大大降低了计算复杂度。

► 层次 Softmax (Hierarchical Softmax)

另一种降低计算开销的方法是层次 Softmax。层次 Softmax 通过构建一个二叉树来表示词表，每个叶子节点对应一个单词，内部节点表示概率分布的层次结构。在层次 Softmax 中，计算目标词的概率分布只需要遍历从根节点到目标词叶子节点的路径，而不需要计算整个词表的相似度。通过这种方式，层次 Softmax 将计算复杂度从 $O(|V|)$ 降低到 $O(\log |V|)$ ，从而大大减少了计算开销。层次 Softmax 特别适用于词表非常大的场景。

基于上下文单词预测词向量模型

负采样 (Negative Sampling)

- ▶ 负采样通过以下概率模型将词向量的相似度和词出现在上下文窗口的概率相关联：

$$\text{正样本概率: } P(D = 1|w_o, w_c) = \sigma(u_o^T v_c)$$

$$\text{负样本概率: } P(D = 0|w_o, w_c) = 1 - P(D = 1|w_o, w_c)$$

$D = 1$ 表示这组上下文词-中心词来自训练语料，即单词 w_o 出现在 w_c 的上下文窗口中。 $D = 0$ 表示这组上下文词-中心词未来自训练语料，即单词 w_o 未出现在 w_c 的上下文窗口中。 σ 表示 Sigmoid 函数， u_o 是 w_o 用作上下文词的表示， v_c 是 w_c 用作中心词的表示。

- ▶ 负采样的优化目标

对于每组上下文词-中心词，原 Skip-Gram 模型只优化正样本

$P(D = 1|w_o, w_c)$ ，而负采样下的模型从原始词分布 $P(w)$ 中采样 K 个未出现在上下文窗口中的词 $w_1, \dots, w_K$ 作为负样本，并额外将 $P(D = 0|w_i, w_c)$ 作为优化目标，形式化表示为：

$$P(w_o|w_c) = P(D = 1|w_o, w_c) \prod_{i=1}^K P(D = 0|w_i, w_c)$$

- ▶ 负采样的优势

计算效率：通过减少相似度计算的次数，负采样大大降低了训练的计算开销。灵活性：超参数 K 可以根据具体任务进行调整，平衡计算效率和模型性能。适用性：负采样适用于大规模词表和复杂语义关系的建模。

基于上下文单词预测词向量模型

负采样 (Negative Sampling) : 对于一个给定的词, 如何生成负样本?

- ▶ 在负采样中, 负样本生成是一个关键步骤。负样本是指未出现在上下文窗口中的词, 用于优化模型参数。负样本的生成需要遵循一定的概率分布, 以确保高频词被选为负样本的概率较大, 而低频词被选中的概率较小。这种带权采样的方法能够提高模型的训练效率和性能。
- ▶ 带权采样的实现

设词典 D 中的每一个词 w 对应一个线段 $l(w)$, 长度为:

$$\text{len}(w) = \frac{\text{counter}(w)}{\sum_{u \in D} \text{counter}(u)}$$

其中, $\text{counter}(w)$ 表示词 w 在语料中出现的次数, 分母中的求和项用来做归一化。

将这些线段首尾相连地拼接在一起, 形成一个长度为 1 的单位线段。

如果随机地往这个单位线段上打点, 则其中长度越长的线段 (对应高频词) 被打中的概率就越大。

通过这种方式, 带权采样能够确保高频词被选为负样本的概率较大, 而低频词被选中的概率较小。

基于上下文单词预测词向量模型

负采样 (Negative Sampling) :


► 带权采样的实现方法

(1) 非等距剖分：词典中的每一个词 w_k 对应一条线段 $I_i = (l_{i-1}, l_i]$ ，所有词组成了 $[0, 1]$ 间的非等距剖分。线段的长度 $\text{len}(w_k)$ 与词的频率成正比。

(2) 等距剖分：引入 $[0, 1]$ 上的一个等距剖分，剖分节点为 $\{m_j\}_{j=0}^M$ ，其中 $M \ll N$ (N 是词典大小)。

(3) 映射关系：建立由 m_j 到区间 I_i 的映射关系 $\text{Table}(i) = w_k$ ，其中 $m_i \in I_k$ 。

(4) 采样过程：每次生成一个 $[1, M - 1]$ 间的随机整数 r ，看落在哪个词对应的剖分上， $\text{Table}(r)$ 就是一个样本。如果恰巧选到 w_i 本身，word2vec 则直接跳过。



- 在实际应用中，设置权值 $\text{len}(w) = \frac{[\text{counter}(w)]^{3/4}}{\sum_{u \in D} [\text{counter}(u)]^{3/4}}$ 时效果最好。这种设置能够平衡高频词和低频词的影响，避免高频词过于频繁地被选为负样本，从而提高模型的训练效果。

基于上下文单词预测词向量模型

层次 Softmax (Hierarchical Softmax)

- ▶ 一种用于降低 Skip-Gram 和 CBoW 模型计算开销的技术。它将词表组织成二叉树结构（通常是哈夫曼树），树的每个叶子节点代表词表中的一个词语。通过这种方式，层次 Softmax 将计算复杂度从 $O(|V|)$ 降低到 $O(\log |V|)$ ，从而大大减少了训练的计算开销。

- ▶ 层次 Softmax 的二叉树结构

在层次 Softmax 中，词表被组织成二叉树结构，每个叶子节点对应一个词语。具体来说：

路径表示： $w(n, j)$ 表示从根 root 到叶子结点 w 的路径上的第 j 个结点。

路径长度： $L(w)$ 表示路径长度，定义为路径中的结点个数。例如， $n(w, 1) = \text{root}$, $n(w, L(w)) = w$ 。

- ▶ 层次 Softmax 的二分类

在层次 Softmax 中，二叉树的每个内部节点都定义了一个二分类问题。例如，可以定义左分支为正类，右分支为负类。具体来说：

如果 $n(w, j + 1) = \text{left}(n(w, j))$ ，则路径上的第 j 个结点被分类为正类。

如果 $n(w, j + 1) = \text{right}(n(w, j))$ ，则路径上的第 j 个结点被分类为负类。


若 $n(w, j + 1) = \text{left}(n(w, j))$ 为 True，则 $\mathbb{I}[n(w, j + 1) = \text{left}(n(w, j))] = 1$

基于上下文单词预测词向量模型 层次 Softmax (Hierarchical Softmax)

► 则词 w_o 出现在 w_c 的上下文窗口中的概率估计为:

$$P(w_o|w_c) = \prod_{j=1}^{L(w)-1} \sigma \left(\llbracket n(w, j+1) = \text{left}(n(w, j)) \rrbracket \cdot \mathbf{u}_{n(w, j)}^\top \mathbf{v}_{w_c} \right)$$

其中 $\sigma(x) = 1/(1 + \exp(-x))$ 。




基于上下文单词预测词向量模型

层次 Softmax (Hierarchical Softmax)

- 假设词表中有一个词 $w = \text{'足球'}$ ，在哈夫曼树中，从根结点出发到‘足球’所在的叶子结点，路径中有 4 个分支。每个分支表示进行一次二分类。具体来说：

路径表示： $w(n, j)$ 表示从根 root 到叶子结点 w 的路径上的第 j 个结点。

路径长度： $L(w) = 4$ ，表示路径中有 4 个结点。



基于上下文单词预测词向量模型

层次 Softmax (Hierarchical Softmax)

- ▶ 在层次 Softmax 中，每个内部节点都定义了一个二分类问题。例如，可以定义左分支为正类，右分支为负类。具体来说：

非叶结点对应的参数向量：每个非叶结点 n 对应一个参数向量 $\theta_i^{w_t}$ ；

二分类概率：从根结点出发到‘足球’所在叶子结点所经历的 4 次二分类，每次分类的概率可以表示为：

$$p(d_j^w | w_c) = \sigma(u_n^T v_c)$$

u_n 是非叶结点 n 的参数向量。 v_c 是中心词 w_c 的词向量。

路径概率：‘足球’的条件概率可以表示为路径上所有二分类概率的连乘积：

$$p(w = \text{足球} | w_c) = \prod_{i=2}^5 p(d_i^w | w_c, \theta_{i-1}^w)$$

基于上下文单词预测词向量模型

层次 Softmax (Hierarchical Softmax)

► 层次 Softmax 的一般形式

对于词典 V 中的任意词 w ，哈夫曼树中必存在一条从根结点到词 w 对应结点的路径（唯一的路径），路径上存在 L^w 个分支。将每个分支看做一次二分类，每次分类产生一个概率，连乘起来即可得到概率：

$$p(w_t | \text{context}_t) = \prod_{j=2}^{L^{w_t}} p(d_j^{w_t} | c_t, \theta_{j-1}^{w_t})$$

context_t 表示上下文词。 c_t 表示中心词。 $\theta_{j-1}^{w_t}$ 表示路径上第 $j-1$ 个非叶结点的参数向量。

基于上下文单词预测词向量模型

层次 Softmax (Hierarchical Softmax)

- ▶ 层次 Softmax 的概率归一化性质

对于任意的中心词 w_c ，层次 Softmax 保证词表中所有词出现在中心词上下文窗口特定位置的条件概率之和为 1。具体来说：

$$\sum_{w=1}^{|V|} p(w|w_c) = 1$$

其中， $|V|$ 是词表的大小。这一性质确保了层次 Softmax 的概率分布是归一化的，从而使得模型能够正确地表示词表中所有词的条件概率。

- ▶ 层次 Softmax 的计算开销

基于层次 Softmax 计算词表示模型时，由于层次 Softmax 通过一系列二分类问题来计算目标词的概率分布，计算开销与路径长度 $L(w)$ 的平均值呈线性关系。

- ▶ 层次 Softmax 的计算复杂度上界

当使用满二叉树结构容纳词表时，路径长度 $L(w)$ 具有 $\mathcal{O}(\log_2 |V|)$ 的上界。具体来说：

满二叉树：在满二叉树中，每个内部节点都有两个子节点，路径长度 $L(w)$ 最多为 $\log_2 |V|$ 。

计算复杂度：由于层次 Softmax 的计算开销与路径长度 $L(w)$ 的平均值呈线性关系，因此层次 Softmax 的计算复杂度为 $\mathcal{O}(\log_2 |V|)$ 。

全局向量 (GloVe) 模型

► 局部信息与全局信息的结合

在词表示学习中，局部信息和全局信息都提供了有效的语义信息。
例如：

Skip-Gram 和 CBOW 模型：这些模型根据局部信息进行学习，通过预测上下文词或中心词来捕捉单词之间的语义关系。

LSA 模型：LSA 模型基于词共现矩阵的全局信息，通过奇异值分解 (SVD) 来得到词语表示。

全局统计信息和局部信息各有优势，结合这两种信息可以进一步提高词表示的质量。

► GloVe (Global Vectors for Word Representation, GloVe) 模型的基本思想

结合了局部信息和全局信息的优点，从共现概率的角度分析并改进了 Skip-Gram 模型。具体来说：

局部信息：GloVe 模型使用文本中局部的上下文信息，捕捉单词之间的语义关系。

全局信息：GloVe 模型对语料库的全局共现统计数据加以利用，通过共现矩阵来捕捉单词之间的全局语义关系。

全局向量 (GloVe) 模型

► GloVe 模型的共现矩阵

GloVe 模型基于上下文窗口共现矩阵的统计，即对语料库中特定中心词-上下文词对的出现次数进行统计。在共现计数方法的基础上，GloVe 模型进一步考虑了中心词和上下文词之间的距离，使相距更近的中心词-上下文词对对于共现次数起到更大的贡献。具体来说：

共现矩阵：共现矩阵 X 中的每个元素 X_{ij} 表示词 w_i 和词 w_j 在特定上下文窗口内的共现次数。

距离加权：GloVe 模型通过距离加权的方式，使得相距更近的中心词-上下文词对对于共现次数起到更大的贡献。

► 共现矩阵的统计与概率估计

在 GloVe 模型中，共现矩阵的统计和概率估计是关键步骤。具体来说：上下文词的总数：出现在词 w_i 上下文的任意词的个数表示为：

$$X_i = \sum_k X_{ik}$$

共现概率：由共现矩阵可以得到单词 w_j 出现在单词 w_i 上下文的共现概率：

$$p_{ij} = P(w_j|w_i) = \frac{X_{ij}}{X_i}$$

全局向量 (GloVe) 模型

- GloVe 模型对 Skip-Gram 进行了重要改进，主要体现在以下几个方面：

损失函数：GloVe 模型用平方损失代替了 Skip-Gram 模型中的交叉熵损失，从而简化了优化过程。

偏置项：GloVe 模型为每个单词 w_i 引入了可训练的中心词偏置项 b_i 和上下文词偏置项 $\tilde{b}_j$ ，用于校正训练目标。

- GloVe 模型的优化目标是通过最小化以下损失函数来学习词向量：

$$\mathcal{J} = \sum_{i,j=1}^{|V|} f(X_{ij}) \left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2$$

其中： X_{ij} 表示词 i 和词 j 的共现次数。 w_i 和 $\tilde{w}_j$ 分别是词 i 和词 j 的词向量。 b_i 和 $\tilde{b}_j$ 分别是词 i 和词 j 的偏置项。 $f(X_{ij})$ 是一个加权函数，用于平衡高频词和低频词的影响。

- **权重函数的设计**：GloVe 模型中的权重函数 $f(x)$ 用于平衡高频词和低频词的影响。具体来说：

$$f(x) = \begin{cases} 1 \left(\frac{x}{x_{\max}} \right)^{\alpha} & \text{if } x < x_{\max} \\ 1 & \text{otherwise} \end{cases} \quad (1)$$

全局向量 (GloVe) 模型

在 GloVe 模型中, 权重函数 $f(x)$ 用于平衡高频词和低频词的影响。权重函数具有以下基本性质:

- ▶ 单调递减: 距离越远权重越小, 符合共现词之间距离的反比关系。使得模型能够更准确地捕捉单词之间的语义关系。
- ▶ 非负性: 权重函数的取值范围在 $[0, 1]$ 之间。
- ▶ 对称性: $f_{ij} = f_{ji}$, 即共现关系是对称的。使得模型能够更好地处理双向语义关系。
- ▶ 自反性: $f_{ii} = 1$, 即一个词和自己的共现关系的权重为 1。确保了模型能够正确处理自共现关系。
- ▶ 严格截断性: 当共现距离超过截断距离 $x_{\max}$ 时, 权重为 1, 即共现距离超过一定阈值后, 权重不再随距离增大而逐渐变小, 避免了共现矩阵中的噪声和无关信息。






图: GloVe 设置参数 $x_{\max} = 100, \alpha = 3/4$ 。

全局向量 (GloVe) 模型

GloVe、CBOW 和 Skip-Gram 在单词类比任务上的实验对比

- ▶ 实验设置与训练时间控制：GloVe：训练时间由迭代次数控制。CBOW 和 Skip-Gram：训练时间由负采样的数量控制。实验中，作者使用大小为 10 的对称上下文窗口，在 Wikipedia 2014 + Gigaword 5 语料数据上训练了 300 维的向量模型。通过这种方式，实验能够比较不同模型在单词类比任务中的表现。
- ▶ 随着迭代次数和负样本数的增加，模型在单词类比任务中的准确性逐渐提高，但在一定程度上会出现收敛的趋势。具体来说：迭代次数：随着 GloVe 模型的迭代次数增加，模型在单词类比任务中的准确性逐渐提高，但最终会趋于收敛。负样本数：随着 CBOW 和 Skip-Gram 模型的负样本数增加，模型在单词类比任务中的准确性也逐渐提高，但同样会趋于收敛。这些结果表明，适当增加迭代次数和负样本数可以提高模型的性能，但过度的增加可能会导致性能提升的边际效应递减。



全局向量 (GloVe) 模型

词类比 (Word Analogies) 任务

- 一种用于测试单词之间线性关系的任务。它通过给定一组单词对，要求模型预测另一组单词对。例如，给定‘男人’和‘女人’，‘国王’和？，模型需要预测‘女王’。词类比任务能够有效地评估词向量模型捕捉语义关系的能力。

Test for linear relationships, examined by Mikolov et al. (2014)


a:b :: c:?



$$d = \arg \max_x \frac{(w_b - w_a + w_c)^T w_x}{||w_b - w_a + w_c||}$$





man:woman :: king:?

+	king	[0.30 0.70]
-	man	[0.20 0.20]
+	woman	[0.60 0.30]
	queen	[0.70 0.80]



全局向量 (GloVe) 模型

词类比 (Word Analogies) 任务



基于字节对编码的子词表示模型

► 固定词表模型的局限性

前几节所介绍的词表示模型都依赖预先确定的词表 V ，在编码输入词序列时，这些模型只能处理词表中存在的词。然而，这种固定词表模型存在以下局限性：

未登录词问题：在固定词表模型中，未登录词通常通过以下方式处理：
默认标识：模型会预先在词表中加入一个默认的 ‘[UNK]’ (unknown) 标识，表示未知词。

训练与使用：在训练过程中，将 [UNK] 的向量作为词表示矩阵的一部分一起训练。在使用时，对于全部的未登录词，都使用 [UNK] 的向量作为这些词的表示向量。然而，这种处理方式存在明显的局限性：信息丢失：未登录词的语义信息被忽略，导致模型在处理未登录词时表现不佳。通用表示：所有未登录词共享同一个表示向量，无法区分不同未登录词的语义差异。

词表大小敏感性：固定词表模型对词表大小的选择比较敏感。当词表大小过小时，未登录词的比例较高，影响模型性能；而当词表大小过大时，大量低频词出现在词表中，这些词的词向量很难得到充分学习。

这些局限性促使研究者提出了基于子词的表示模型，例如**字节对编码 (Byte Pair Encoding, BPE)**。

基于字节对编码的子词表示模型

- ▶ **字符级表示的局限性**：为了缓解未登录词问题，一种直接的解决思路是为输入建立字符级表示，并通过字符向量的组合来获得每个单词的表示。然而，这种方法存在以下局限性：

构词模式的学习：单词中的词根、词缀等构词模式往往跨越多个字符，基于字符表示的方法很难学习跨度较大的模式。

计算复杂度：字符级表示需要处理更多的输入单元，增加了计算复杂度。

- ▶ **子词表示模型的基本概念**

子词表示模型提出了**子词 (Subword)** 的概念，子词表示模型会维护一个子词词表，其中既存在完整的单词，也存在形如 ‘c’、‘re’、‘ing’ 等单词部分信息，称为子词。具体来说：


子词词表：子词词表包含完整的单词和常见的子词单元。

输入处理：对于输入的词序列，子词表示模型将每个词拆分为词表内的子词。例如，将单词 ‘reborn’ 拆分为 ‘re’ 和 ‘born’。

表示组合：模型随后查询每个子词的表示，将输入重新组成为子词表示序列。

基于字节对编码的子词表示模型

- ▶ **字节对编码 (BPE)** 是一种常见的子词表示模型，最早由 Philip Gage 于 1994 年提出。它的核心思想是通过统计和迭代合并的方式，将词汇分解为更小的子词单元。BPE 在自然语言处理 (NLP) 中广泛应用，尤其是在处理未登录词 (Out-of-Vocabulary, OOV) 问题时表现出色。
- ▶ BPE 的词表不仅包含常见的完整单词，还包含高频出现的子词。这种设计使得常见词可以直接被词表覆盖，而罕见词则可以被分解为多个子词，从而显著降低未登录词的比例。例如，单词 “unhappiness” 可以被分解为 “un”、“happiness” 或更小的子词单元 “un”、“happi”、“ness”。
- ▶ **BPE 的核心思想** 是通过逐步合并高频字符对来构建子词词表。具体来说，BPE 从字符级别的词表开始，通过统计训练语料中字符对的出现频率，逐步将高频字符对合并为新的子词单元，直到达到预定的词表大小。
- ▶ 举例说明：假设训练语料中包含以下单词及其频率：“low” : 6、“lower” : 2、“newest” : 6、“widest” : 3。BPE 的合并过程：1) 初始词表：字符集 l, o, w, e, r, n, s, t, i, d。2) 统计字符对频率，例如 “lo”、“ow”、“ne” 等。3) 合并最高频的字符对，例如 “e” 和 “s” 合并为 “es”。4) 重复上述过程，直到词表大小达到预设值。



基于字节对编码的子词表示模型

- ▶ **子词切分过程**：在子词词表确定之后，BPE 算法需要对输入词序列中未出现在词表中的全词进行切分。切分过程的核心思想是按子词长度从长到短的顺序遍历词表，尝试将全词切分为已知的子词。具体步骤：
 - 1 初始化：将输入词序列中的每个词标记为未切分状态。
 - 2 遍历词表：按子词长度从长到短的顺序遍历词表，尝试匹配未切分的词或部分词。
 - 3 匹配与切分：如果当前子词与未切分的部分匹配，则将该部分切分为当前子词和剩余部分。重复上述过程，直到所有部分都被切分为已知的子词。
 - 4 终结符处理：在切分过程中，终结符 `</w>` 用于标记单词的结束，确保切分结果能够正确反映单词的边界。

举例说明：假设子词词表包含以下子词：`low`, `est</w>`, `er</w>`，需要对单词 `lowest</w>` 进行切分。首先，尝试匹配最长的子词 `est</w>`，将 `lowest</w>` 切分为 `low` 和 `est</w>`。接着，尝试匹配子词 `low`，发现 `low` 已经是一个已知子词。最终切分结果为 `low` 和 `est</w>`。
- ▶ **输出序列的重组**：对于使用了子词表示模型的自然语言处理系统（如机器翻译系统），其输出序列通常是子词序列。为了得到最终的可读结果，需要将子词序列重新组合为完整的词序列。具体步骤：

确定单词范围：根据终结符 `</w>` 的位置，确定每个单词的边界。合并子词：将每个单词范围内的子词按顺序合并，形成完整的单词。生成最终结果：将所有合并后的单词按顺序组合，得到最终的词序列。

单词分布式表示的评价与应用

单词分布式表示模型（如 Word2Vec、GloVe、FastText 等）的评估方法主要分为两类：内部评价（Intrinsic Evaluation）和外部评价（Extrinsic Evaluation）。这两种方法从不同角度评估词向量的质量，帮助我们理解模型的特点并选择适合实际任务的词向量模型。

- ▶ **内部评价** 内部评价方法通过设计一个辅助任务，直接评估词向量是否具有某种期望的性质，如词义相关性、类比性等。这种方法通常返回一个分数，用于衡量词向量的好坏。常用辅助任务：

词义相关性（Word Similarity）：计算词向量之间的相似度（如余弦相似度），并与人类标注的相似度评分进行比较。

类比性（Word Analogy）：通过词向量解决类比问题，例如“国王 - 男人 + 女人 = 女王”。

聚类质量（Clustering Quality）：对词向量进行聚类，评估聚类结果与真实语义类别的匹配程度。

- ▶ **外部评价** 外部评价方法基于一个实际应用任务（如文本分类、机器翻译、命名实体识别等），通过将词向量作为该任务的输入表示，比较不同词向量模型在该任务上的性能，从而选择适合的词向量模型。

文本分类：将词向量作为分类模型的输入，评估分类性能。

命名实体识别：将词向量作为 NER 模型的输入，评估实体识别的性能。

机器翻译：将词向量作为机器翻译模型的输入，评估翻译质量。

单词分布式表示的评价与应用

在评价词向量模型的综合性能时，通常会使用内部评估方法。

- ▶ **内部评估方法**通过设计简单的辅助任务，直接评估词向量的性质（如词义相关性、类比性等），具有以下**优点**：

任务简单：辅助任务通常比实际应用任务更简单，例如计算词向量之间的相似度或解决类比问题。

计算速度快：由于任务简单且数据规模较小，内部评估的计算速度通常较快。

针对性明确：内部评估直接关注词向量本身的性质，能够清晰反映词向量模型的特点。

- ▶ **外部评估方法**通过实际应用任务（如文本分类、机器翻译等）评估词向量的性能，但其**局限性**主要体现在以下方面：

任务复杂性：实际应用任务通常涉及复杂的模型和流程，例如文本分类任务需要设计分类器，机器翻译任务需要构建序列到序列模型。

问题定位困难：当系统整体表现不佳时，问题可能来自词向量模型，也可能来自下游任务模型或两者之间的交互。这种复杂性使得外部评估难以直接指导词向量模型的选择与改进。

计算成本高：实际应用任务通常需要更大的数据集和更复杂的计算，导致评估成本较高。

单词分布式表示的评价与应用

词义相关性任务

- ▶ 词义相关性任务通过评估词向量对词义相关性的表达能力，来衡量词向量模型的质量。具体来说，该任务要求模型能够捕捉单词之间的语义关系，并将这种关系量化为一个相似度分数。
- ▶ 对于单词 w_i, w_j 及其词向量 $\mathbf{v}_i, \mathbf{v}_j$ ，简单地使用余弦相似度作为词义相似性的度量：

$$\text{sim}(w_i, w_j) = \cos(\mathbf{v}_i, \mathbf{v}_j) = \frac{\mathbf{v}_i \mathbf{v}_j}{\|\mathbf{v}_i\| \|\mathbf{v}_j\|}$$

余弦相似度的取值范围为 $[-1, 1]$ ，值越接近 1 表示两个词向量越相似。

余弦相似度对向量的长度不敏感，仅关注向量的方向，因此适合用于衡量词向量的语义相似性。

单词分布式表示的评价与应用

词义相关性任务

- ▶ 词义相关性任务通过比较词向量计算的语义相似度与人工标注的相似度，来验证词向量是否能够准确捕捉单词之间的语义关系。
- ▶ 常用数据集：WordSim-353：包含 353 对英文单词，每对单词都有人工标注的相似度评分，评分范围为 [0,10]。广泛应用于词向量模型的评估。SimLex-999：包含 999 对英文单词，专注于语义相似性（而非相关性）。更适合评估词向量对语义关系的捕捉能力。
- ▶ 对于词向量模型的评测，通常使用以下步骤：

计算相似度：使用词向量模型计算数据集中每对单词的余弦相似度。

计算相关系数：将模型计算的相似度与人工标注的相似度进行比较，计算相关性指标。1) 斯皮尔曼相关系数 (Spearman Correlation)：衡量单调相关性。2) 皮尔逊相关系数 (Pearson Correlation)：衡量线性相关性。分析结果：相关系数越高，表明词向量模型对语义相关性的表达能力越强。

单词 1	单词 2	相似度
dirty	narrow	0.30
student	pupil	9.40
win	dominate	5.68
smart	dumb	0.60
attention	awareness	8.73
leave	enter	1.38

- ▶ 在应用中，对给定的单词 w ，可通过余弦相似度，在词表中检索意义最为接近的词语，即 $w^* = \arg \max \text{sim}(w, w')$ 。

单词分布式表示的评价与应用

类比任务回答： w_a 之于 w_b ，相当于 w_c 之于？

- ▶ 可以通过以下公式检索最恰当的类比词：

$$w^* = \arg \min_{w' \in V} \cos(v^*, v_c + v_b - v_a)$$

其中 v^*, v_a, v_b, v_c 分别是 w^*, w_a, w_b, w_c 对应的词向量。

在由 (man, woman) 词对确定的类比关系下，可以为单词 son 检索类比词 daughter，它们满足 man 之于 woman，相当于 son 之于 daughter 的类比关系。

句子分布式表示

► 句子分布式表示 (Sentence Distributed Representation)

句子分布式表示是自然语言处理 (NLP) 中的关键技术，主要用于句子级别的任务，如情感分析、文本推理、语义匹配等。与单词分布式表示不同，句子表示需要捕捉句子整体的语义信息，而不仅仅是单个词的语义。

核心目标：将句子映射到一个低维稠密的向量空间，使得语义相似的句子在向量空间中距离相近。为句子级别的下游任务提供有效的特征表示。

► 构建句子表示的挑战

单词语义的整合：句子表示需要融合句子中所有单词的语义信息。

词间关系的捕捉：句子表示需要考虑词与词之间的共现信息和语义关系，例如语法结构和上下文依赖。

句子间语义关系的建模：句子表示需要反映句子之间的隐含语义相似性以及其它语义关系（如逻辑关系、因果关系等）。

Skip-Thought 句子表示模型

- **Skip-Thought 模型** 是一种用于构建句子分布式表示的经典模型，其核心目标是建模句子与句子之间的上下文语义关系。该模型借鉴了 Skip-Gram 模型的思想，通过预测上下文句子来学习句子表示，从而捕捉句子之间的语义关联。

核心思想：给定一个句子，模型预测其前一个句子和后一个句子，以此作为监督信号。通过这种方式，模型能够学习到句子的上下文语义信息，从而生成有效的句子表示。


- **模型结构**：Skip-Thought 模型包括以下三个主要组件

编码器 (Encoder) 输入：当前句子 $S^i = w_1^i, \dots, w_N^i$ 。功能：将句子编码为一个固定维度的向量表示。常用实现：基于 RNN 的序列编码器。

前向解码器 (Forward Decoder) 输入：编码器生成的句子向量。功能：预测当前句子的后一个句子 S^{i+1} 。常用实现：基于 RNN 的序列解码器。

后向解码器 (Backward Decoder) 输入：编码器生成的句子向量。功能：预测当前句子的前一个句子 S^{i-1} 。

- **模型工作流程**：编码器将当前句子编码为向量表示。前向解码器基于句子向量生成后一个句子。后向解码器基于句子向量生成前一个句子。通过最小化生成句子与真实句子之间的差异，优化模型参数。



Skip-Thought 句子表示模型

- **编码器**：Skip-Thought 模型使用一个 GRU 网络作为编码器，将输入的句子 s^i 编码为一个固定维度的向量表示。编码器输入：句子 $S^i = w_1^i, \dots, w_N^i$ ，其中每个单词 w_t 被表示为独热向量（one-hot vector） x_t 。编码器输出：每个时间步 t 的隐藏状态 h_t ，最终隐藏状态 h_N 通常作为整个句子的向量表示。

$$\mathbf{h}_1^i, \dots, \mathbf{h}_N^i = \text{Encoder}(\mathbf{x}_1^i, \dots, \mathbf{x}_N^i), t \in [1, T]$$

其中 $\mathbf{x}_1^i, \dots, \mathbf{x}_N^i$ 是单词 $w_1^i, \dots, w_N^i$ 的独热表示。

- GRU 单元通过两个门控机制（更新门和重置门）来控制信息的流动，通过引入门控机制，能够更好地捕捉长距离依赖关系，其计算公式如下：

$$\mathbf{r}_t = \sigma(\mathbf{W}_t \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1})$$

重置门 $\mathbf{r}_t$ 决定是否忽略前一时刻的隐藏状态 $\mathbf{h}_{t-1}$

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1})$$

更新门 $\mathbf{z}_t$ 决定当前时刻的隐藏状态 $\mathbf{h}_t$ 中保留多少前一时刻的隐藏状态 $\mathbf{h}_{t-1}$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{r}_t \odot (\mathbf{U}_h \mathbf{h}_{t-1}))$$

候选隐藏状态 $\tilde{\mathbf{h}}_t$ 是当前时刻的建议更新状态

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

最终隐藏状态 $\mathbf{h}_t$ 是前一时刻隐藏状态 $\mathbf{h}_{t-1}$ 和候选隐藏状态 $\tilde{\mathbf{h}}_t$ 的加权和

⊙ 表示逐元素乘积。更新门和重置门的值在 0 到 1 之间。

Skip-Thought 句子表示模型

► 解码器：

Skip-Thought 模型包含两个解码器，分别用于生成当前句子的前一个句子和后一个句子。解码器的核心思想是通过编码器生成的句子向量 $\mathbf{h}_i$ 来指导上下文句子的生成。为了增强解码器的表达能力，模型引入了矩阵 $\mathbf{C}$ ，用于对更新门、重置门和隐藏状态的计算进行偏置更新。

$$\mathbf{r}_t = \sigma(\mathbf{W}_t \mathbf{y}_{t-1} + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{C}_r \mathbf{h}^i)$$

$\mathbf{C}_r$ 是用于句子向量 $\mathbf{h}_i$ 的权重矩阵。

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{y}_{t-1} + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{C}_z \mathbf{h}^i)$$

$\mathbf{C}_z$ 是用于句子向量 $\mathbf{h}_i$ 的权重矩阵。

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{y}_{t-1} + \mathbf{r}_t \odot (\mathbf{U}_h \mathbf{h}_{t-1}) + \mathbf{C}_h \mathbf{h}^i)$$

$\mathbf{C}_h$ 是用于句子向量 $\mathbf{h}_i$ 的权重矩阵。

$$\mathbf{h}_t^{i+1} = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

- 每个解码器都使用不同的参数。
- 词汇矩阵 $\mathbf{V}$ 将隐藏状态 $\mathbf{h}_t$ 映射到单词分布 $p(w_t | w_{<t}, \mathbf{h}_t) = \text{softmax}(\mathbf{V} \mathbf{h}_t)$
以解码 s^{i+1} 句子的解码器为例，给定输出表示 $\mathbf{h}_t^{i+1}$ ，对输出词语 w_t^{i+1} 的预测概率满足：

$$P(w_t^{i+1} | w_{<t}^{i+1}, \mathbf{h}^i) \propto \exp(\mathbf{v}_{w_t^{i+1}} \mathbf{h}_t^{i+1})$$

其中 $\mathbf{v}_{w_t^{i+1}}$ 是单词 w_t^{i+1} 的词向量， $\mathbf{h}_t^{i+1}$ 是负责编码 s^{i+1} 的编码器在 t 时刻的输出。

Skip-Thought 句子表示模型

- **目标函数**：Skip-Thought 模型的训练目标是最大化上下文句子的预测概率。

给定三元组 (s^{i-1}, s^i, s^{i+1}) ，模型通过优化以下目标函数来学习句子表示：

$$\mathcal{L} = \sum_t \log P(w_t^{i+1} | w_{<t}^{i+1}, \mathbf{h}^i) + \sum_t \log P(w_t^{i-1} | w_{<t}^{i-1}, \mathbf{h}^i)$$

$P(w_t^{i+1} | w_{<t}^{i+1}, \mathbf{h}^i)$ 表示在给定句子向量和已生成的上文的条件下，生成后一个句子 S^{i+1} 的第 t 个单词的概率。

$P(w_t^{i-1} | w_{<t}^{i-1}, \mathbf{h}^i)$ 表示在给定句子向量和已生成的上文的条件下，生成前一个句子 S^{i-1} 的第 t 个单词的概率。

- 模型训练完成后，使用最终得到的模型编码器作为句子的表示模型。这个编码器可以为每个句子生成定长向量，且这个向量具有反映句子之间上下文相关关系的性质。

Sent2Vec 句子表示模型

► Sent2Vec 模型

是一种用于学习句子分布式表示的模型，其核心思想是通过捕捉句子中所有单词和 n 元语法 (n -gram) 单元的全局信息，来生成句子的向量表示。Sent2Vec 模型扩展了 CBoW 模型的学习机制，将上下文窗口从局部扩展到整个句子，并引入词级别的 n 元语法特征，从而更好地捕捉句子的语义和单词顺序。

核心目标：通过句子中所有单词和 n 元语法单元的全局信息，生成句子的向量表示。提升模型对句子中单词顺序和上下文语义的捕捉能力。

► Sent2Vec 模型的结构包括以下关键组件：

词表与嵌入矩阵：词表包含所有单词和 n 元语法单元。嵌入矩阵为每个单词和 n 元语法单元分配一个向量表示。

句子表示计算： V_s 是句子中所有单词和 n 元语法单元向量的均值：

$$\mathbf{v}_s = \frac{1}{|R(s)|} \sum_{w \in R(s)} \mathbf{v}_w$$

$R(s)$ 是句子中全部单词及全部 n 元语法单元集合， $\mathbf{v}_w$ 是 $R(s)$ 的元素 w 的上下文词表示， w 可能是一个单词或一个 n 元语法单元。

► 因此，Sent2Vec 词表和对应的嵌入矩阵同时包含单词和 n 元语法单元。

Sent2Vec 句子表示模型

- **Sent2Vec 模型的训练目标**与 CBoW 模型类似，旨在通过优化中心词与上下文的相似性度量，对文本向量进行自监督训练。具体来说，模型的目标是最大化中心词表示与其上下文表示的相似度，同时采用负采样技术降低计算成本。

核心思想：对于句子 S 中的每个单词 w ，模型学习一个中心词表示 $\mathbf{u}_w$ 和一个上下文表示 $\mathbf{v}_{s \setminus \{w\}}$ 。通过最大化中心词 w 与其上下文 $s \setminus w$ 的相似度，使模型能够捕捉句子中单词的语义关系。

- **为了降低计算成本，Sent2Vec 模型采用了负采样技术：**

构建负采样词集合：对于句子 S 中的每个单词 w ，从词表 V 中采样一组负采样词 $N(w)$ 。负采样词 $N(w)$ 不包括中心词 w 本身。

采样概率：单词 w 的采样概率 $q_n(w)$ 与其词频 f_w 的平方根成正比：

$$q_n(w) = \frac{\sqrt{f_w}}{\sum_{w \in V} \sqrt{f_w}}$$

使得高频词更有可能被选为负采样词，而低频词被选中的概率较低。

- **Sent2Vec 模型的损失函数**由两部分组成：

正样本损失：衡量中心词 w 与其上下文 $s \setminus w$ 的相似度。

负样本损失：衡量中心词 w 与负采样词 $N(w)$ 的不相似度。

$$\mathcal{L}(w, s) = \ell(\mathbf{u}_w^\top \mathbf{v}_{s \setminus \{w\}}) + \sum_{w' \in N(w)} \ell(-\mathbf{u}_w^\top \mathbf{v}_{s \setminus \{w\}})$$

其中， $\ell(x) = \log(1 + e^{-x})$ 是 Logistic 函数， $\mathbf{u}_w$ 是单词 w 的中心词表示， $\mathbf{v}_{s \setminus \{w\}}$ 是单词 w 上下文的表示， w' 是负采样词，来自负采样词集 $N(w)$ 。

Sent2Vec 句子表示模型

► 下采样技术

在训练 Sent2Vec 模型时，为了避免模型对高频词的过度倾向性，采用了下采样（Subsampling）技术。具体来说，对于每个训练样本 (w,s) ，以概率 $1 - q_p(w)$ 丢弃该样本，其中 $q_p(w)$ 是保留样本的概率，计算公式如下：

$$q_p(w) = \min\{1, \sqrt{t/f_w} + t/f_w\}$$

f_w 是单词 w 在语料库中的词频。 t 是一个超参数。

下采样的作用：降低高频词在训练数据中的比例，使模型对单词词频脱敏。提升低频词的训练机会，增强模型对低频词的表示能力。

► 在整个语料库 D 上，Sent2Vec 模型的损失函数定义为

$$\mathcal{L}(D) = \sum_{s \in D} \sum_{w \in s} k(w,s) \mathcal{L}(w,s)$$

其中 $k(w,s) \in \{0,1\}$ 是一个伯努利随机变量，其取值为 1 的概率为 $q_p(w)$ ，表示样本 (w,s) 是否被保留。

篇章分布式表示

► 文档级别特征学习

在自然语言处理（NLP）和信息检索（IR）领域，部分任务需要模型学习并表示文档级别的特征。这些任务包括文档检索、文档去重、文档级情感分析、主题识别等。与一般的 NLP 任务不同，文档级别特征学习更关注文档的整体语义信息，如主题、关键词等，而不需要精确捕捉细粒度的词句信息。

核心目标：学习文档的全局语义表示，捕捉文档的主题和关键词。生成文档的向量表示，用于下游任务。

- 文档级别特征学习在以下任务中具有重要应用：文档检索（Document Retrieval）、文档去重（Document Deduplication）、文档级情感分析（Document-level Sentiment Analysis）、主题识别（Topic Identification）。

► 文档表示方法

词袋模型（Bag of Words, BoW） 将文档表示为所有单词的频次向量。

TF-IDF（Term Frequency-Inverse Document Frequency） 在 BoW 的基础上，考虑单词在文档中的重要性。

主题模型（Topic Models） 使用概率模型（如 LDA）学习文档的主题分布。

深度学习模型（Deep Learning Models） 使用神经网络（如 Doc2Vec、Transformer）生成文档的向量表示。

词频-逆文档频率篇章表示方法

► 词频-逆文档频率 (TF-IDF)

TF-IDF 是一种用于评估词在特定文档中重要程度的统计方法。其基本假设是：

词频 (TF)：一个词在文档中出现的频率越高，说明该词与文档的主题相关性越强。

逆文档频率 (IDF)：一个词在整个语料库中出现的频率越高，说明该词的区分性越差，重要性越低。

如果一个词在特定文档的出现频率高，则说明这个词与该文档的主题具有比较强的相关关系，因此该词相对于该文档的重要性应该较高。但是，如果一个词语在整个文档集合很多文档上都出现了，那么说明该词是常见词语，其区分性不好，因此其重要程度应该较低。

词频-逆文档频率篇章表示方法

- 词汇频率 (Term Frequency, TF) 主要用来衡量词汇在特定文档中的重要程度，建模文档中的关键词。
对于文档 d 中的词项 t ， $TF(t,d)$ 表示词项在文档中的出现频率，具体计算方法

$$TF(t, d) = \frac{COUNT(t, d)}{\sum_{t' \in V} COUNT(t', d)}$$

$COUNT(t,d)$ 是文档 d 中的词项 t 的出现次数，分母的和式表示文档中的总词数。

词频-逆文档频率篇章表示方法

- ▶ 逆文档频率 (IDF, Inverse Document Frequency) 用于衡量词汇在语料库中的常见性，用于去除常见词对文档关键词建模的影响。

常见词：如果一个词在语料库中出现的频率很高，说明该词是常见词，对文档主题的区别性较差，因此其重要性较低。

罕见词：如果一个词在语料库中出现的频率很低，说明该词是罕见词，可能对文档主题的区别性较强，因此其重要性较高。

- ▶ 对于词项 t 的逆向文件频率 $IDF(t)$ ，计算包含该词项的文档占全体文档的比例， $IDF(t)$ 与之呈对数反相关关系：

$$IDF(t) = \log \frac{|\mathcal{D}|}{\sum_{d \in \mathcal{D}} \mathbf{1}^{t \in d}}$$

$|\mathcal{D}|$ 表示文档总数，分母的和式表示包含词项 t 的文档数。

$\mathbf{1}^{t \in d}$ 是指示函数，当词项 t 出现在文档 d 中时取值为 1，否则为 0。

- ▶ 平滑处理：在计算未登录词项的逆文档频率时，为了防止分母为零，通常采用平滑方法，例如在分母上 $+1$ 。

词频-逆文档频率篇章表示方法

- **TF-IDF**：词项 t 在文档 d 中的 TF-IDF 表示为词汇频率和逆文档频率的乘积：

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

- **文档的表示向量**：由词表中每个词项在文档中的 TF-IDF 值构成，每个维度对应一个词项。这种表示向量的特点是对关键词信息的反映。

对于每个文档，具有较高的 TF-IDF 的词项是在整个文档集合中出现频率较低，但在本文档中出现频率较高的词项。

因此，基于 TF-IDF 的表示向量筛选文档中的高频词，过滤掉其中的常见词，保留反映文档主题、主要内容的关键词。

在信息检索系统中，对于用户输入的检索关键词，可以容易地通过比较文档中词项的 TF-IDF，来返回与检索词相关性高的文档。

fastText 篇章表示模型

- **fastText** 文本表示模型是由 Facebook AI Research 于 2016 年提出的一种用于生成句子和篇章级别向量表示的方法。与 fastText 单词表示模型类似，fastText 文本表示模型基于 n-gram 表示单词，并将其聚合为篇章级别的向量表示。

该模型在文本分类、情感分析、语义相似度计算等任务中表现出色，并以其训练速度快和适用于小型数据集的特点而广受欢迎。

- **模型结构**

fastText 文本表示模型的核心思想是通过 n-gram 特征捕捉单词的局部信息，并通过平均池化（Averaging Pooling）生成篇章级别的向量表示。具体步骤如下：

- 1) 文本分割：将输入文本分割为单词序列。
 - 2) 单词表示：将每个单词表示为其 n-gram 特征的平均值。例如，对于单词“apple”，其 3-gram 特征包括“app”、“ppl”、“ple”。通过 n-gram 特征，模型能够捕捉单词的形态学信息和局部上下文。
 - 3) 篇章表示：将所有单词的向量表示取平均，得到整个篇章的向量表示。通过平均池化，模型不仅考虑了每个单词的信息，还考虑了单词之间的顺序和相互作用。
- **模型特点**：通过 n-gram 特征，模型能够捕捉单词的形态学信息和局部上下文，提升表示能力。通过平均池化，模型能够生成固定长度的篇章向量表示，适用于各种 NLP 任务。训练速度快。适用于小型数据集。

fastText 篇章表示模型

- ▶ fastText 在构建词级别表示时，引入了字符 n-gram 特征，以更好地表示罕见词和未登录词。与传统的词向量模型不同，fastText 不仅为整个单词生成向量表示，还通过字符 n-gram 捕捉单词的形态学信息。这种设计使得 fastText 在处理罕见词、未登录词以及形态丰富的语言时表现优异。
- ▶ 字符 n-gram 特征是指从单词中提取的固定长度的字符子序列。fastText 通过以下步骤生成字符 n-gram 特征：

添加边界符号：在单词的开头和末尾分别添加特殊字符“<”和“>”，以区分前缀和后缀。例如，单词“where”变为“<where>”。

滑动窗口提取子词：通过滑动窗口的方式，提取单词中所有长度为 n 的字符子序列。例如，对于单词“where”和 n=3，提取的子词包括：“<wh”、“<whe”、“<her”、“<ere”、“<re>”。

- ▶ 基于对训练语料的统计，fastText 为所有长度不小于 n 的子词建立词表和对应的子词表示矩阵。具体步骤如下：

子词提取：对训练语料中的所有单词，提取其所有长度在 n 到最大长度之间的子词。例如，对于单词“where”和 n=3，提取的子词包括：“<wh”、“<whe”、“<her”、“<ere”、“<re>”以及单词本身“where”。

词表构建：将所有子词加入词表，并为每个子词分配一个向量表示。

词表示构建：对于每个单词，将其所有子词的向量表示取平均，得到该单词的最终向量表示。

fastText 篇章表示模型

- 词向量生成：fastText 直接使用子词向量的和作为对应单词的词向量：

$$\mathbf{v}_w = \sum_{s \in V_s(w)} \mathbf{z}_s$$

$\mathbf{v}_w$ 是单词 w 的词向量， $V_s(w)$ 是子词词表中 w 的全体子词， $\mathbf{z}_s$ 是子词 s 的表示向量。

示例：单词：“where” 子

词：“<wh”、“whe”、“her”、“ere”、“re>” 词向量：

$$\mathbf{v}_{\text{where}} = \mathbf{z}_{\text{<wh}} + \mathbf{z}_{\text{whe}} + \mathbf{z}_{\text{her}} + \mathbf{z}_{\text{ere}} + \mathbf{z}_{\text{re}}$$


- fastText 通常使用 Skip-Gram 模型的训练方式得到预训练的词级别表示。在预训练中，fastText 采用层次 Softmax 方法提升训练效率。

fastText 篇章表示模型

- 在构建文档表示时，fastText 首先计算每个词的表示向量，再将其进行平均，得到句表示向量。
- 将 fastText 句向量用于文本分类时，通常以对数概率作为优化目标：

$$\mathcal{L}(x = w_1, \dots, w_N, y) = -y \cdot \log(\text{softmax}(\mathbf{W} \cdot \mathbf{v})), \quad \mathbf{v} = \frac{1}{N} \sum_{i=1}^N \mathbf{v}_i$$

$\mathbf{v}$ 是文档的表示向量， $\mathbf{W}$ 是可训练的线性映射层，将样本表示映射为预测分布。



本章小结

第四章 语义分析

4.1 语义学概述

4.2 语义表示

4.3 分布式表示