

自然语言处理

王刚

统计与数据科学学院

2026 年春季学期

目录

第四章语义分析 (II)

4.4 词义消歧

4.5 语义角色标注

第四章语义分析 (II)

4.4 词义消歧

词义消歧

- ▶ **词义消歧 (Word Sense Disambiguation, WSD)** 是指确定一个多义词在给定的上下文中的具体含义。由于自然语言中存在大量的一词多义现象，词义消歧是自然语言处理中的一项核心任务，旨在帮助计算机更准确地理解文本。根据词汇语义学相关介绍，我们可以知道语言中一词多义现象十分普遍。例如：英语中的“bank”可以表示“银行”或“河岸”，而中文中的“水分”既可以表示物体内所含的水，也可以表示某些情况中夹杂的不真实的成分。
(1) 葡萄糖液可用来供给水分。(2) 这个报导有些水分，需要核实。
- ▶ **词义消歧任务核心**是根据词语所处的句子或篇章，结合上下文信息，确定该词在当前环境下的确切含义。这一过程通常包括以下步骤：
候选词义提取：从词典或知识库（如 WordNet）中获取目标词的所有可能含义。
上下文分析：利用上下文信息（如句子中的其他词语、句法结构等）对候选词义进行筛选。
消歧决策：通过规则、统计方法或深度学习模型选择最合适的词义。

基于目标词上下文的词义消歧方法

- ▶ 对于待消歧的目标词，词义消歧方法通常采用有监督分类方法：将词语的每个词义项作为候选词义，通过估计待消歧词义的概率分布从而完成目标词的词义消歧。
- ▶ 基于目标词上下文的词义消歧方法：其核心思想是利用目标词周围的上下文信息，通过机器学习模型预测目标词在给定上下文中的最可能词义。这种方法将词义消歧任务形式化为一个分类问题，其中每个候选词义作为一个类别，模型的目标是预测目标词属于每个类别的条件概率。

方法流程：1/候选词义提取：从词典或知识库（如 WordNet）中获取目标词的所有可能词义。2/特征提取：从目标词的上下文中提取特征，例如：上下文词：目标词前后若干个词语。词性信息：上下文词的词性标注。句法信息：目标词在句法树中的位置和关系。语义信息：上下文词的词嵌入表示。3/模型训练：使用标注数据训练分类模型，学习从上下文特征到词义的映射关系。4/词义预测：对于新的句子，提取目标词的上下文特征，输入训练好的模型，预测目标词的最可能词义。

- ▶ 自然语言处理中常用的统计机器学习方法和深度学习算法，均可用于构建基于目标词上下文的词义消歧方法。

基于朴素贝叶斯分类器的消歧方法

- ▶ 基于朴素贝叶斯分类器的词义消歧方法，是一种经典的统计学习方法。其核心思想是利用贝叶斯定理，通过计算目标词在给定上下文中的条件概率，选择最可能的词义。
 - ▶ 使用 w 表示待消歧的目标词， c 表示目标词所处的上下文， $\{s_i\}_{i=1}^N$ 为目标词的候选词义集合。由于待消解的目标词词义仅与其所处的上下文语境有关，因此可以[通过估计条件概率 \$P\(s_i|c\)\$ 来预测目标词 \$w\$ 的词义](#)。
- 给定句子 $c = \{w_k\}_{k=1}^K$ ，可以将条件概率 $P(s_i|c)$ 通过贝叶斯公式得：

$$P(s_i|c) = \frac{P(c|s_i)P(s_i)}{P(c)}$$

$P(s_i)$ 是词义 s_i 的先验概率，通常通过词义在语料库中的频率估计。
 $P(c|s_i)$ 是上下文 c 在词义 s_i 下的条件概率。 $P(c)$ 是上下文的边缘概率，由于 $P(c)$ 对于所有词义相同，因此在比较时可以忽略。我们可以简化为：

$$P(s_i|c) \propto P(c|s_i)P(s_i)$$

最终选择使 $P(s_i|c)$ 最大的词义作为目标词的预测结果。 $P(c|s_i)$ 的计算方式与语言模型类似。

基于朴素贝叶斯分类器的消歧方法

- ▶ 随着上下文长度的增加，上下文 c 的数量指数级增长，该概率值难以估计。

因此，需要引入单词独立假设，近似地将概率估算为上下文中每个单词的独立出现概率：

$$P(c|s_i) = \prod_{k=1}^K P(w_k|s_i)$$

其中 w_k 是上下文中的第 k 个词语， K 是上下文长度。

$P(w_k|s_i)$ 表示在词义 s_i 下，词语 w_k 出现的概率，通常通过最大似然估计计算。

基于朴素贝叶斯分类器的消歧方法

- ▶ 通过上述公式，词义分类可以根据如下公式选择最大条件概率的词义：

$$\hat{s} = \arg \max_{s_i} P(s_i|c) = \arg \max_{s_i} P(s_i) \prod_{k=1}^K P(w_k|s_i)$$

$P(s_i)$ 和 $P(w_k|s_i)$ 可以通过训练语料利用最大似然估计得到：

$$P(w_k|s_i) = \frac{\text{COUNT}(w_k, s_i)}{\text{COUNT}(s_i)}$$

$$P(s_i) = \frac{\text{COUNT}(s_i)}{\text{COUNT}(w)}$$

$\text{COUNT}(w_k, s_i)$ 是训练语料中目标词 w 以语义 s_i 在上下文中出现的次数； $\text{COUNT}(s_i)$ 是训练语料中语义 s_i 出现的总次数； $\text{COUNT}(w)$ 是训练语料中目标词 w 出现的总次数。

- ▶ 优点：简单高效，易于实现。在小规模数据集上表现良好。
- ▶ 缺点：独立性假设过于强，忽略了上下文词语之间的依赖关系。对于低频词义或罕见上下文，概率估计可能不准确。

基于上下文向量表示的消歧方法


- ▶ 在分布式表示中介绍了句子和短语分布式向量表示算法，可以看到深度神经网络算法可以很好地对句子和短语的语义进行表示。

基于上下文向量表示的词义消歧方法，利用深度神经网络对目标词上下文的语义进行分布式表示，并通过计算上下文向量与候选词义向量的相似度，选择最可能的词义。这种方法的核心是将词义消歧任务形式化为一个相似度学习问题，通过捕捉上下文与词义之间的语义关系，实现更准确的消歧。

- ▶ 方法流程：1/上下文向量表示：使用深度神经网络（如 LSTM、Transformer）对目标词的上下文进行编码，生成上下文向量表示。上下文向量能够捕捉句子或短语的全局语义信息。2/词义向量表示：每个候选词义 s_i 通过预训练的词嵌入（如 Word2Vec、GloVe）或上下文感知的词向量（如 BERT）表示。词义向量可以来自词典（如 WordNet）或通过大规模语料库预训练得到。3/相似度计算：计算上下文向量与每个候选词义向量的相似度，常用的相似度度量包括余弦相似度或点积。4/词义选择：选择与上下文向量相似度最高的词义作为目标词的预测结果。
- ▶ 基于上下文向量表示的最近邻方法将词义消歧任务形式化为词义表示和上下文表示的相似度学习问题。

基于上下文向量表示的消歧方法

- 基于上下文向量表示的最近邻方法，是一种利用上下文语义信息进行词义消歧的技术。其核心思想是通过学习目标词在训练集中的上下文表示和候选词义表示，构建一个相似度计算模型。在应用时，通过比较目标词上下文表示与候选词义表示的相似度，选择最可能的词义。对于未在训练集中出现的词义，可以通过语义扩展（如使用 WordNet）确定其表示。



基于上下文向量表示的消歧方法

在词义编码部分

- ▶ 核心思想：在基于上下文向量表示的词义消歧方法中，词义编码是一个关键步骤。其目标是为每个候选词义生成一个高质量的向量表示，以便与目标词的上下文向量进行比较。具体来说，
 - 1 首先，考虑在词义消歧语料库中存在标注的语义。对于每一个标注词义，在训练集中抽取全体包含该词义标注的样本。
 - 2 随后，通过预训练上下文表示模型，计算词义对应的目标词在样本上下文中的表示。
 - 3 最后，以目标词表示的平均值作为词义的代表。

基于上下文向量表示的消歧方法

- 具体地，对于词义 s ，若该词义在词义消歧语料库出现过，则根据如下公式计算该词义表示 v ：

$$v_0, v_1, \dots, v_w, \dots, v_n = \text{Encoder}(c = c_0, c_1, \dots, w, \dots, c_n)$$

$$v = \frac{1}{|C(s)|} \sum_{c \in C(s)} v_w$$

其中， v_w 是目标词 w 在上下文 c 中的表示， v 是词义 s 的上下文表示。

$C(s)$ 为全体标记词义为 s 的样本集合，Encoder 代表使用预训练语言模型初始化的编码器，如 ELMo、BERT 等。

基于上下文向量表示的消歧方法

- ▶ 针对未在词义消歧语料库中出现的词义 在词义消歧任务中，可能会遇到未在词义消歧语料库中出现的词义（未登录词义）。针对这种情况，可以采用 LMMS (Language Modelling Makes Sense) 方法¹，利用 WordNet 中的语义关系信息（如同义词、上位词、词性标注等），找到与目标词义相似或相关的词义，并以这些词义表示的平均值作为未登录词义表示。
- ▶ 以同义词关系为例，对于待确定表示的词义 s ，记 $S(s)$ 为 s 的同义语义集合。若 $S(s)$ 不是空集， s 的语义表示为 $S(s)$ 中同义语义的平均表示：

$$v = \frac{1}{|S(s)|} \sum_{s \in S(s)} v_s, \text{ if } |S(s)| > 0$$

¹Language modelling makes sense: Propagating representations through WordNet for full-coverage word sense disambiguation

基于上下文向量表示的消歧方法

- ▶ 当同义语义缺失时，可依次使用相同上位的语义或相同词性的语义作为近义语义集合，利用相似的方式计算目标语义的表示，具体计算公式如下所示：

$$v = \frac{1}{|H(s)|} \sum_{s \in H(s)} v_s, \text{ if } |H(s)| > 0$$

$$v = \frac{1}{|L(s)|} \sum_{s \in L(s)} v_s, \text{ if } |L(s)| > 0$$

$H(s)$ 为 s 的同上位语义集合，包含与 s 属于同类概念的语义。

$L(s)$ 为 s 的同词性语义集合，包含与 s 词性相同的全体语义。
在结合语义关系之后，可以全面覆盖 WordNet 中的词义，从而解决候选词义未在训练集出现的问题。

基于上下文向量表示的消歧方法

- 在构建了所有词义的向量表示后，对于每一条输入的待进行词义消歧的样本，首先基于语言模型计算目标词的上下文表示，在此基础上，**计算上下文表示与全体候选词义表示的点积相似度**，选择相似度最大的语义做为分类结果，具体计算公式如下所示：

$$\hat{s} = \arg \max_s (v_w \cdot v(s))$$

v_w 为目标词的上下文表示，与词义表示映射到相同维度。
 $v(s)$ 为候选词义 s 的表示。

基于上下文向量表示的消歧方法

► 优点：

1. 可以很好地对句子和短语的语义进行表示，能够捕捉上下文中的语义关系，从而更好地进行词义消歧。
2. 通过学习上下文的分布式表示，可以对不同长度和复杂度的上下文进行建模，并且不需要手工提取特征。
3. 对于未知词义，可以通过上下文向量的相似度和词义之间的语义关系来进行词义推断。

► 缺点：

1. 上下文向量表示的效果受到训练语料的质量和数量的影响，需要大量的高质量训练数据才能得到较好的效果。
2. 对于某些具有多义的词汇，上下文向量表示的效果可能较差，因为不同的词义在上下文中的语义关系可能较为复杂，难以准确捕捉。
3. 对于某些特定的领域或专业术语，由于缺乏大规模的训练语料，上下文向量表示的效果可能较差。

基于词义释义匹配的词义消歧方法

- 以知网 (HowNet)、WordNet 等为代表的词汇知识资源中不仅包含了词义之间的关系，还包含了词义的解释信息。

例如：

WordNet 3.1 中对“table”给出了如下词义解释：

table¹: a set of data arranged in rows and columns.

table²: a piece of furniture having a smooth flat top that is usually supported by one or more vertical legs.

table³: a piece of furniture with tableware for a meal laid out on it.

table⁴: flat tableland with steep edges.

table⁵: a company of people assembled at a table for a meal or game.

table⁶: food or meals in general.

基于词义释义匹配的词义消歧方法

- ▶ 这些释义与目标词上下文之间存在着非常强的联系。比如 table¹ 所对应的“表格”含义，其上下文更多的对应的设计、制作、数据等词汇。而 table² 所对应的“桌子”含义，其上下文更多的对应的椅子、沙发等词汇。


因此，也可以将词义消歧问题转化为目标词上下文和词义释义之间的语义匹配问题。

- ▶ 对于待消歧的目标词 w 所在的上下文句子 c ，以及候选词义 s ，构建相似度度量函数，建模目标词上下文和候选词义的匹配度。在应用时，根据目标词和每个候选语义的相似度得分，来确定目标词义的预测分布 $\phi(w|c, s)$ 。
- ▶ 优点：能够利用词义释义的语义信息，提升消歧的准确性。适用于多义词在不同语境下的动态语义匹配。
- ▶ 挑战：需要高质量的释义数据，释义的准确性和覆盖范围直接影响消歧性能。对于复杂或抽象的释义，语义匹配可能不够准确。

基于特征式匹配的消歧方法

BEM (Bi-Encoder Model) 模型²通过分布式向量表示匹配方式学习目标词上下文和词义释义的相关性。

- ▶ 主要包含上下文编码器和词义编码器两个组成部分。上下文编码器 T_c 对输入的目标词及其上下文进行编码，计算目标词上下文的分布式表示。词义编码器 T_g 对输入的词义释义文本进行编码，将输入词义和上下文表示在同一表示空间内。通过建立上下文语义表示和候选词义表示的相似度计算模型，来完成词义消歧任务。



²Moving down the long tail of word sense disambiguation with gloss-informed biencoders.

基于特征式匹配的消歧方法

- BEM 模型结构的上下文编码器 T_c 和词义编码器 T_g 都采用基于 BERT 的架构。

针对目标词上下文表示的计算，使用 w 表示待消歧的目标词， $c = c_0, c_1, \dots, w, \dots, c_n$ 表示目标词所处的上下文，上下文编码器 T_c 将序列中的每一个单词构建对应的上下文表示，并取目标词位置的输出为目标词的上下文表示，具体计算：

$$V_{cls}, V_0, V_1, \dots, V_w, \dots, V_n, V_{sep} = T_c([CLS], c_0, c_1, \dots, w, \dots, c_n, [SEP])$$

v_w 是目标词 w 在句子中的上下文表示。

对于分解成多个标识位的单词，采用每个标识位输出的平均值作为该单词的表示。

基于特征式匹配的消歧方法

- ▶ 分别针对候选词义表示的计算，候选词义 s 的词义释义为 $g_s = g_0, g_1, \dots, g_m$ ，在词义释义序列的首尾分别添加 [CLS] 及 [SEP] 标识，输入词义编码器 T_g ，取 [CLS] 位置的输出作为词义表示。

计算过程如下所示：

$$v_{\text{cls}}^g, v_0^g, v_1^g, \dots, v_m^g, v_{\text{sep}}^g = T_g([\text{CLS}], g_0, g_1, \dots, g_m, [\text{SEP}])$$

其中，记 $v_s = v_{\text{cls}}^g$ 为候选词义 s 的表示。

基于特征式匹配的消歧方法

- ▶ 上下文 c 中待消歧的目标词 w ，以及候选词义 s ，它们的相似度：

$$\phi(w|c, s) = v_w \cdot v_s$$

v_w 是目标词的表示向量， v_s 是词义 s 的表示向量。

- ▶ 在模型训练过程中，对于待消歧的目标词 w ，取该目标词在句子中的表示与全体候选词义的表示进行相似度计算，以相似度作为预测词义的对数概率分布，优化交叉熵损失函数：

$$\mathcal{L}(w; c) = -\phi(w|c, s^+) + \log \sum \exp(\phi(w|c, s^-))$$

s^+ 表示正确的候选词义， s^- 表示其余的候选词义。

- ▶ 在使用模型进行词义消歧时，与目标词具有最大相似度的词义将被预测为目标词的词义：

$$\hat{s} = \arg \max_s \phi(w|c, s)$$

基于交互式匹配的消歧方法

- ▶ GlossBERT³使用交互式匹配方法，通过对预训练模型 BERT 进行微调，实现上下文和词义释义的相似度计算。
交互式匹配的优点是只使用一个编码器进行匹配任务，大大减小了训练参数的规模。此外，交互式匹配可以充分利用词粒度的信息，参考输入的一对文本中的每个单词，进行充分的比较，从而实现更好的学习效果。
- ▶ GlossBERT 以BERT 双句分类的方式，将目标词所处的上下文句子和词义释义组合为输入，以是否匹配作为二分类标签，构造分类模型的微调样本，通过这些样本进行模型的微调。模型通过微调后，对于待消歧的目标词和候选词义，将目标词上下文和每一个候选词义组合成输入，通过模型计算语义匹配的置信度，根据置信度选取预测词义。

³GlossBERT: BERT for word sense disambiguation with gloss knowledge.

基于交互式匹配的消歧方法

► GlossBERT 微调样本的构造

原句: Your <i>research</i> stopped when a convenient assertion could be made .			
微调样本		标签	原始词义
[CLS] Your "research" ... [SEP] research: systematic investigation to ... [SEP]		Yes	research%1:04:00::
[CLS] Your "research" ... [SEP] research: a search for knowledge [SEP]		No	research%1:09:00::
[CLS] Your "research" ... [SEP] research: inquire into [SEP]		No	research%2:31:00::
[CLS] Your "research" ... [SEP] research: attempt to find out in a ... [SEP]		No	research%2:32:00::

- 该句以“research”作为消歧目标词时，目标词具有“research%1:04:00::”等 4 个词义。
- GlossBERT 按照输入模板将上下文句子和各个词义的释义分别拼接为 BERT 的输入形式，并在输入词序列中使用双引号 (")、冒号 (:) 等标点符号标出目标词的位置。
- 对于和目标词匹配的词义，GlossBERT 为微调样本赋予“Yes”类标签，否则赋予“No”类标签。

基于交互式匹配的消歧方法

- GlossBERT 微调样本的构造过程可以形式化地表示为：给定待消歧对目标词 w 及其所处的上下文句子 c ，对于 w 的每个候选词义 s_i 的释义 $g^i = g_0^i, \dots, g_m^i$ ，将句子和词义组合为如下的输入形式：

$$\begin{aligned} x &= f(w, c, s_i) \\ &= [\text{CLS}], c_0, c_1, \dots, ", w, ", \dots, c_n, [\text{SEP}], w, :, g_0^i, \dots, g_m^i, [\text{SEP}] \end{aligned}$$

[CLS] 和 [SEP] 是 BERT 使用的特殊标识，双引号 (")、冒号 (:) 是用来标出目标词位置的特殊标识。

- 如果目标词实际词义和词义释义匹配，则标注正例标签，否则标注负例标签。

因此，对于样本中每个待消歧的目标词，可以构造 N 个分类样本，其中 N 是目标词候选词义的个数。

基于交互式匹配的消歧方法

- ▶ BERT 分类层包含一个 BERT 编码层和一个线性分类层。
GlossBERT 根据训练集中每个样本的每个目标词所构造的分类样本，使用 BERT 编码层在 [CLS] 位置的输出作为分类判据，通过下游的线性分类层进行语义是否匹配的二元分类，分类层的计算：


$$\hat{y} = W \cdot \text{BERT}(x)[0]$$

W 为线性分类层的权重。采用交叉熵损失

$$\mathcal{L}(x, y) = \text{CrossEntropy}(\hat{y}, y)$$

当使用模型进行词义消歧时，将目标词构造对应的分类样本，输入模型对其进行预测。预测正例标签置信度最高的候选词义将被预测为目标词的词义：

$$\hat{s} = \arg \max_s P(\hat{y}(w, c, s) = 1)$$



基于词义知识增强预训练的消歧方法

- ▶ 基于预训练语言模型的方法在词义消歧任务中取得了不错的结果，为了使得预训练语言模型更好地适应词义消歧任务，可以通过设计词义级别的预训练任务，使得预训练模型融合知识库中所包含词义信息。然而，预训练模型需要大规模的有监督数据才能对模型参数进行有效训练。但是，目前缺乏标注了词义的大规模数据用于支持模型预训练。
- ▶ SenseBERT 模型，针对缺失语义监督数据问题，在 BERT 的预训练中添加了一个掩码词义预测任务作为辅助任务。SenseBERT 利用 WordNet 所包含的超义（Supersense）信息作为弱监督信号。

WordNet 将所有义项归纳为多个类别，这些类型称之为超义。例如，针对名词有 26 个超义，包括:BODY、LOCATION、PLANT 等。模型在预训练中不但预测掩码位置单词的词形，还预测缺失单词的超义。通过这种方式引入语义级别的监督信息，从而提升预训练模型在词义消歧任务上的效果。


基于词义知识增强预训练的消歧方法

- SenseBERT 在输入表示部分增加了语义嵌入模块，用来建构单词的词义信息。对于输入序列 $w_1, \dots, w_n$ ，每个标识位的输入表示 v_t 由词形嵌入 W_t 、词义嵌入 W_s 和位置嵌入 W_p 的和组成：

$$v_t = e_t(W_t + W_s) + p_t W_p$$

其中 e_t, p_t 是独热向量表示。SenseBERT 使用和 BERT 相同的 Transformer 编码层作为输入的编码结构：

$$o_1, \dots, o_n = \text{TransformerEncoder}(v_1, \dots, v_n)$$



基于词义知识增强预训练的消歧方法

- 在预训练任务方面，SenseBERT 包括掩码单词预测和掩码语义预测两个任务。通过与词嵌入、语义嵌入矩阵的比较，模型计算每一个掩码位置的单词预测分布和语义预测分布，并将其与实际标签比对。

$$P(\hat{w}_t | \text{context}) = \text{Softmax}(W_t^\top o_t)$$

$$P(\hat{s}_t | \text{context}) = \text{Softmax}(W_s^\top o_t)$$

在掩码单词预测任务上，模型约束单词预测分布和实际单词的交叉熵损失。

$$\mathcal{L}_{LM}(w_t) = -\log P(\hat{w}_t | \text{context})$$

基于词义知识增强预训练的消歧方法

- 在掩码语义预测的优化中，要求模型预测与超义集合中的语义吻合。根据 WordNet 统计实际单词全体词义所属的超义，单词 w 的超义集合记为 $A(w)$ ，即单词 w 的可取义项，作为掩码语义预测的弱监督信号。损失项 $\mathcal{L}_{\text{SLM}}^{\text{allowed}}(w_t)$ 优化模型预测掩码位置语义 $\hat{s}_t$ 属于可取义项集合 $A(w_t)$ 的概率。

$$\mathcal{L}_{\text{SLM}}^{\text{allowed}}(w_t) = - \sum_{s_t \in A(w_t)} \log P(\hat{s}_t | \text{context})$$

考虑到模型在 SLM(Semantic Language Model) 训练过程中可能会出现过拟合特定超义义项的情况，SenseBERT 引入了正则项 $\mathcal{L}_{\text{SLM}}^{\text{reg}}(w_t)$ 对 $A(w_t)$ 中每个超义义项的模型预测置信度的平均值进行约束，保证模型对全体可取义项都有一定的预测置信度，防止出现模型对单一义项预测置信度过高，预测分布退化的情况。

$$\mathcal{L}_{\text{SLM}}^{\text{reg}}(w_t) = - \sum_{s_t \in A(w_t)} \frac{1}{|A(w_t)|} \log P(\hat{s}_t | \text{context})$$

基于词义知识增强预训练的消歧方法

- **整体损失函数**：为掩码单词预测和掩码语义预测目标的加权和值。

$$\mathcal{L} = \sum_{w_t=[\text{MASK}]} \lambda_1 \mathcal{L}_{\text{LM}}(w_t) + \lambda_2 \mathcal{L}_{\text{SLM}}^{\text{allowed}}(w_t) + \lambda_3 \mathcal{L}_{\text{SLM}}^{\text{reg}}(w_t)$$

由于掩码词义预测只对被掩盖的全词有意义，SenseBERT 在掩码标识为子词时，只优化掩码单词预测损失，不训练掩码语义预测任务。

为了进一步增强对词义知识的学习，SenseBERT 在 BERT 的原始词表中增加了维基百科中的高频词，使掩码全词的比例更大，有助于学习低频词义。

词义消歧评价方法

- ▶ 词义消歧评测的主要指标通常采用机器学习算法评测常用指标，包括词义消歧的精确率 (Precision)，召回率 (Recall)，和 F 值 (F-Score) 得分。
- ▶ 在部分基于机器学习的方法中，也会使用精度和覆盖率 (Coverage) 作为词义消歧系统的评测指标。

$$\text{覆盖率} = \frac{\text{算法输出的全部标记个数}}{\text{测试集合中全部标记个数}} \times 100\%$$

词义消歧语料库

词义消歧义项分类标注语料库

- **义项分类语料库**针对目标词语，构建包含该目标词句子，并对句子中目标词所属的语义项进行标注。义项相同判断语料库则针对目标词给出两个包含该词语的句子，并依据在两个句子中目标词的词义是否相同给出分类标签。

词义消歧语料库

词义消歧义项分类标注语料库

- **SemCor**是基于 WordNet 词义进行标注的语料库。3.0 版本包含 352 个文档和 22 万余条手动语义注释，其原始语料从布朗语料库获取，经过筛选后，参考 WordNet 1.4 的词义清单进行词义标记。

例句：Kim _a got _b slowly _c up _b , the children _d were _e already _f on _g their _g feet _g .			
编号	范围	对应词	词义
a	Kim	Kim	org
b	got, up	get_up	get_up_4
c	slowly	slowly	slowly_1
d	children	child	child_1
e	were	be	be_3
f	already	already	already_1
g	on their feet	on_one's_feet	no_tag

图: SemCor 语料库的示例样本标注

在句中标出了开放域词汇，如“got...up”；包含多个词汇的表达，如“on their feet”；以及命名实体，如“Kim”以实体类型进行标注。

词义消歧语料库

词义消歧义项分类标注语料库

- **OMSTI** (One Million Sense-Tagged Instances) 是自动标注的语料库，也常用于词义消歧系统的训练。OMSTI 使用 WordNet 3.0 的词义进行注释，它是通过在大型英汉平行语料库 (MultiUN 语料库) 上使用基于对齐的词义消歧方法自动构建的。

OMSTI 中包含针对 22437 个单词，由 85 万句子组成的 113 万训练样例。虽然 OMSTI 是自动标注的，但其具有比 SemCor 更大的规模，且包含更丰富的歧义情况，很多工作的实验说明将 OMSTI 应用于词义消歧算法训练，可以有效提升算法效果。

词义消歧语料库

词义消歧义项分类标注语料库

- ▶ **WSDEval**是统一词义消歧基准评测框架，将不同时期构建的采用不同词义注释构建的评测基准语料统一使用 WordNet 3.0 词义进行注释。
- ▶ WSDEval 包含 5 个来自 SensEval 和 SemEval 的测试基准语料，具体如下：
 - ▶ SensEval-2 使用 WordNet 1.7 进行标注，包含 2282 个词的语义标注。
 - ▶ SensEval-3Task1 使用 WordNet1.7.1，包含来自社论，新闻和小说领域的 3 个文档，包含 1850 个词的语义标注。
 - ▶ SemEval-07 Task 17 使用 WordNet 2.1，包含 455 个词的语义标注。
 - ▶ SemEval-13 Task 12 使用 WordNet 3.0 的标注，包含来自多个领域的 13 个文档和名词上的 1644 个词的语义标注。
 - ▶ SemEval-15 Task 13 使用 WordNet 3.0 的标注，包含生物医学、数学/计算和社会问题题材的 4 个文档和 1022 个词的语义标注。

词义消歧语料库

词义消歧义项相同判断标注语料库

- WiC (Word in Context) 数据集是一个由专家标注的词义消歧数据集，每个样本对同一个目标词给出两个包含该词语的句子，并依据在两个句子中目标词的词义是否相同，给出 T 或 F 的分类标签。

语句对	标签
There is a lot of trash on the <i>bed</i> of the river I keep a glass of water next to my <i>bed</i> when I sleep	F
<i>Justify</i> the margins The end <i>justifies</i> the means	F
<i>Air</i> pollution Open a window and let in some <i>air</i>	T
The expanded <i>window</i> will give us time to catch the thieves You have a two-hour <i>window</i> of clear weather to finish working on the lawn	T

- 在这些句子中，只取具有多种含义、并出现在不同句子中的名词和动词作为目标词。为了筛选高质量的验证集和测试集，标注者要求包含相同目标词的样本不超过 3 个，且样本之间没有重复的上下文句子。在此基础上，尽量保证类别平衡、以及目标词的多样性。

词义消歧语料库

词义消歧义项相同判断标注语料库

► WiC (Word in Context) 数据集

在此基础上，尽量保证类别平衡、以及目标词的多样性。

数据划分	样本个数	名词比例	动词比例	目标词数
训练集	5,428	49%	51%	1,256
验证集	638	62%	38%	599
测试集	1,400	59%	41%	1,184

图: WiC 数据集的统计数据，包括样本个数、目标词个数和目标词中名词、动词的占比

- 与 SemEval 和 SensEval 评测基准相比，WiC 不依赖于 WordNet 等外部数据库的词义信息，而且作为分类数据集，具有较为简单的任务形式。简洁的任务形式促进了模型的灵活性和丰富性，而不依赖于外部信息的特质使 WiC 支持低资源场景下的评测，而不强制假设完整训练数据的可用性。

词义消歧语料库

词义消歧义项相同判断标注语料库

- **WiC-TSV** (Word in Context - Target Sense Verification) :
在 WiC 的基础上，针对词义消歧系统对专用领域词义的建模，对 WiC 的语料筛选和任务形式进行了改进，形成了新的跨越多个领域的词义消歧评测基准。与 WiC 不同，WiC-TSV 中的每个样本仅包含一个句子，其中标出待消歧的目标词。同时，样本包含该单词的一个预期词义，根据目标词在上下文中的实际词义是否和给出的词义相符，标记 T 或 F 的分类标签。另外，样本中还会给出单词词义的上位词，保证预期词义和实际词义在领域上是接近的。

词义消歧语料库

词义消歧义项相同判断标注语料库

► WiC-TSV (Word in Context - Target Sense Verification)

数据划分	语句	预期词义	上位词	标签
WNT/WKT	<i>Smoking</i> is permitted .	the act of smoking tobacco or other substances	breathing, respiration, ventilation	T
	All that work went down the <i>sewer</i> .	someone who sews	needleworker	F
CTL	We started the evening with <i>Bellini</i> , made with fresh , Niagara peaches .	A Bellini cocktail is a mixture of Prosecco sparkling wine and peach purée	cocktail	T
	After a morning 's work I went off to see the <i>Bellini</i> retrospective at the Quirinale .	A Bellini cocktail is a mixture of Prosecco sparkling wine and peach purée	cocktail	F
MSH	Italy now reports the second highest number of <i>corona</i> cases worldwide .	A viral disorder characterized by high fever, ... and other symptoms of a viral pneumonia.	viral pneumonia; coronavirus infection	T
	<i>Corona</i> Labs is happy to announce the general availability of the public beta of Android 64-bit Corona builds .	A viral disorder characterized by high fever, ... and other symptoms of a viral pneumonia.	viral pneumonia; coronavirus infection	F
CPS	pandas is an open source data analysis and manipulation tool built on top of the <i>Python</i> programming language .	Python is an interpreted, high-level, general-purpose programming language	programming language	T
	The present paper compares the recently studied <i>pythons</i> with those examined 20 years ago , and uses the combined dataset to assess the ecological sustainability .	Python is an interpreted, high-level, general-purpose programming language	programming language	F

图: WNT/WKT 测试集包含通用域的样本, Cocktails(CTL), Medical Subjects(MSH) 和 Computer Science(CPS) 测试集分别包括酒饮、医疗和计算机科学领域的测试样本。

4.5 语义角色标注

语义角色标注

语义角色标注 (Semantic Role Labeling, SRL) 是一种浅层语义分析技术，目标是分析句子的谓词-论元结构，揭示句子中概念范畴之间的语义关系。

- ▶ 语义角色标注的主要语言学理论来源于题元理论 (Thematic Theory)、格语法 (Case Grammar) 以及配价理论 (Valency Theory) 等句子语义理论等。
- ▶ 题元理论认为句子以谓语为中心，谓语决定了句子的基本结构。
- ▶ **论元 (Argument)** 是谓语所涉及的对象，担任了施事、客体、受事、地点或命题等不同的题元角色。语义角色标注任务核心是识别句子中谓语的论元，并确定论元的题元角色。

例如：[中国成飞公司]_{AO}[正在]_{AM-TMP}[制造]_V[民用飞机]_{A1}。
“制造”为谓词 (V)，代表了一个事件的核心行为；
“中国成飞公司”和“民用飞机”为动作的施事者 (AO) 和受事者 (A1)

语义角色标注

语义角色标注算法有很多类型，其基本流程主要由论元识别和论元分类组成。基于句法分析的语义角色标注算法还需要先对句子进行句法分析。

- ▶ 论元识别的目标是从句子识别所有由连续几个单词组成的论元。

由于如果将句子中所有的连续单词片段都作为论元候选，其数量会过于庞大，因此早期的方法在进行论元识别前，通常还会引入基于规则的候选论元过滤方法，利用句法分析结果构造启发式规则对候选项进行大幅度删减。

- ▶ 论元分类则是对论元和谓词之间的关系类型进行分类。
- ▶ 论元识别和论元分类通常采用有监督机器学习算法，将上述任务转换为分类问题。
- ▶ 两个任务之间可以采用流水线结构，也可以采用联合学习的方法。

基于句法树的语义角色标注方法

- ▶ 句法结构主要有成分结构和依存结构两大类。

因此，依赖句法结构的语义角色标注算法可以进一步细分为：

基于成分结构的语义角色标注 (Span-Based SRL)

基于依存形式的语义角色标注 (Dependency-Based SRL)

基于成分句法树的语义角色标注方法

- 在基于成分结构的语义角色标注中，模型基于句子的成分句法分析结果，对句中论元短语对应的跨度进行语义成分标注。





图: 句子“中国成飞公司正在制造民用飞机”的成分句法分析结果

模型的目标是根据句子的句法成分标注, 将名词短语“中国成飞公司”, 副词“正在”和名词短语“民用飞机”识别为谓词“制造”的施事者(AO)、受事者(A1), 以及表示时间关系的修饰语(AM-TMP)。

基于成分句法树的语义角色标注方法

- 通过对成分句法树进行**剪枝**，从句子中初步识别候选论元，供后续的论元识别、论元分类步骤使用。从成分句法树的谓词节点开始，考察该节点的每个兄弟节点；如果兄弟节点和该节点在句法结构上不是并列关系，则将兄弟节点加入候选论元集合；如果兄弟节点是介词短语 (PP)，则将兄弟节点的全体子节点加入候选论元集合。依次对谓词节点的父节点等每个祖先节点执行上述过程，直至到达根节点为止。



图：自谓语 (VV) “制造”开始，此方法逐次考察包含此谓语的谓语短语 (VP)，即“制造民用飞机”等成分。在此过程中，此方法将“民用飞机”、“正在”、“。”和“中国成飞公司”加入候选论元集合，并过滤掉大量不可能是论元的成分。

基于成分句法树的语义角色标注方法

在上述筛选过程后，训练分类模型从候选论元集合中识别真正的论元，并标注论元类型。在此过程中，通常需要为分类器构造有效的特征，常用特征有以下类别：

- ▶ **谓词及相关特征**：谓词，谓词的语态，或论元和谓词出现的前后关系等。
- ▶ **论元的词特征**：论元的中心词及其词性，以及头尾单词等。
- ▶ **基于成分句法标注的特征**：论元的成分类型，树中论元到谓词的路径，成分的父亲、兄弟节点类型等。

在上述特征的基础上，可以利用最大熵分类器、SVM、感知机等监督机器学习方法构建语义角色标注算法。

基于依存关系树的语义角色标注方法

- 基于依存的语义角色标注算法根据句子依存树进行语义角色标注。给定句子“中国成飞公司正在制造民用飞机”及其依存句法树，样本中标注谓词-论元关系，表示谓词与论元的中心词之间的语法关系。在依存句法树中，每个论元自身内部的语法结构由依存关系展示，而论元和谓词的语法关系体现为论元中心词和谓词之间的依存关系。




图: 对于论元“民用飞机”和谓词“制造”，两者之间的语法关系通过从“制造”指向“飞机”的边，体现为宾语 (OBJ) 关系。

基于依存关系树的语义角色标注方法

- 基于依存句法树的语义角色标注方法将上节所述的候选论元筛选过程迁移到依存句法树上。首先，从谓词节点开始，将当前节点的全体子节点加入候选论元集合；然后将当前节点的父节点作为当前节点，重复上述过程，逐次考察谓词节点的祖先节点；至当前节点作为句子的根节点为止。




图: 谓语“制造”分别指向“公司”、“正在”、“飞机”和句尾的标点符号，对应的论元“中国成飞公司”、“正在”和“民用飞机”将被识别为候选论元。

基于依存关系树的语义角色标注方法

针对后续的论元识别、论元分类阶段，基于依存句法树的语义角色标注方法将其建模为判断谓词和论元中心词之间语义关系的任务，并建立分类模型来解决。在此过程中常用的分类特征包括以下几类：


- ▶ **谓词及相关特征**：谓词，谓词的词根、词义、词性、语态，或论元和谓词出现的前后关系等
- ▶ **论元的词特征**：论元的中心词及其词性，以及头尾单词等
- ▶ **基于成分句法标注的特征**：树中论元中心词到谓词的路径，谓词与其父节点的依存关系，以及其父节点的相关信息；谓词与其子节点的依存关系；候选论元中心词的子节点、兄弟节点相关信息等

基于深度神经网络的语义角色标注

- ▶ 基于深度神经网络的语义角色标注，可以用 BIO 标注方案表示论元标签，从而可以直接利用通用的序列标注模型来解决。
- ▶ 也可以以跨度标注句子中的论元短语位置，采用基于跨度预测的方法。由于跨度预测模型显式地建模了句子中短语级别的语义，模型可以更好地学习论元短语的长程邻接关系。
- ▶ 由于句法结构信息为语义角色标注任务提供了丰富的语言学信息，因此可有效利用句法树结构的图神经网络也在该任务上取得了不错的效果。

基于跨度的语义角色标注方法

- 文献⁴中通过端到端模型构建了跨度预测模型，为语句中的每个词和跨度构造表示，实现同时识别句子中的谓词和论元并判断它们之间关系的效果。
该模型分为两个部分：词和跨度表示的构建以及谓词-论元的联合抽取。



⁴Jointly Predicting Predicates and Arguments in Neural Semantic Role Labeling.

基于跨度的语义角色标注方法


- 编码器使用双向 LSTM 作为文本序列的编码器，编码器在每个位置的输入是单词的 GloVe 向量，以及通过 CharCNN 提取的字符级特征。针对每个单词 w_i ，其嵌入表示为

$$x_i = [\text{WORDEMB}(w_i); \text{CHARCNN}(w_i)]$$

编码过程可以形式化地表示为：

$$v_1, \dots, v_n = \text{Encoder}(w_1, \dots, w_n)$$

其中 $S = w_1, \dots, w_n$ 是输入序列， $v_1, \dots, v_n$ 是对应位置的表示。



基于跨度的语义角色标注方法

- 模型的词表示直接使用编码器在对应单词位置的输出，若潜在的谓词 $p = w_i$ 是句子中的第 i 个单词，则 $g(p) = v_i$ 。
- 跨度表示通过四部分构成，以 $a = (w_i, \dots, w_j)$ 为例，分别是
跨度头标记的表示 v_i
跨度尾标记的表示 v_j
中心词特征 $x^h(a)$
跨度范围特征 $\phi(a)$

公式如下所示：

$$g(a) = [v_i, v_j, x^h(a), \phi(a)]$$

基于跨度的语义角色标注方法

- ▶ 中心词特征使用注意力机制建模了跨度内词语的重要程度, 捕获句子中重要词在跨度内出现的信息。对于跨度 $a = (w_i, \dots, w_j)$, 中心词表示的计算如下所示:

$$e(a) = \text{softmax}(W_e^T [v_i; \dots; v_j])$$

$$x^h(a) = [x_i; \dots; x_j] e(s)^T$$

$e(s)$ 是句子 s 中每个词的注意力分数。 $x_i, \dots, x_j$ 是单词 $w_i, \dots, w_j$ 经过编码器之前的原始表示, 由它们计算中心词特征。

跨度范围特征 $\phi(a)$ 仅和跨度的长度有关, 通常按照跨度的出现频率将跨度长度分为若干个范围, 为每个范围训练一个表示向量作为范围特征。在一般的语义角色标注任务中, 可以取 $[1, 2, 3, 4, 5-7, 8-15, 16-31, 32-63, 64+]$ 作为跨度长度的区分范围。

基于跨度的语义角色标注方法

- 在谓词-论元联合抽取部分，通过计算谓词-论元匹配分数 $\phi(p, a, l)$ 来识别谓词和论元，以及论元相对谓词的语义角色

Softmax

$$P(y_{p,a} = l \mid X)$$

谓词-论元匹配分数

Combined

score $\phi(p, a, l)$

匹配得分

Label score $\Phi_{\text{rel}}^{(l)}$


Unary scores Φ_a, Φ_p

谓词/论元得分

Span

representation (g)

跨度表示



基于跨度的语义角色标注方法

- 谓词-论元匹配分数主要通过组合谓词和论元的表示来计算：

$$\Phi_a(a) = \mathbf{W}_a^\top \mathbf{MLP}_a(\mathbf{g}(a))$$

$$\Phi_p(p) = \mathbf{W}_p^\top \mathbf{MLP}_p(\mathbf{g}(p))$$

$$\Phi_{\text{rel}}^{(l)}(a, p) = \mathbf{W}_r^{(l)\top} \mathbf{MLP}_r([\mathbf{g}(a); \mathbf{g}(p)])$$

$$\phi(p, a, l) = \Phi_a(a) + \Phi_p(p) + \Phi_{\text{rel}}^{(l)}(a, p)$$


Softmax
 $P(y_{p,a} = l \mid X)$

谓词-论元匹配分数
Combined score $\phi(p, a, l)$

匹配得分
Label score $\Phi_{\text{rel}}^{(l)}$

Unary scores Φ_a, Φ_p
谓词/论元得分

Span representation (g)
跨度表示



基于跨度的语义角色标注方法

- ▶ 在句子长度为 n 时，潜在谓词和论元的个数分别为 $\mathcal{O}(n)$ 和 $\mathcal{O}(n^2)$ 个，如果要确定每个候选谓词和候选论元之间的语义角色关系，涉及的计算量为 $\mathcal{O}(n^3|\mathcal{L}|)$ ，其中 $\mathcal{L}$ 是标签集合。因此，使用束剪枝 (Beam pruning) 方法降低计算量，在计算谓词-论元匹配分数时，首先考察 $\Phi_a(a)$ 和 $\Phi_p(p)$ ，只保留分数较高的 $\lambda_a n$ 个论元和 $\lambda_p n$ 个谓词进行语义关系标签的计算，从而将计算量降至 $\mathcal{O}(n^2|\mathcal{L}|)$ 。
- ▶ 对于在剪枝中保留下来的谓词-论元对，计算匹配分数后，根据匹配分数的 Softmax 预测语义标签。在训练时，以负对数概率作为目标函数，最大化标准答案的出现概率。


$$P(y_{p,a} = l | X) = \text{softmax}(\phi(p, a, l))$$

$$P(Y|X) = \prod_{p,a} P(y_{p,a}|X)$$

$$\mathcal{J} = -\log P(Y^*|X)$$

基于图卷积神经网络融合句法树的语义角色标注方法

- 语义角色标注与语法树有紧密的联系，如果能够在深度学习模型中**融入语法树结构，可以提供更丰富的信息**。文献⁵提出了一种基于图网络的方法，可以有效融入依存句法树信息。该方法设计了一种结合门控机制的图网络，用于输入语句和句法树的编码。



⁵Encoding Sentences with Graph Convolutional Networks for Semantic Role Labeling.

基于图卷积神经网络融合句法树的语义角色标注方法

- ▶ 记 $G = (V, E)$ 为句法树对应的图，其中节点集合 V 由句子中的每个词语组成，边集合 E 对应句法树中的依存弧。若边 $(u, v) \in E$ ，记 $L(u, v)$ 为边 (u, v) 的类别标签， $D(u, v)$ 为边 (u, v) 的方向标签。
- ▶ 方向标签的取值有 3 种：自指关系，以及依存句法树中的依存关系 (双向)。若在依存关系树中存在由 u 指向 v 的弧，则 $(u, v) \in E$ 且 $D(u, v) = 0$ ， $(v, u) \in E$ 且 $D(v, u) = 1$ 。另外，对于 $\forall v \in V$ ， $(v, v) \in E$ 且 $D(v, v) = 2$ 。

类别标签包括方向信息和依存关系类型。 $L(u, v)$ 和 $D(u, v)$ 分别对应边的细粒度和粗粒度类型标签。

基于图卷积神经网络融合句法树的语义角色标注方法

- ▶ 在图网络的第 k 层，对于每个节点 v ，通过 v 的邻接节点来更新 v 的表示向量：

$$h_v^{(k+1)} = \text{ReLU} \left(\sum_{u \in N(v)} g_{v,u}^{(k)} (W_{D(u,v)}^{(k)} h_u^{(k)} + b_{L(u,v)}^{(k)}) \right)$$

其中， $h_v^{(k+1)}$ 是节点 v 在第 $k+1$ 层的表示， $N(v)$ 是和 v 邻接的节点集合， $g_{v,u}$ 是衡量 u 对 v 的重要性权重， W, b 是线性层的可学习权重，前者仅利用边的方向标签关系，从而大幅度减少了模型的参数规模。

基于图卷积神经网络融合句法树的语义角色标注方法




图: 融合句法信息的 GCN (省略了偏置项和门控), 虚线表示句法, 参数矩阵使用句法函数进行子索引, 撇号 (例如, subj') 表示信息以与依赖弧相反的方向流动 (即, 从依赖到头部)

基于图卷积神经网络融合句法树的语义角色标注方法

- 门控机制通过为节点 v 的每个邻接节点 u 赋予权重，用来排除句法树中和谓词-论元关系无关的依存弧，也起到对依存句法分析结果进行去噪的效果。

v 对 u 的重要性权重按照如下公式进行计算：

$$g_{u,v}^{(k)} = \sigma \left(W'_{D(u,v)}^{(k)} h_u^{(k)} + b'_{L(u,v)}^{(k)} \right)$$

其中， W' ， b' 是线性层的可学习权重。

基于图卷积神经网络融合句法树的语义角色标注方法

- 在模型的整体训练过程中，输入序列首先经过双向 LSTM 编码，将编码结果作为图网络的节点初始表示和句法树信息同时输入图网络。

以图网络的输出作为句子中每个词的表示，该模型将数据标签以序列标注的形式进行编码，每个单词的类标签分布概率预测如下所示：

$$p(r|t_i, t_p, l) \propto \exp(W_{l,r}(t_i \circ t_p))$$

$$W_{l,r} = \text{ReLU}(U(q_l \circ q_r))$$

其中 t_i, t_p 是句子中第 i 个单词和谓词的输出表示， r 是语义角色标签， l 是谓词的词干， U, q 是可学习的权重。 $\circ$ 表示连接操作。

语义角色标注评价方法

- 语义角色标注的评价指标包括精确率 (Precision, P)、召回率 (Recall, R) 和 F 值 (F-Score) 得分。

在预测结果中，仅当论元范围和类型均预测正确时，才视为该论元预测正确，计为真正例 TP。样本中标注，但未被模型预测正确的论元计为假反例 FN。预测结果中出现，但无法与样本标注对应的论元预测结果计为假正例 FP。语义角色标注的精确率为预测正确的论元数和预测结果中总的论元数之比值，即 $P = TP / (TP + FP)$ 。召回率为预测正确的论元数和样本中标记的论元数之比值，即 $R = TP / (TP + FN)$ 。F1 得分为准确率、召回率的调和平均值， $F = 2PR / (P + R)$ 。

语义角色标注语料库

1. 语义角色标注语料库

- ▶ **框架网络 (FrameNet)** 根据框架语义学理论，对英国国家语料库进行标注。FrameNet 目前包括超过 200,000 个人工标注的句子，在句子中标注目标谓词的语义框架、语义角色，以及每个语义角色在句法层面的短语类型和句法功能。
- ▶ **命题库 (Propositional Bank, PropBank)** 是论元角色语义知识库，针对动词性谓词，在语料中标注所在句的谓词-论元 (predicate-argument) 信息。PropBank 对英文宾州树库中的 WSJ (华尔街日报标注) 语料和一部分 BROWN (布朗语料库标注) 语料进行了标注。
- ▶ **名词命题库 (NomBank)** 关注并侧重名词性谓词的语义角色标注，对 PropBank 的涵盖范围进行了补充。NomBank 对语料中的名词性谓词进行语义角色标注。其主要语料资源同样来自《华尔街日报》，研究人员对其中名词性的谓词对应的论元角色进行人工标注。

语义角色标注语料库

2. 基于成分结构的语义角色标注评测

- 在基于成分结构的语义角色标注中，常用的评测基准是 CoNLL05 和 CoNLL12 数据集。CoNLL05 数据集主要由英文宾州树库的 WSJ 部分组成，语料来自《华尔街日报》的新闻报道，数据标注包括宾州树库的句法树标注，以及从 PropBank 中提取的谓词-参数结构信息。在 OntoNotes 语料库提出后，由于其规模大并且涉及多个领域，还具有多种语言等特点，CoNLL 基于该语料库提出了语义角色标注的 CoNLL12 基准。

数据集	CoNLL 2005				CoNLL 2012 (英文)			CoNLL 2012 (中文)		
数据划分	训练集	验证集	测试集	Brown	训练集	验证集	测试集	训练集	验证集	测试集
句子个数	39.8k	1.3k	2.4k	0.4k	75.2k	9.6k	9.5k	36.5k	6.1k	4.5k
谓词个数	90.8k	3.2k	5.3k	0.8k	188.9k	23.9k	24.5k	117.1k	16.6k	15.0k
论元个数	333.7k	11.7k	19.6k	3.0k	622.5k	78.1k	80.2k	365.3k	51.0k	46.7k

语义角色标注语料库

3. 基于依存结构的语义角色标注评测

- CoNLL09 是目前常用于依存形式语义角色标注的评测基准。CoNLL09 数据集包含来自不同语系的加泰罗尼亚语、汉语、捷克语、英语、德语、日语和西班牙语等 7 种语言，用于评估系统在给定谓词的情况下，进行谓词消歧、论元识别和论元分类的能力。CoNLL09 的英语部分主要基于 PropBank 和 NomBank 的标注，包含动词性和名词性谓语，训练集和验证集分别包含 39.3k 和 2.4k 个句子。

数据集	训练集句数	训练集词数	平均句长	谓词比例	验证集句数	验证集词数
CoNLL 2009 (英文)	39.3k	958.2k	24.4	18.7%	2.4k	57.7k
CoNLL 2009 (中文)	22.3k	609.1k	27.3	16.9%	2.6k	73.2k

本章小结

第四章语义分析 (II)

4.4 词义消歧

4.5 语义角色标注