自然语言处理

王刚

统计与数据科学学院

2026 年春季学期

目录

第五章篇章分析

5.1 篇章理论概述

5.2 话语分割

5.3 篇章结构分析

5.4 指代消解

第五章篇章分析

5.1 篇章理论概述

篇章分析

- 篇章的定义与重要性

  语言通常并不是由独立无关的句子组成，而是由具有一定结构的连贯句子集合组成。我们将这样的句子集合称为篇章(Discourse)。篇章是语言表达的基本单位，它反映了语言的内在逻辑和结构。

- 篇章分析的目的：篇章分析的核心在于从整体上理解篇章，其中最重要的任务是对篇章的连贯性（Coherence）和衔接性（Cohesion）进行分析：

1. 连贯性是将真正的篇章与无关、随机的句子集合区分开来的关键性质。它体现了篇章在语义和逻辑上的整体性。
2. 衔接性则帮助我们分析和理解篇章的结构，包括名词、代词之间的指代关系，以及句子之间的逻辑连接手段（如连接词、重复、省略等)。

- 连贯性与衔接性的关系，连贯性和衔接性是相辅相成的：

  连贯性关注篇章的语义一致性，确保内容在逻辑上通顺。

  衔接性关注篇章的形式结构，通过具体的语言手段（如代词、连接词等）实现句子之间的连接。

篇章理论概述

- 背景：篇章语言学是在二十世纪五十年代以后发展起来的一门新兴学科。传统语言学通常以句子本身及其组成成分为研究对象，主要关注句子的语法结构和语义。然而，随着语言学研究的深入，人们逐渐认识到句子在不同的上下文和语境中可能具有不同的意义或交际功能。此外，多个合乎句法的句子并不能随意堆砌在一起构成一个合格的语篇。这些发现促使语言学研究超越句子层次，探索更高层次的语言单位。
- 篇章语言学的核心观点

  超越句子层次：语言研究不应局限于句子本身，而应关注句子的组合及其背后的规则。这些规则不仅包括语法，还涉及语境、逻辑和交际功能等因素。

  语篇为描述框架：W. Weinrich 在 1967 年首次提出了“篇章语言学”这一概念，强调任何语言学研究都应以语篇为基本描述框架，因为语篇是语言使用的实际单位。
- 重要里程碑

  话语分析的提出：Harrris（1952）在《Discourse Analysis》一书中首次提出了“话语分析”这一术语，为篇章语言学的发展奠定了基础。

  篇章语言学的确立：W. Weinrich 在 1967 年明确提出了“篇章语言学”的概念，标志着这一学科的正式确立。
- 篇章语言学的意义：篇章语言学的出现填补了传统语言学的空白，将研究视角从句子扩展到语篇，揭示了语言在更高层次上的结构和功能。它不仅深化了人们对语言本质的理解，还为自然语言处理、翻译学、文学研究等领域提供了重要的理论支持。

篇章理论概述

- 篇章的定义：篇章（Discourse），也称语篇，是指由一系列连续的语段或句子组成的整体。它是语言运用或交际的基本单位，反映了语言在实际使用中的结构和功能。
- 篇章的多样性：篇章的形式多种多样，既包括新闻、小说、论文、报告等较长且复杂的文本，也包括警示标语、交通标识等简短但有意义的语言单位。例如：新闻：通过一系列句子传递最新事件的信息。警示标语：如“禁止通行”，虽然简短，但传达了明确的指令。交通标识：如“停！”，通过单一词语或符号传达重要信息。
- 篇章的合格性：然而，并非所有大于句子的单位都能构成一个合格的篇章。合格的篇章需要满足以下条件：

  连贯性：句子之间在语义和逻辑上具有内在联系。

  衔接性：通过语言手段（如代词、连接词等）实现句子之间的连接。

  交际功能：能够实现特定的交际目的，如传递信息、表达情感或发出指令。

篇章理论概述

- Beaugrande 和 Dressler 在 1981 年所著的《Introduction to Text Linguistics》一书中指出，一个合格的篇章需要满足七个标准：
  - 衔接（Cohesion）
  - 连贯（Coherence）
  - 意图性（Intentionality）
  - 可接受性（Acceptability）
  - 信息性（Informativity）
  - 情景性（Situationality）
  - 互文性（Intertextuality）
- 篇章与孤立句子的主要区别在于：篇章是由句子组成的前后连贯的、有主题的统一整体。篇章所呈现的特定结构，不仅包含音、词和句法等表层结构上，也体现在语义连贯的深层结构上。
  需要注意的是，由于篇章的类型和特点千差万别，一个合格的篇章并不一定完全满足上述所有七个标准。

篇章的衔接

衔接（Cohesion）是指篇章中的某一语言成分需要依赖另一语言成分进行解释。

- 衔接是一种语义关系，使得篇章各组成部分在语义上相互联系，关系紧凑。
- 衔接也被作为语篇连贯性的必要条件之一，在语篇中体现为词汇衔接和语法衔接。
- 词汇衔接包括重述（Reiteration）、搭配（Collocation）等衔接手段。
- 语法衔接包括照应（Reference）、替代（Substitution）、省略（Ellipsis）、连接（Conjunction）等衔接手段。

篇章的衔接—词汇衔接

- 重述关系是通过词的重复、同义词或近义词、反义词、上下位词等词汇手段形成的篇章衔接关系。

  例如：

  (1) 苏州园林据说有一百多处，我到过的不过十多处。其他地方的园林我也到过一些。倘若要我说说总的印象，我觉得苏州园林是我国各地园林的标本，各地园林或多或少都受到苏州园林的影响。因此，谁如果要鉴赏我国的园林，苏州园林就不该错过。

  (2) 那棵树立在那条路边上已经很久很久了。当那路还只是一条泥泞的小径时，它就立在那里；当路上驶过第一辆汽车之前，它就立在那里；当这一带只有稀稀落落几处老式平房时，它就立在那里。

  例 (1) 中“苏州园林”出现了四次，“我国的园林”、“各地园林”等则通过上下位关系进行衔接。例 (2) 中，“它就立在那里”出现了三次，与“已经很久很久了”也形成了近义重述关系。

篇章的衔接—词汇衔接

- 搭配关系是指词的共现关系，包括一个词组或者一个句子内部的词之间的组合关系，也包括句子间或段落间的词的习惯性共现。

  例如：有一天早上，撒了三次网，什么都没捞着，他很不高兴。第四次把网拉拢来的时候，他觉得太重了，简直拉不动。他就脱了衣服跳下水去，把网拖上岸来。打开网一看，发现网里有一个胆形的黄铜瓶，瓶口用锡封着，锡上盖着所罗门的印。

  例子中，围绕“撒网”展开，形成了一个与撒网打鱼相关的动词链，“撒-捞-拉-拖”够成了词汇衔接。在同一个篇章中，词汇之间通过语义联想构成衔接关系。

篇章的衔接—语法衔接

- 照应是指篇章中一个语言成分与另一可以与之相互解释的成分之间的关系，即一个成分作为另一个成分的参照点。

  例如：那只最后从蛋壳里爬出来的小鸭是那么丑陋，他处处挨啄，被排挤，被讪笑，不仅在鸭群中是如此，连在鸡群中也是这样。

  代词“他”的确切含义是由它所指的对象决定的。例中“他”是指“最后从蛋壳里爬出来的小鸭”。

- 照应性（Phoricity）是语言交际过程中一个普遍现象，用来指代篇章中的实体、概念或事件。
  照应可以分为两种：
  外指（Exophora）照应是指篇章中的某个成分的参照点不在篇章本身，而是在语境中。
  内指（Endophora）照应是指语言成分的参照点在篇章上下文中。

篇章的衔接—语法衔接

- 替代是指用替代形式来取代上文中的某一成分。可以进一步细分为名词性替代、动词性替代和小句性替代。

  例如：各式各样的球鞋像装在万花筒里，在她面前转开了：白色的，蓝色的，高筒的，矮帮的，白色带红边的，白色带蓝边的。

  例中“白色的，蓝色的，高筒的，矮帮的，白色带红边的，白色带蓝边”与上一句中“球鞋”构成了紧密的衔接关系，“的”替代了上文中的“球鞋”，属于名词性替代。汉语中“做”和“干”经常用于动词性的替代。“这样”、“这么”等经常用于小句性替代。

篇章的衔接—语法衔接

- 省略是指将语言结构中某个成分在句子中去除。虽然省略结构在语法层面不完整，但是并不是不可理解的，并且表达更加精炼。

  例如：雨是最寻常的，一下就是三两天。可别恼。看，雨像牛毛，雨像花针，雨像细丝，密密地斜织着，人家屋顶上全笼着一层薄烟。

  例中“像牛毛，像花针，像细丝”前都省略了“雨”，但是很容易理解并且语篇前后衔接，结构紧凑。

  省略也可以分为名词性省略、动词性省略以及小句性省略(Clausal Ellipsis)。

篇章的衔接—语法衔接

- 连接是通过连接成分体现篇章中逻辑关系。从逻辑语义关系类型上，可以细分为三大类：
  1. 详述（Elaboration）是对上文内容进一步说明、评论或解释，主要包括同位语和阐明两种情况。
  2. 延伸（Extension）是从正面或反面增加新的陈述，包括添加、转折、变换等类型。
  3. 增强（Enhancement）则是指补充额外必要信息，达到加强语义并使其更加完整，包括时空、方式、因果与条件、话题等条件。

  例如：不必说碧绿的菜畦，光滑的石井栏，高大的皂荚树，紫红的桑葚；也不必说鸣蝉在树叶里长吟，肥胖的黄蜂伏在菜花上，轻捷的叫天子 (云雀) 忽然从草间直窜向云霄里去了。单是周围的短短的泥墙根一带，就有无限趣味。

  例中通过“不必说”、“也不必说”、“单是”层层递进，使得句子之间紧密连接。

篇章的连贯

- 连贯（Coherence）是指篇章在语义、功能和心理上构成一个整体，围绕同一个主题或意图展开。
  连贯性（Coherent）是衡量篇章质量的重要指标，只有连贯的句子集合才能够形成篇章。这也是篇章与无关的、随机的句子集合区分开的最主要因素。
- 篇章应该同时具有局部连贯性（Local Coherent）和整体连贯性（Global Coherent）。
  局部连贯性是在微观层面，篇章中前后相连的命题在语义上的联系。
  整体连贯性是在宏观层面，篇章中的所有命题与篇章主题之间的联系。

  例如：(1) 他点了一份外卖。(2) 外卖很快就送到了。
  (1) 表示 (2) 的条件，并且与真实世界中事件存在对应关系，属于外延语义结构。为了达到话语序列在语义上的连贯性，需要与现实世界中的自然顺序相对应，也就是说如果把 (1) 和 (2) 的顺序颠倒过来，那么该话语序列就不再具有语义上的连贯性。

篇章的连贯

- 除了现实世界中自然顺序的限制，话语序列的语义结构还受到人们普遍认知规律的制约。人们认识和描述客观世界时通常遵循从一般到特殊、从整体到局部、从大到小，从集合到子集的认知模式。

  例如：
  单是周围的短短的泥墙根一带，就有无限趣味。油蛉在这里低唱，蟋蟀们在这里弹琴。翻开断砖来，有时会遇见蜈蚣；还有斑蝥，倘若用手指按住它的脊梁，便会啪的一声，从后窍喷出一阵烟雾。

  上例符合整体到局部的排列顺序，从对百草园的“无限趣味”开始，再以局部的细节展开，详细描写了由“油蛉”、“蟋蟀”、“斑蝥”所带来的乐趣。这样的顺序与人们一般的认知规律和感知顺序相符合，从而也就更容易让人接受。

篇章的连贯

- 局部连贯说明篇章中相邻句子存在联系，但是仅有局部连贯是不够的，篇章在整体上还需要围绕一个主题展开，既需要具有整体连贯性。整体连贯性对篇章中句子之间的联系施加宏观制约。

  例如：
  (1) 于一个在北平住惯的人，像我，冬天要是不刮风，便觉得是奇迹；济南的冬天是没有风声的。对于一个刚由伦敦回来的人，像我，冬天要能看得见日光，便觉得是怪事；济南的冬天是响晴的。自然，在热带的地方，日光永远是那么毒，响亮的天气，反有点儿叫人害怕。可是，在北方的冬天，而能有温晴的天气，济南真得算个宝地。
  (2) 母亲还从来没有一次给过我这么多钱。我也从来没有向母亲一次要过这么多钱。我来到母亲工作的地方，呆呆地将那些母亲扫视一遍，却没有发现我的母亲。背直起来了，我的母亲。转过身来了，我的母亲。褐色的口罩上方，一对眼神疲惫的眼睛吃惊地望着我，我的母亲。
  例 (1) 在微观层面上前后承接，句子之间的逻辑关系清晰，宏观层面围绕“济南的冬天”主题开展。例 (2) 的局部上是连贯的，但是宏观层面上缺乏主题，从而缺乏整体连贯。

篇章的连贯

- 篇章的连贯是一个复杂的现象
  有些现象不能完全从语义角度解释话语序列的连贯性，还需要从语用角度以及认知角度进行讨论。
- 围绕语篇的连贯也有很多理论和方法，包括：
  从关联理论角度对微观层面连贯性研究；
  利用修辞结构理论（Rhetorical Structure Theory）进行语篇连贯性研究；
  运用图式理论（Schema Theory）的连贯性研究；
  基于语篇策略（Discourse Strategy）的连贯性研究等。
- 研究篇章的连贯性是自然语言处理中的重要问题，对文本摘要、阅读理解、机器翻译等篇章级别的任务都具有有重要的作用。

篇章的结构

- 篇章同时具有线性结构和等级结构。篇章中的句子按照一定的线性规则排列在一起，因此篇章是线性的。同时，句子的组合可以构成更大的语言单位，因此篇章又是具有等级结构的。

  [1] 著名苏联作家高尔基曾经说过："书是人类进步的梯。" [2] 书是一个知识的殿堂，是人类最好的精神食粮，也是人鸿鹄高翔的羽翼。[3] "书中自有黄金屋。"书本中的知识是无穷无尽的，读书是为了更好地获取更多知识，开阔自己的视野，帮助自己创造，实现自己的人生目标。[4] 战国时期，苏秦去秦国以连横说进行游说，多次给秦惠王上书也未被采纳。[5] 回到家中，父母妻嫂都不理睬他，于是他就找出许多书籍发奋研读。终于以合纵之策而身佩六国相印。
  句子（1）（2）组成了引论，句子（3）给出了第一个论点，句子（4）-（5）是论据。

- 常见的篇章结构的表示方法：超级结构 (Superstructure)、修辞结构理论 (Rhetorical Structure Theory) 和语篇模式 (Textual Pattern)。

篇章的结构 – 篇章超级结构

- 篇章超级结构（Superstructure）是采用规约化图式结构来表示篇章宏观内容组织形式的一种形式结构。只涉及篇章内容的组织方法，与篇章所表达的具体内容没有直接关系。不同类型的语篇往往具有不同的超级结构。

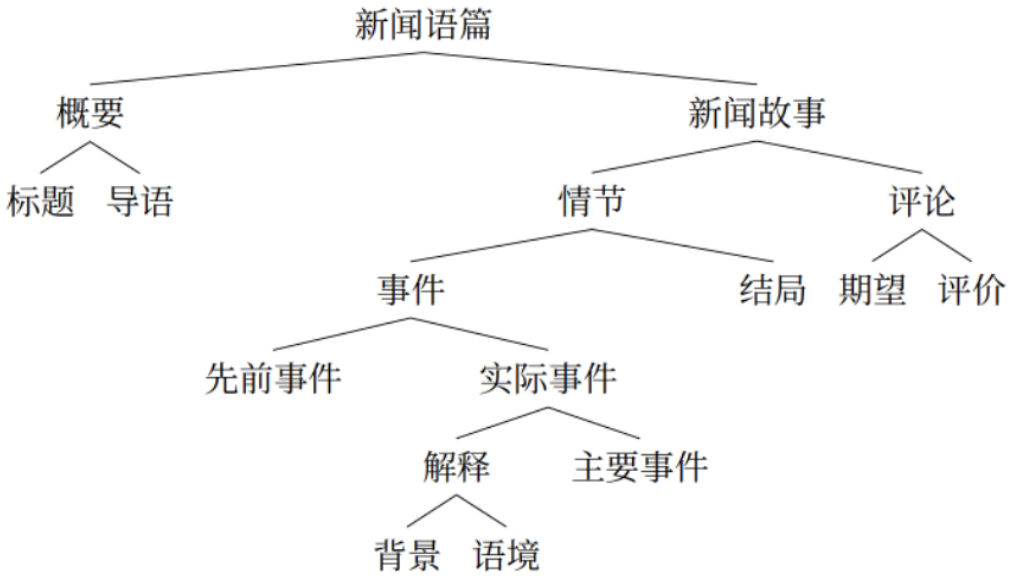

篇章超级结构提供了组织相关类型语篇的基础纲要和架构。在具体的篇章中，结构也具有一定的灵活性，并不是所有的结构成分都要存在，结构成分的位置也是不固定的。

篇章的结构 – 修辞结构理论

- 修辞结构理论（Rhetorical Structure Theory, RST） 是 Mann 和 Thompson 于 1987 年提出的一种通过描述篇章各个组成部分之间的修辞关系来分析篇章结构的理论。
- 修辞结构理论将修辞关系定义在两个或多个文本单元（Text Span）之间。文本单元又称基本篇章单元，有两种主要类型：
  1. 核心（Nucleus）单元是篇章中最重要的部分，表达作者的核心意图，并且具有相对完整的语义，能够独立解释。
  2. 辅助（Satellite）单元则较少表达作者的核心意图，用于传达支撑其他信息，补充说明核心单元，通常只有在与核心单元关联时才能够被解释。

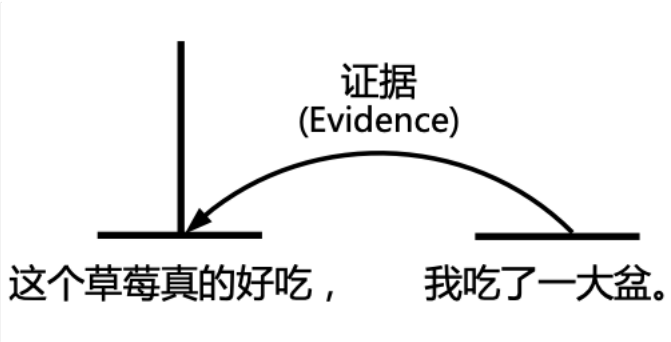

图: 例如：[1] 这个草莓真的好吃，[2] 我吃了一大盆。

篇章的结构－修辞结构理论

- 篇章中的修辞关系主要包括两种类型：
  (1) 不对称性的核心-辅助关系，也称单核关系，包括: 对立，动机、背景、析取、意图、总结、评价、证据、使能等；
  (2) 无主次之分的多核心关系，包含对比、联合、列举和序列。

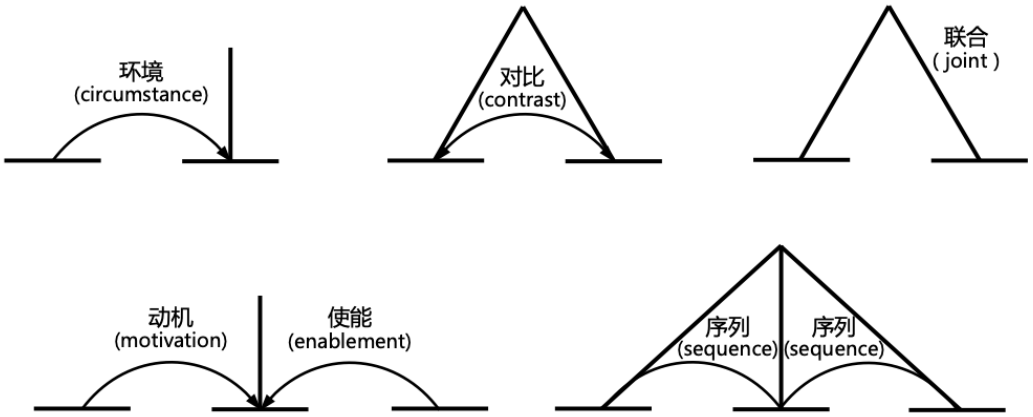

环境关系是单核心关系，弧线箭头指向核心单元。对比关系总是两个核心单元。序列关系则可以具有多个连续的单元，相邻的两个单元之间构成序列关系。联合关系也可以具有多个单元，这些单元一起构成该关系。

篇章的结构 – 修辞结构理论

- 篇章的修辞结构在总体上表现为等级结构，连贯的篇章可以由不同层次的修辞关系组织成层次结构，从而形成一个修辞关系树。

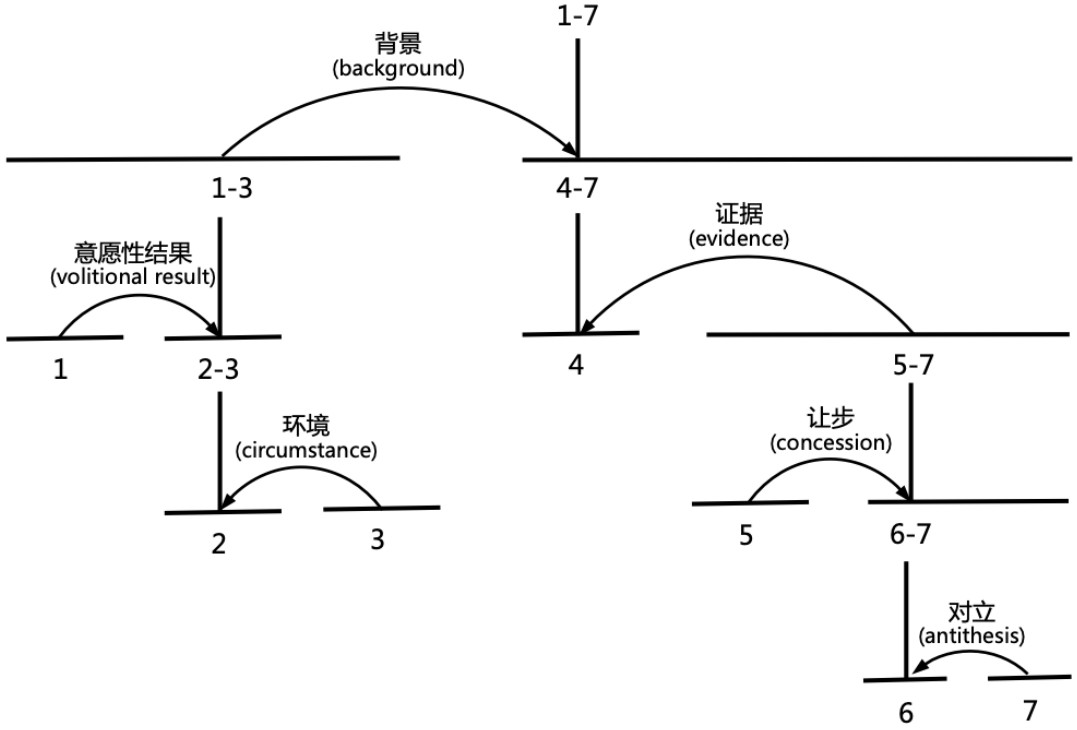

图: 修辞结构关系树样例

篇章的结构－语篇模式

语篇模式（Textual Pattern）是指人们长期积累并根据经验形成的一些程式化的语篇组织形式或策略。

- 语篇模式是在一定的文化中形成的，因此往往带有不同文化积淀的内涵和文化规约性。
- 语言学家总结出了“问题-解决”（Problem-Solution）、“概括-具体”（General-Specific）等英语中常见的语篇模式。
- 语篇模式与小句关系之间存在着密切的联系，小句通过组合形成逻辑序列关系或匹配关系，通过这些关系小句又组合为更大的语篇单位。
- 语篇模式与具体的篇章内容通常没有直接的联系，但是每种语篇模式通常都具有特定的词汇标记。

篇章的结构 – 语篇模式

- 语篇模式示例

[1] 长征五号遥三运载火箭 27 日晚在海南文昌一飞冲天，将实践二十号卫星成功送入太空预定轨道。[2] “胖五”也以实际行动，诠释着中国俗话所说“哪里跌倒，就要从哪里爬起来”的坚持与坚韧。[3] 2017 年 7 月长征五号遥二火箭因发动机故障发射失利。[4] 科研人员历经两年多的艰苦攻关、连续奋战，进行大量地面试验，完成遥二失利故障归零和遥三火箭各项工作，还采取一系列改进优化措施，切实提升火箭飞行任务可靠性。[5] 长征五号遥三火箭在此背景下成功发射，对研制团队直面挑战、发现问题、解决问题的心理能力建设也是一次巨大考验，也为航天人才特别是青年人才树立起不怕失败、敢于挑战、勇于拼搏的榜样力量。

情景（句子 1、2）→ 问题（句子 3）→ 反应（句子 4）→ 评价（句子 5）

5.2 话语分割

话语分割

- 根据修辞结构理论，篇章修辞关系定义在两个或多个基本篇章单元（EDU）之间。
  话语分割（Discourse Segmentation）的目标就是将篇章分割为基本篇章单元，从而实现后续的篇章分析任务。
- 话语分割任务通常被形式化为序列标注任务或者单词级别的二分类任务，对每个单词位置输出预测其是否为一个基本篇章单元的边界。

输入：“The bank also says it will use its network to channel the investments”

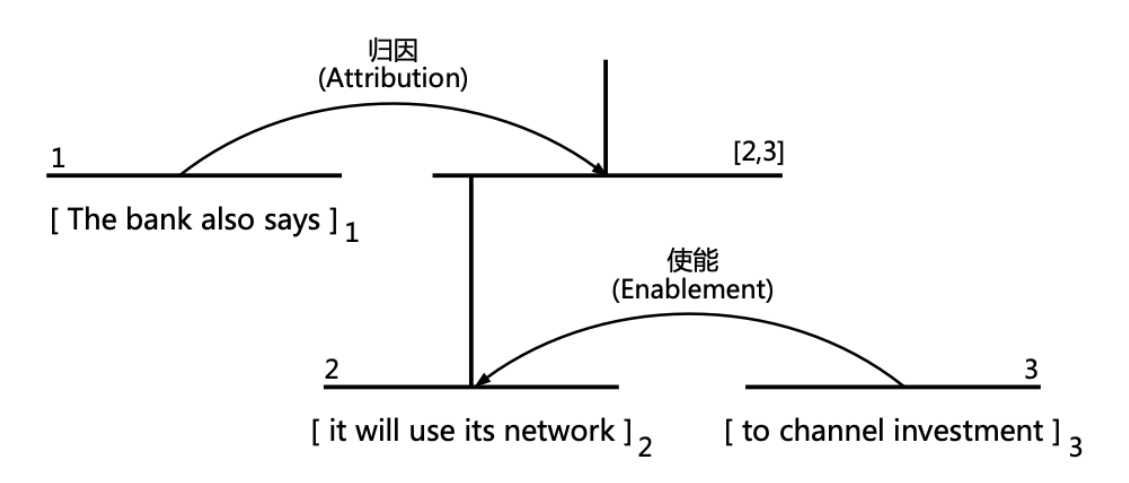

基于词汇句法树的统计话语分割

- SynDS[1]算法是一种基于句法树的统计模型，用于估计句子中每个词作为基本篇章单元（EDU）分界点的概率。其核心思想是通过句法分析工具获取句子的句法树，并结合词汇和句法特征，预测每个词是否为分界点。
- 给定句子 $s = w_1, w_2, ..., w_n$
  (1) 首先使用句法分析工具得到该句子的句法树 t;
  (2) 随后对句子中的每个词 w_i，使用最大似然估计的方法学习其作为分界点的概率 $P(b_i|w_i, t)$，其中 $b_i \in \{0, 1\}$。0 表示为非边界，1 表示为边界。
  (3) 为了同时使用词汇及句法特征估计基本篇章单元分界，SynDS 算法使用了词汇中心（Lexical Head）映射规则，将词汇成分引入句法树。
  LexicalHead 映射是 NLP 和计算语言学中的一种技术，主要用于将词汇成分（如单词或短语）与句法树中的节点关联起来，以增强句法分析和语义理解的准确性。其核心目标是通过词汇信息补充句法结构的表示，从而更精确地捕捉语言单元的边界和功能。
  对于每个词 w 来说，SynDS 算法关注其包含右兄弟节点的最高父节点，使用其构建的特征决定当前词是否作为分界词。

[1] Sentence level discourse parsing using syntactic and lexical information, 2003

基于词汇句法树的统计话语分割

- SynDS 在判断词“says”是否为分界词时，使用该词本身对应的节点 $N_w = VBZ(says)$、其父节点 $N_p = VP(says)$ 及其右兄弟节点 $N_r = SBAR(will)$ 作为特征。

  当前词节点 N_w：提供词的词性信息和句法角色，帮助判断其是否可能成为分界点。

  父节点 N_p：反映当前词在句法树中的上下文结构，进一步明确其句法功能。

  右兄弟节点 N_r：揭示当前词与后续词之间的关系，为判断分界点提供重要线索。

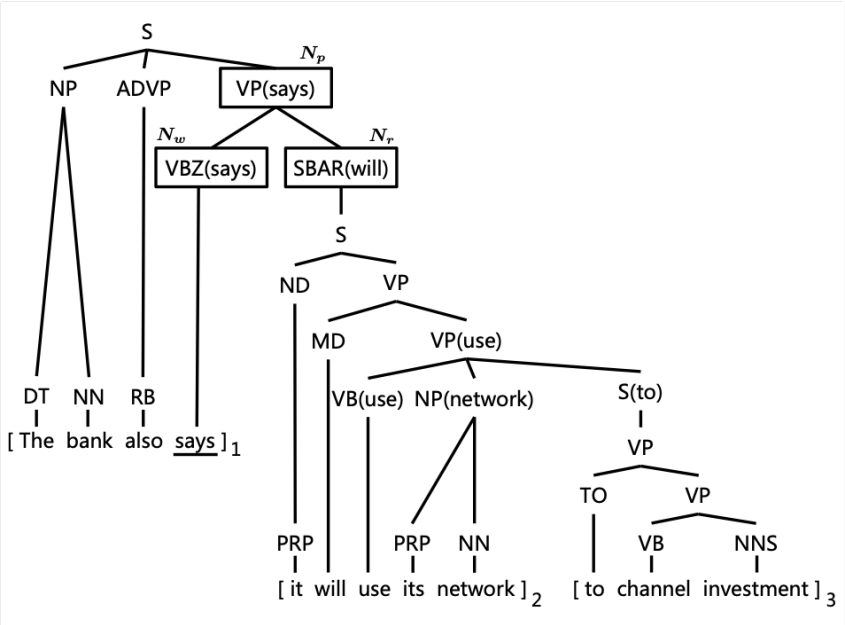

基于词汇句法树的统计话语分割

- 使用修辞结构理论树库 (Rhetorical Structure Theory Discourse Treebank，RST-DT) 语料的统计量估计每个词作为分界词的似然概率：

$$P(b|w,t) \simeq \frac{\mathrm{Cnt}(N_p \to \ldots N_w \uparrow N_r \ldots)}{\mathrm{Cnt}(N_p \to \ldots N_w N_r \ldots)}$$

  分子表示规则 $\mathrm{Cnt}(N_p \to \ldots N_w N_r \ldots)$ 在语料中出现且 w 为分界词的次数 (↑ 表示该处为分界)，分母表示该规则在语料中出现的总次数。

- RST-DT 是基于修辞结构理论（RST）构建的篇章级标注语料库，旨在通过树形结构表示文本的语义关系和篇章组织。标注框架：基于 RST 理论，将篇章结构表示为树形层级，包含四种要素：
  基础语篇单元（EDU）：最小语义片段，对应树叶节点。
  文本跨度（Span）：内部节点，由连续 EDU 组成。
  核心性（Nuclearity）：区分核心（nucleus）与卫星（satellite）单元，核心承载主要信息。
  修辞关系（Rhetorical Relation）：如因果、对比等，连接文本跨度。

基于循环神经网络的话语分割

- 话语分割任务还可以转换为序列标注问题[2]，给定一个输入句子 $\mathbf{x} = \{x_t\}_{t=1}^{n}$，其输出 $\mathbf{y} = \{y_t\}_{t=1}^{n}$ 中每个 y_t 表示第 t 个词是否为一个基本单元的开头，如果是，则 $y_t = 1$，否则 $y_t = 0$。可以采用基于 BiLSTM-CRF 模型实现这一任务。

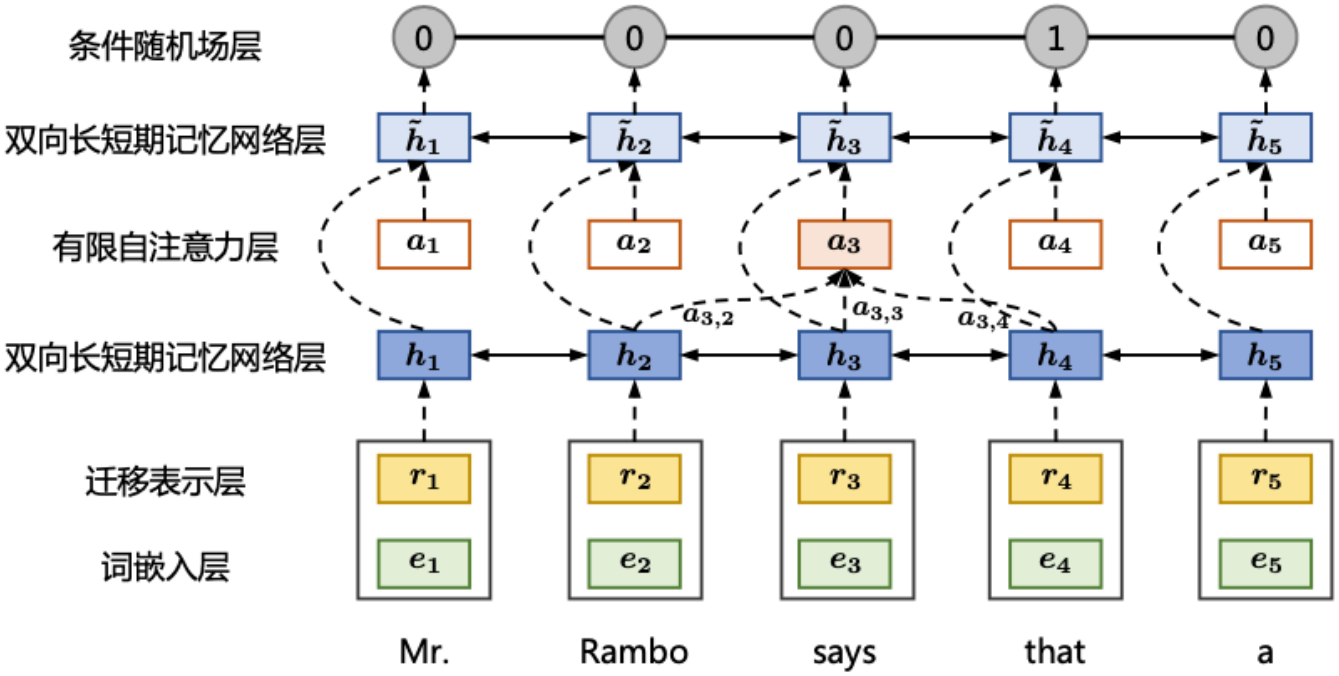

[2]Toward Fast and Accurate Neural Discourse Segmentation, 2018.

基于循环神经网络的话语分割

- 将每个词 x_t 表示为一个向量 e_t，然后使用一个 Bi-LSTM 网络建模序列中每个词的表示：$h_t = \mathrm{BiLSTM}(h_{t-1}, e_t)$。其中，$h_t = [h_t^f, h_t^b]$ 为 t 位置正向 LSTM 及反向 LSTM 编码得到的隐向量表示的串联。
- 在获得每个词的隐向量表示后，为了更好地利用序列信息，使用条件随机场层进行输出解码。给定一个句子 x 的输出隐向量序列 $h = \{h_t\}_{t=1}^n$，该句子预测为序列 y 的概率为:

$$P(y \mid h; W; b) = \frac{\prod_{i=1}^n \psi_i(y_{i-1}, y_i, h)}{\sum_{y' \in \mathcal{Y}} \prod_{i=1}^n \psi_i(y'_{i-1}, y'_i, h)}$$

其中，$\mathcal{Y}$ 表示所有可能的输出标签序列，$\psi_i(y'_{i-1}, y'_i, h) = \exp(w^\top h_i + b)$ 为势函数。在训练时，模型最大化输出正确标签序列的似然概率。在解码时，模型计算产生最大似然概率的标签序列

$$y^* = \arg\max_y P(y \mid h; W; b)$$

基于循环神经网络的话语分割

- 由于用于话语分割训练的语料通常较小，使用上述 BiLSTM 模型在该语料上训练难以取得理想地效果。因此，可以使用预训练词向量将更大语料上获取的知识迁移到话语分割任务上。
- 例如使用 ELMo（Embeddings from Language Models）词向量建模输入序列:

$$r_t = \gamma^{LM} \sum_{l=0}^{3} s_l^{LM} h_{t,l}^{LM}$$

其中，s_l^{LM} 为归一化权重，对 ELMo 词向量的三个组成部分进行加权，γ^{LM} 为整个 ELMo 词向量的权重。随后，r_t 被拼接到词向量 e_t 上作为模型的输入。

基于循环神经网络的话语分割

- 考虑使用自适应机制 (Restricted Self-attention) 加强句子的长距离依赖建模。但是并不是所依赖的距离越长越好，模型关注过长距离的信息可能会引入噪音，不利于预测。考虑 EDU 边界识别任务特性，即通常只需要使用相邻 EDU 的信息。因此，使用距离限制的自适应机制，只使用邻近的信息来预测。
- 首先计算当前词 x_i 和一个窗口内的相邻词 x_j 之间的相似度:

$$s_{i,j} = W_{attn}^{T}[h_i, h_j, h_i \odot h_j]$$

基于循环神经网络的话语分割

- 传统的自注意力机制计算每个词与序列中所有词的注意力权重，复杂度为 $O(n^2)$。而在 EDU 边界识别任务中，研究表明约 85% 的边界决策只需考虑当前词前后 3-5 个词的上下文。基于这一观察，模型采用窗口受限的自注意力：
- 每个词的注意力向量由相邻词加权获得:

$$\alpha_{i,j} = \frac{e^{s_{i,j}}}{\sum_{k=-K}^{K} e^{s_{i,i+k}}}, \quad a_i = \sum_{j=-K}^{K} \alpha_{i,i+k} h_{i+k}$$

其中，K 为使用的窗口大小。该注意力向量随后和 h 一起被输入另一层 BiLSTM，并输出 $\tilde{h}$ 作为 CRF 的输入:

$$\tilde{h}_t = \mathbf{BiLSTM}(\tilde{h}_{t-1}, [h_t, a_t])$$

最后，利用序列标注模型 CRF 给出输出。CRF 层通过学习标签转移约束解决 BiLSTM 输出的局部不一致问题。

基于循环神经网络的话语分割

- https://github.com/PKU-TANGENT/NeuralEDUSeg
- 数据样本示例 https://github.com/PKU-TANGENT/NeuralEDUSeg/tree/master/data/rst

5.3 篇章结构分析

篇章结构分析

- 篇章结构分析的目标是分析篇章单元之间存在的连贯关系，从而服务于下游任务。
- 现有的篇章分析工作基于不同的篇章分析标注框架，主要可以分为两大类：
  基于词汇的浅层篇章分析
  基于语义或意图关系的完整篇章分析

1. 浅层篇章分析代表是 Penn Discourse Treebank（PDTB）标注框架
2. 完整篇章分析代表是 RST Discourse TreeBank（RST-DT）标注框架

修辞结构篇章分析

- RST-DT是篇章分析中的代表性标注框架，其标注基于修辞结构理论，将一个完整的篇章标注成由基本篇章单元组成的层次树状结构。其中，树的节点关系由相邻篇章单元之间的关系构成。在标注时，一个完整的篇章首先被切分成不相交的基本篇章单元（EDU）。在此基础上，根据修辞关系理论，将相邻的基本篇章单元连接，并标注为 78 种修辞关系的一种。

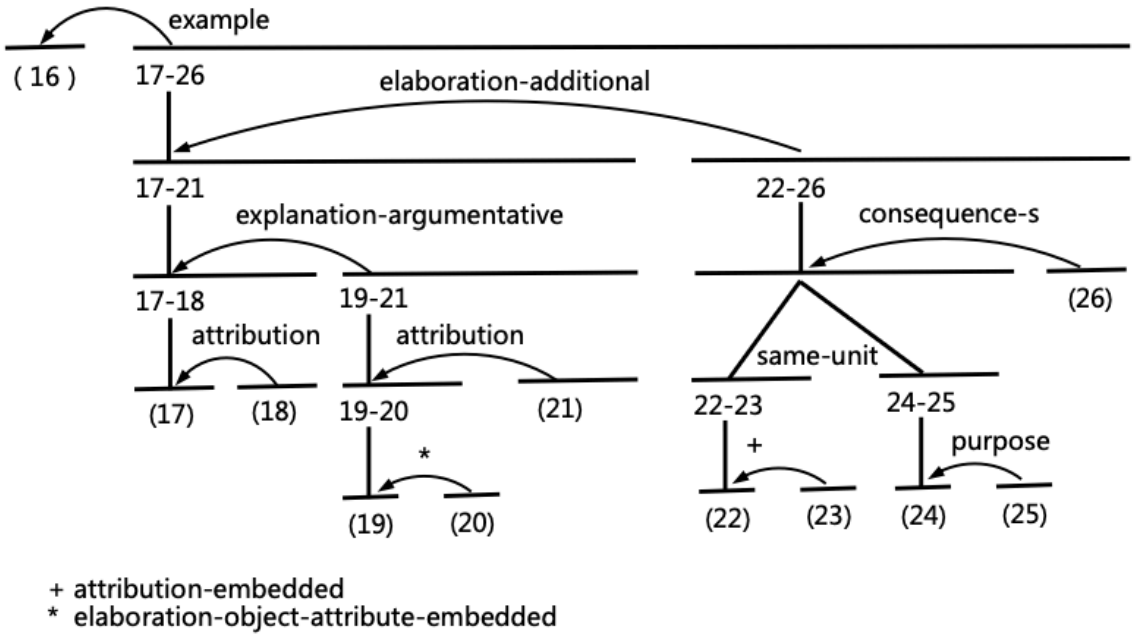

基于 SVM 分类器的 RST 篇章分析

- HILDA（HIgh-Level Discourse Analyzer）是基于 SVM 分类器的 RST 篇章分析算法，将修辞结构树定义为二叉树结构，并定义了建立一个有效修辞结构树（valid RS-tree）T 的两项规则：

1. T 的所有叶子结点均为 EDU
   (单个 EDU 也可以构成一个修辞结构树)。
2. T 的所有非叶子结点被标注为篇章关系集合中的一种关系
   ($R_i \in \mathcal{R}$)。

基于 SVM 分类器的 RST 篇章分析

- 基于这一修辞结构树的定义，HILDA 采用了基于贪心原则的流水线方法，使用两个支持向量机分类器对 EDU 之间是否存在关系以及存在何种关系分别进行分类。
  具体来说，HILDA 定义的两个分类器：

1. 结构分类器 $\mathrm{Struct}(l_i, l_j)$：用于判断篇章结构的二元分类器，即判断两个有效修辞结构树之间是否存在修辞关系，分类目标为 0 和 1，0 表示没有关系，1 表示有关系。
2. 类型分类器 $\mathrm{Label}(l_i, l_j)$：用于判断修辞关系类型及核类型的多元分类器，分类目标为篇章关系集合 $\mathcal{R} = \{R_1, ..., R_n\}$，$R_i =< RR_i, Left_i, Right_i >$ 定义为由两个有效修辞结构树的核类型及其之间的修辞关系类型组成的三元组，其中 $RR_i \in \{ATTRIBUTION, CAUSE, ...\}$ 为 HILDA 所使用的修辞关系集合中的一种关系；
   $Left_i, Right_i \in \{Nucleurs, Satellites\}$ 为两个修辞结构树的核类型。

基于 SVM 分类器的 RST 篇章分析

- 基于上述两个分类器，算法步骤如下：

1. 对输入文本，首先创建一个包含所有 EDU 的列表，其中 EDU 的排序按照从左到右的阅读顺序。当列表元素数目大于 1 时，使用结构分类器计算列表中所有相邻单元的结构预测分数。
2. 基于贪心原则，取出所有结构预测中分数最高的一组，使用类型分类器预测其修辞关系类型及核类型，并基于预测结果建立一个新的子树。得到新的子树后，分别重新计算该子树与相邻单元之间的结构预测分数，并将列表中对应单元替换为新的子树。
3. 重复上述过程直到列表元素数目等于 1，则留在列表中的元素即为输出的篇章树。

- 为了能够更准确地对篇章结构及修辞关系进行分类，HILDA 构建了多种类型的特征作为 SVM 分类器的输入，包括 N-gram 特征、句法结构特征、POS 特征等。

基于递归神经网络的 RST 篇章分析

- 基于递归神经网络的 RST 篇章分析算法 RNN-RST。与 HILDA 算法相似，RNN-RST 也是通过训练两个分类器，即结构分类器及修辞关系类型分类器构造修辞结构树，但用于分类的特征则使用递归神经网络进行计算。

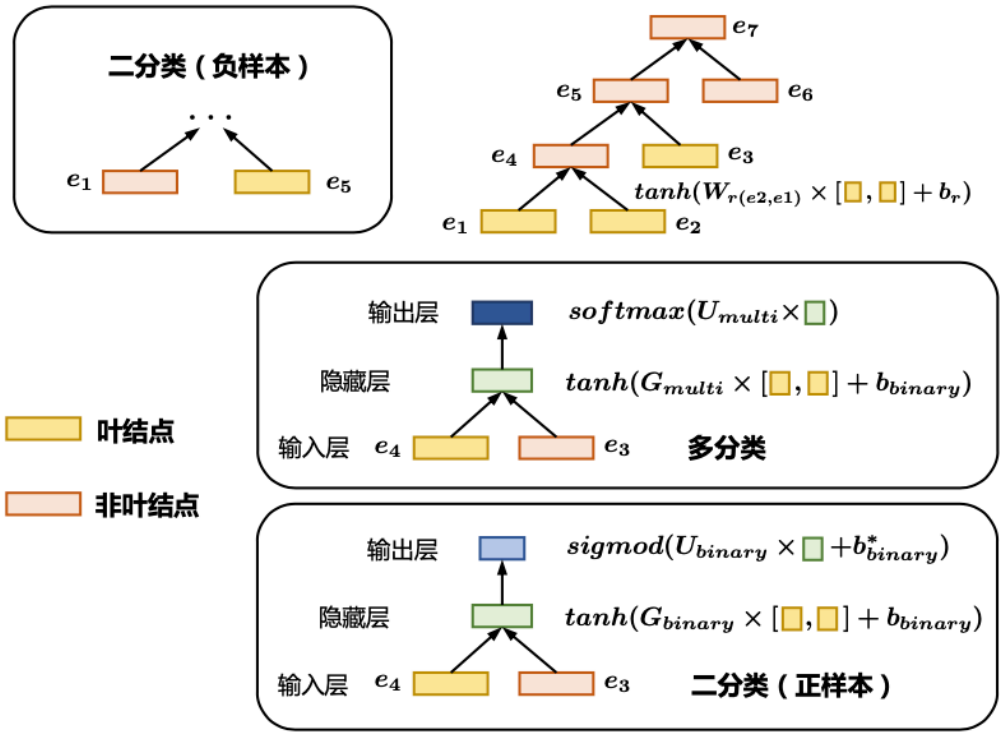

基于递归神经网络的 RST 篇章分析

- 利用标注语料集合，可以分别构造上述两个分类器的训练数据，并利用交叉熵损失函数进行模型参数训练。

  在训练完成后可以采用类似用于句法分析的 CKY 动态规划方法，对于给定的篇章进行修辞结构树构建。对于由 n 个 EDU 组成的篇章，可以构建 $N_r \times n \times n$ 组成的动态规划表 P_r，N_r 表示关系类型数量，P_r 表中每个单元格 $P_r[r, i, j]$ 表示从片段从第 i 个 EDU 到第 j 个 EDU 中具有关系 r 的概率，其计算过程如下：

$$
\begin{aligned}
P_r[r, i, j] = \max_{r_1, r_2, k} & P_r[r_1, i, k] \cdot P_r[r_2, k, j] \\
& \times P(t_{\text{binary}}(e_{[i,k]}, e_{[k,j]}) = 1) \\
& \times P(r(e_{[i,k]}, e_{[k,j]}) = 1)
\end{aligned}
$$

  其中 k 是分割点，r_1 和 r_2 是子片段的关系类型。结构分类器 $P(t_{\text{binary}}(e_{[i,k]}, e_{[k,j]}) = 1)$ 用于判断两个 EDU 片段 $e[i, k]$ 和 $e[k, j]$ 是否可以合并为一个更大的修辞单元。关系分类器 $P(r(e_{[i,k]}, e_{[k,j]}) = 1)$ 预测合并后的修辞关系类型，是一个多分类问题。

浅层篇章分析

- Penn Discourse Treebank（PDTB）是基于词汇化树型连接语法（Discourse Lexical Tree Adjunct Grammar，D-LTAG）理论构建的篇章分析标注框架，是篇章分析中的另一代表性框架。PDTB 以篇章内相邻或者跨度在一定范围内的片段，以连接词为核心，对片段间关系进行标注。
- 相较于修辞结构理论将整个篇章构建为树结构而言，PDTB 则针对两个片段之间的关系，因此也可以称为浅层篇章分析。
- 每个篇章关系由两个论据（Argument）及其之间的关系组成，两个论据分别标注为 Arg1 和 Arg2。在相邻句子构成的关系中，Arg1 和 Arg2 则反映论据之间的线性顺序，其中 Arg1 在 Arg2 之前。
- 根据连接词是否显式存在，PDTB 标注的关系可分为显式篇章关系和隐式篇章关系两类。

浅层篇章分析

- 显式篇章关系（Explicit Discourse Relation）由显式连接词定义，通过显式连接词连接 Arg1 和 Arg2。在显式关系中，Arg2 一般为句法上关联的论据，Arg1 则为另一个论据，显式连接词由三种语法连接词产生：
  1. 从属连词，如 because, when 等
  2. 并列连词，如 and, or 等
  3. 语篇副词，如 for example, instead 等

  基于显式关系定义的标注样例：

  (1) Third-quarter sales in Europe were exceptionally strong$_{[Arg1]}$, boosted by promotional programs and new products –although$_{显式连接词}$ weaker foreign currencies reduced the company's earnings$_{[Arg2]}$.

  (2) Most oil companies, when they set exploration and production budgets for this year, orecast revenue of $15 for each barrel of crude produced.

浅层篇章分析

- 隐式篇章关系（Implicit Discourse Relation）则是除显式篇章关系以外，需要靠读者通过推断判断的篇章关系。

  But a few funds have taken other defensive steps. Some have raised their cash positions to record levels. Implicit = BECAUSE High cash positions help buffer a fund when the market falls.
  虽然没有显式连接词，但读者能够通过论据之间的语义判断出其之间表达的因果关系。在 PDTB 中，这样的隐式关系通常通过标注者插入一个连接词进行标注（例如上面例子中的 BECAUSE 被插入以表示因果关系）。

浅层篇章分析

- 而当隐式关系无法使用一个隐式连接词进行标注时，则构成三种特殊的隐式关系：
  1. AltLex表示语篇关系已经由非连接词的词汇表达，额外插入连接词会构成冗余的情况。
  2. EntRel表示句子之间只存在基于实体的连贯关系的情况。
  3. NoRel表示句子之间不存在任何篇章关系或基于实体的连贯关系的情况。

1. Ms. Bartlett's previous work, which earned her an international reputation in the non-horticultural art world, often took gardens as its nominal subject. Implicit = AltLex Mayhap this metaphorical connection made the BPC Fine Arts Committee think she had a literal green thumb.
2. Hale Milgrim, 41 years old, senior vice president, marketing at Elecktra Entertainment Inc., was named president of Capitol Records Inc., a unit of this entertainment concern. Implicit = EntRel Mr. Milgrim succeeds David Berman, who resigned last month.
3. Jacobs is an international engineering and construction concern. Implicit = NoRel Total capitalinvestment at the site could be as much as $400 million, according to Intel.

浅层篇章分析

- 由于一个连接词在不同的篇章中可能表达不同的语义关系，PDTB 中为显式关系、隐式关系和 AltLex 关系提供了三级语义标注 (Sense Tag)：CLASS, TYPE, SUBTYPE。其中，最高层标注 (CLASS) 包含四个主要语义类别：TEMPORAL(时序关系), CONTINGENCY(条件关系), COMPARISON(比较关系), EXPANSION(扩展关系)。对于每个语义类别，使用 TYPE 进一步标注其语义。第三级语义标签 SUBTYPE 则具体化每个论据的语义贡献。

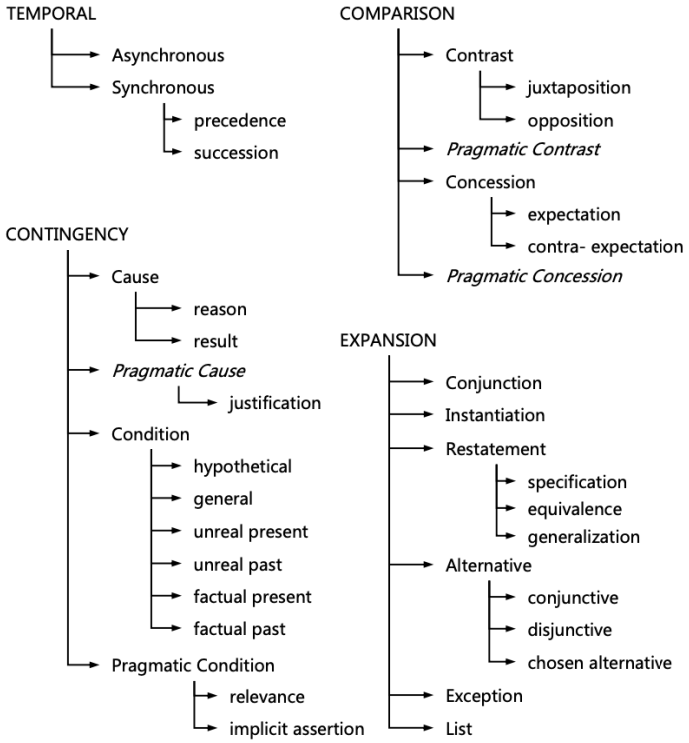

基于句法特征构建的显式篇章分析

- 由于部分显式连接词在不同语境下具有不同语义，显式篇章分析的重点在于对显式连接词进行消歧，并将每一连接词分类为 PDTB 标注的四个一级语义类别（TEMPORAL、CONTINGENCY、COMPARISON、EXPANSION）[3]

  例如：下述两个包含 since 的句子

  (1) Guangzhou has a wide water area with many rivers and water systems since it is located in the water-rich area of southern China.

  (2) She has been living in since she graduated from Shanghai University of Finance and Economics.
  显式连接词“Since”在句子 (1) 中表示因果关系，属于 CONTINGENCY 语义类别；在句子 (2) 中则是 TEMPORAL 语义类别。

- 显式篇章分析关注的主要问题即为将连接篇章中话语的显式连接词正确划分为其所属的语义类别，通常以文本分类的方式实现。

[3] TEMPORAL 表示时间关系，CONTINGENCY 表示因果关系，COMPARISON 表示比较关系，EXPANSION 表示进一步阐述或解释关系。

基于句法特征构建的显式篇章分析

- 使用最大熵分类器[4]，通过利用句法特征对显式篇章关系进行分类。基于标准 Penn Treebank 句法分析标注，构建了多种句法特征对显式连接词的语义进行消歧，所构建的句法特征包括：
  - 自身类别（Self Category）：子树包含且仅包含该显式连接词的最高父节点。对于单个单词构成的显式连接词，其特征为该词自身的 POS 标注；对于多个单词构成的显式连接词则不然。
  - 父节点类别（Parent Category）：自身类别的最近父节点的类别。
  - 左兄弟节点类别（Left Sibling Category）：离自身类别最近的左兄弟节点类别。如果左兄弟节点不存在，则其特征为“None”。
  - 右兄弟节点类别（Right Sibling Category）：离自身类别最近的右兄弟节点类别。
- 实验结果表明，通过构建句法特征，对显式连接词进行分类能够达到 94.15% 的准确率。

[4] Using syntax to disambiguate explicit discourse connectives in text, 2009

基于循环神经网络语言模型的隐式篇章分析

- 由于传统机器学习方法在显式篇章分析任务上已经能够达到较高的准确率，后续基于 PDTB 的篇章分析工作更多地关注隐式篇章分析，相关的工作包括基于前馈网络、基于浅层卷积神经网络、基于循环神经网络语言模型及基于预训练语言模型的隐式篇章分析等。
- DRLM[5]算法使用包含隐变量的循环神经网络语言模型建模隐式篇章分析算法，整个过程建模为两阶段生成过程。首先，句子 t-1 和句子 t 之间的隐式篇章关系 z_t 由句子 t-1 的信息建模。在此基础上，句子 x_t 根据句子 x_{t-1} 和 z_t 生成。

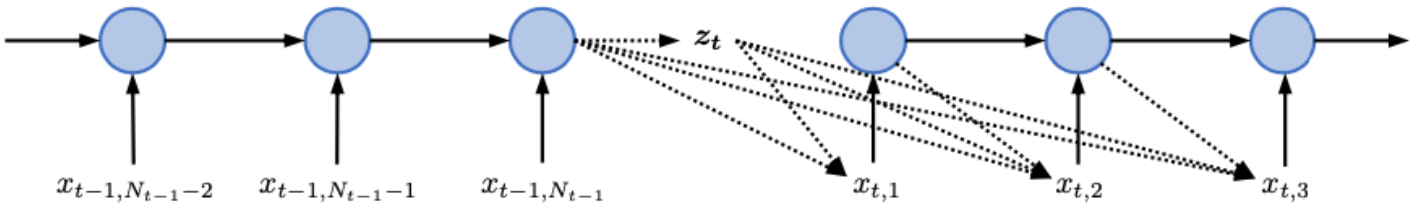

[5] A Latent Variable Recurrent Neural Network for Discourse Relation Language Models, 2016.

基于循环神经网络语言模型的隐式篇章分析

- 给定输入句子 $x_t = \{x_{t,n}\}_{n\in\{1\ldots N_t\}}$，其中 t 表示该句为篇章中的第 t 个句子，$N_t$ 为句子 t 的长度。基于链式法则，RNN 语言模型将该句出现的概率转化为每个词出现的条件概率的乘积：

$$p(x_t) = \prod_{n=1}^{N_t} p(x_{t,n}|x_{t,<n})$$

在每个时刻 n，RNN 语言模型的输入为包含所有历史信息的上一刻输出隐变量 $h_{t,n-1}$ 和当前词的词向量 $\mathbf{x}_{x_{t,n}}$，其预测下一个词的条件概率为：

$$h_{t,n} = \mathrm{RNN}(X_{x_{t,n}}, h_{t,n-1})$$

$$p(x_{t,n} \mid x_{t,<n}) = \mathrm{softmax}(W_o h_{t,n-1} + b_o)$$

基于循环神经网络语言模型的隐式篇章分析

- 由于篇章分析需要对包含多句话的长文本进行语言模型建模，而 RNN 语言模型难以处理长距离依赖关系，DRLM 使用了基于文档的语言模型。具体来说，文档中第 t 个句子的第 n 步输出的条件概率为：

$$p(x_{t,n} \mid x_{t,<n}, x_{<t}) = \mathrm{softmax}(W_o h_{t,n-1} + W_c c_{t-1} + b_o)$$

其中，c_{t-1} 为句子 t-1 的上下文信息，DRLM 算法采用句子 t-1 最后一步输出的隐向量表示该句子信息。

基于循环神经网络语言模型的隐式篇章分析

- 基于上述 RNN 语言模型，DRLM 将篇章关系 z_t 作为隐变量引入，并设计了两步语言模型生成过程。第一步，使用句子 t-1 的上下文信息 c_{t-1} 生成句子 t-1 和句子 t 之间的篇章关系：

$$p(z_t \mid x_{t-1}) = \mathrm{softmax}(Uc_{t-1} + b)$$

第二步，基于句子 x_{t-1} 及上一步生成的篇章关系 z_t，生成句子 x_t：

$$p(x_t \mid z_t, x_{t-1}) = \prod_{n}^{N_t} p(x_{t,n} \mid x_{t,<n}, x_{t-1}, z_t)$$

引入篇章关系隐向量后的输出条件概率计算为:

$$p(x_{t,n} \mid x_{t,<n}, x_{t-1}, z_t) = \mathrm{softmax}(W_o^{(z_t)} h_{t,n} + W_c^{(z_t)} c_{t-1} + b_o^{(z_t)})$$

其中 $W_o^{(z_t)} h_{t,n}$ 关系特定的句内语境，$W_c^{(z_t)} c_{t-1}$ 关系特定的句间语境。

基于循环神经网络语言模型的隐式篇章分析

- 最后，文本及篇章关系的联合概率为:

$$p(x_{1;T}, z_{1;T}) = \prod_{t}^{T} p(z_t \mid x_{t-1}) \times p(x_t \mid z_t, x_{t-1})$$

在训练阶段，DRLM 可以使用两种目标函数进行训练: 联合似然目标函数和条件目标函数。其中，联合似然目标函数的损失函数计算为:

$$\mathcal{L}(\theta) = \sum_{t}^{T} \log p(z_t \mid x_{t-1}) + \sum_{n}^{N_t} \log p(x_{t,n} \mid x_{t,<n}, x_{t-1}, z_t)$$

使用上述联合似然目标函数能够同时优化模型的篇章关系预测能力及语言模型能力，可以视为一种多任务学习。

基于循环神经网络语言模型的隐式篇章分析

- 在实际实现时，由于词的数量比句子的数量更多，使用这一目标对模型语言模型能力的优化占主导地位。因此，DRLM 的条件目标函数的损失函数为:

$$\mathcal{L}(\theta) = \sum_{t}^{T} \log p(z_t \mid x_{t-1}) + \log p(x_t \mid z_t, x_{t-1}) - \log \sum_{z'} p(z' \mid x_{t-1}) \times p(x_t \mid z', x_{t-1})$$

第三项计算了所有可能的 z' 生成句子 x_t 的损失。这项损失的加入使得目标函数倾向于优化篇章关系相关的条件似然损失，而将语言模型任务视为一个辅助任务。

基于循环神经网络语言模型的隐式篇章分析

- 在推断时，通过贝叶斯公式计算句子 t-1 和句子 t 之间为关系 z_t 的条件概率，后验概率计算公式为

$$p(z_t \mid x_t, x_{t-1}) = \frac{p(x_t \mid z_t, x_{t-1}) \times p(z_t \mid x_{t-1})}{\sum_{z'} p(x_t \mid z', x_{t-1}) \times p(z' \mid x_{t-1})}$$

该公式包含三个关键组成部分：

似然项 $p(x_t|z_t, x_{t-1})$: 表示在给定关系 z_t 和前句 x_{t-1} 的条件下，生成当前句 x_t 的概率。

先验项 $p(z_t|x_{t-1})$: 表示仅基于前句 x_{t-1} 预测关系 z_t 的概率。

归一化项 (分母部分): 对所有可能关系 z' 的联合概率 $p(x_t|z', x_{t-1})p(z'|x_{t-1})$ 求和，确保后验概率分布的有效性 (总和为 1)。

基于循环神经网络语言模型的隐式篇章分析

- https://github.com/jiyfeng/drlm?tab=readme-ov-file

- 数据格式 https://github.com/jiyfeng/drlm/blob/master/data-sample.txt

```
yeah .  1
okay .  18
well it was very nice talking to you .  9
nice talking to you .   9
bye-bye .       9
bye-bye .       9
=== Document Boundary
uh-huh ,        8
i have got two .        0
one is two      0
and the other one 's four       0
and this is my first year of staying home .     0
i 've always had them in child care .   0
well then you are familiar with it ?    6
uh-huh .        8
okay ,  12
i i have grandchildren  0
and i know well two of them have gone to preschool .    0
uh-huh .        1
and i know what the experience my daughter has faced with that .        0
why do n't you tell me what you have found .    23
```

5.4 指代消解

指代消解

- 虽然指代现象并不影响人类阅读和理解篇章，甚至还起到了避免重复以及提高语言效率的作用。但是指代对于一些自然语言处理任务却有一定的影响，需要明确不同表述之间的指代关系。
- 指代消解（Coreference Resolution）旨在将同一实体（Entity）在篇章中出现的不同表述（Mention，也称提及）划分到同一等价类（或称表述类）中。

  实体指某一客观存在的事物；

  表述则为指代某一实体的在篇章中不同描述。

指代消解

- 指代消解任务通常关注两种指代类型：
  共指（Coreference）表示两个表述指向真实世界中的同一实体。
  回指（Anaphora）表示当前表述指向上文出现的另一表述。
- 指代上文的表述称为照应词（Anaphor），将照应词指代的上文表述称为先行词（Antecedent）。

例如：上海的卖腌腊的店铺里也卖咸鸭蛋，必用纸条特别标明："高邮咸蛋"。
"咸鸭蛋"和"咸蛋"指代真实世界中的统一实体，因此为共指关系。

例如：我围抱着火炉，烤热漫长一生的一个时刻。我知道这一时刻之外，我其余的岁月，我的亲人们的岁月，远在屋外的大雪中，被寒风吹彻。
"这一时刻"指代上文的"一个时刻"，为回指关系。其中"这一时刻"为照应词，"一个时刻"为先行词。

指代消解

- 指代消解任务将语篇中所有表示同一实体的指代分配到同一等价类中，并给出每一语篇中的所有等价类。

  例如：其间有一个十一二岁的少年 [1]，项带银圈，手捏一柄钢叉，向一匹猹 [2] 用力地刺去。那猹 [2] 却将身一扭，反从他 [1] 的胯下逃走了。

  “一个十一二岁的少年”和“他”指代同一实体，属于同一等价类；
  “一匹猹”和“那猹”指代同一实体，属于同一等价类。
  指代消解任务的目标是发现文中的等价类 [1] 和 [2]。

指代消解

- 指代消解任务一般可分为两个步骤：
  1. 表述发现（Mention Detection）也称提及发现，旨在找出句子中所有可能存在指代关系的名词表述，一般包含人称代词（“你”、“我”、“他”等）、命名实体（人名、地名等）及一些名词短语（“那只猫”、“右边的女士”）等。
  2. 指代消解（Coreference Resolution）旨在对表述同一实体的表述聚合在一起，是这一任务的核心，也是最具挑战的步骤。
- 指代消解的方法主要包括：
  1. 基于表述对(Mention Pair) 的方法使用一个二分类分类器对每一对表述是否为指代关系进行判断。
  2. 基于表述排序(Mention Ranking) 的方法针对给定指代，通过计算其与每一表述组成的表述对的分数，对相关表述进行排序，以确定其指代关系。
  3. 基于实体的方法，基于聚类的方法对文本中所有表述进行聚类，每个类被认为指代同一实体名词。

基于表述对的指代消解

- 基于表述对的指代消解算法是将该任务转换为二分类问题，分别对每个表述与其所有先行词所构成的表述对是否构成指代关系进行分类。
  例如：长妈妈，已经说过，是一个一向带领着我的女工，说得阔气一点，就是我的保姆。我的母亲和许多别的人都这样称呼她，似乎略带些客气的意思。
  对于所选表述“她”，基于表述对的指代消解算法需要分别计算“她”和其所有先行词构成的表述对是否为指代关系进行分类。

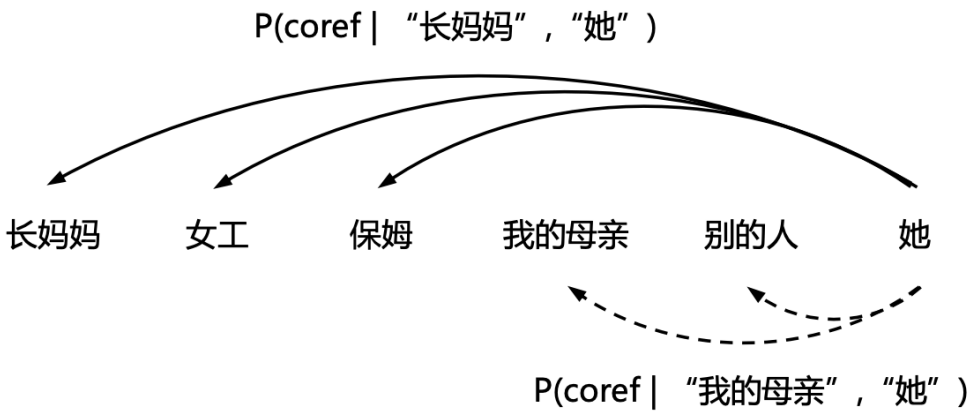

指代消解目标就是对上述所有表述对是否为指代关系进行分类。

基于表述对的指代消解

- 基于一个训练得到的用于表述对分类的二分类器，对每个测试文本的指代消解推理可以视为一个构造消解图（Coreference Graph）的过程（也可视为聚类过程）：每个表述为图中的一个节点，当分类器预测一个对表述之间有指代关系时，则为这两个节点之间添加一条有向边。
- 根据上述方式构成的图，能够表示每两个表述之间是否互为指代。同时通过所有连接构成的传递闭包（Transitive Closure）[6]，我们能够找出所有等价类。
- 对于该先行词的选择策略，基于最近原则（Closest-First）的算法从后向前依次计算所有先行词与该表述构成的表述对为指代关系的分数，并选择第一个大于阈值的先行词。而基于最优原则（Best-First）的算法则计算所有先行词与该表述构成的表述对为指代关系的分数，并选出分数最高的先行词进行连接。

[6]传递闭包是指在一个有向图中，若存在一条从节点 i 到节点 j 的路径，则将节点 i 与节点 j 之间的所有节点都加入到关系中，使得该关系具有传递性。这个关系被称为传递闭包。简单来说，它可以帮助我们找到图中所有可达的节点对。

基于表述对的指代消解

- Feature-pair：基于多类特征及感知器分类的表述对指代消解系统。
  其构造的特征主要包括两个方面：
  1. 表述特征包括表述类型特征，例如其是否为专有名词（Proper Noun）、普通名词（Common Noun）或代词（Pronoun）等。
  2. 表述对特征包括表述对的字符串关系特征（如一个字符串是否为另一个的子串）、语义相符性特征（例如性别、数字是否相符）、相对位置特征、实体类别特征等。

基于特征工程的表述对指代消解

- 表述类型特征：表述所属的类型，为专有名词、普通名词或代词。
- 字符串关系特征：两个字符串之间是否存在一些共有特征，例如一个字符串是另一个字符串的子串等。
- 语义特征：包括两个名词之间的性别是否相符、数字是否相符；两个名词是否为近义词、反义词、或上位词等。
- 相对位置特征：两个表述之间的位置关系，例如将距离转化为二元特征（[distance≤i]，i 包括所有间隔值）、两个表述是否属于同一个句子等。
- 可学习特征：基于可学习分类器得到的特征，例如使用分类器判断两个由同一修饰语修饰的表述，其修饰语之间是否存在指代关系。
- 修饰语对齐特征：两个上位词相同的修饰语之间存在的关系，例如是否为子串、近义词、反义词等。
- 记忆特征：选取一些常常构成指代关系的表述对构造特征（例如“the queen”和“Elizabeth II”），供模型记忆学习。
- 预测实体类别特征：基于模板匹配预测实体所属的实体类别（人名、地名、机构名等），并基于预测类别构造两个表述之间实体类别是否匹配或是否相交等特征。

基于特征工程的表述对指代消解

- 基于上述构造的特征，Feature-pair 算法使用感知器对每一指代对是否构成指代关系进行分类。训练时，Feature-pair 基于最近原则，选择当前表述 m 与其所指代的距离最近的先行词 a 所构成的表述对 (a,m) 作为正样本；选取在 m 之前所有和 m 不属于同一等价类的表述作为负样本。
  测试时，Feature-pair 基于最优原则，每次选择与 m 构成分数最高的表述对的先行词：

$$a = \arg\max_{b \in B_m} (PC(b, m))$$

  其中 $PC(\cdot)$ 为表述对分数计算函数，当 $PC(a, m)$ 大于某一预定义阈值时，则将 a 和 m 链接为同一等价类。Feature-pair 算法使用感知器作为分类器：$PC(b, m) = w \cdot \phi(b, m)$，其中：$\phi(b, m)$ 是表述对 (b, m) 的特征向量，w 是模型权重向量。

基于神经网络的表述对指代消解

- Feedforward-pair：基于前馈神经网络的表述对指代消解分类器，专门设计用于判断两个表述 (mention) 是否指向同一实体。该模型通过组合丰富的语言特征和神经网络表示学习。

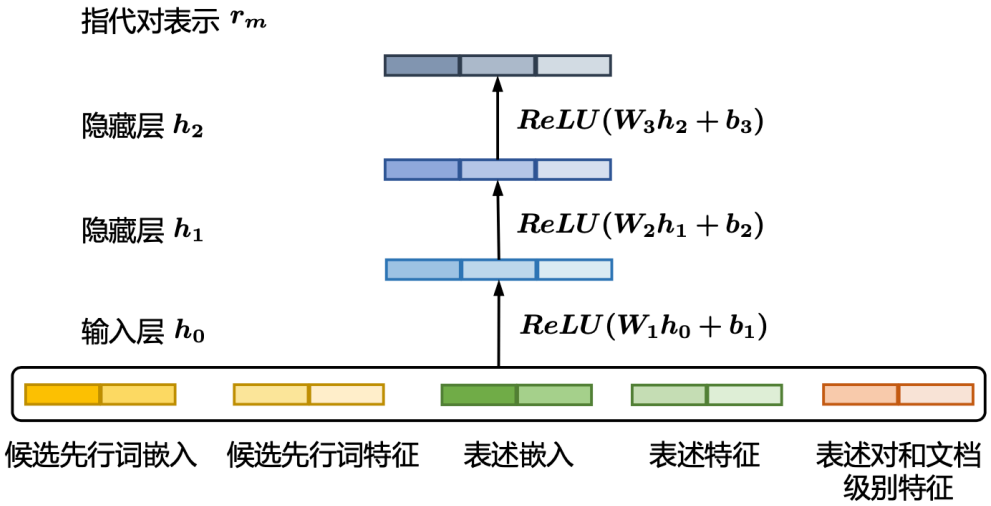

输入层将输入词映射到输入特征空间，其输入特征由表述及表述相关词的词嵌入向量及一些其他特征构成。
表述相关词包括表述的依赖词、句法树中的父节点、表述的第一个词、表述的第二个词、表述之前的两个词及之后的两个词等等；
其他特征包括表述的类型特征、位置特征、文档类型特征等。

基于表述排序的指代消解

- 基于表述对的指代消解基于二分类器分别对每个先行词和当前指代构成的表述对进行预测。这种做法对于不同先行词的预测是相互独立的，只能判断每个先行词相对当前指代的合理程度，而无法直接通过比较判断哪个先行词是最正确的。
- 基于表述排序的指代消解算法的基本思路是使用一个多分类器，基于多个先行词候选计算出分数最高的先行词。

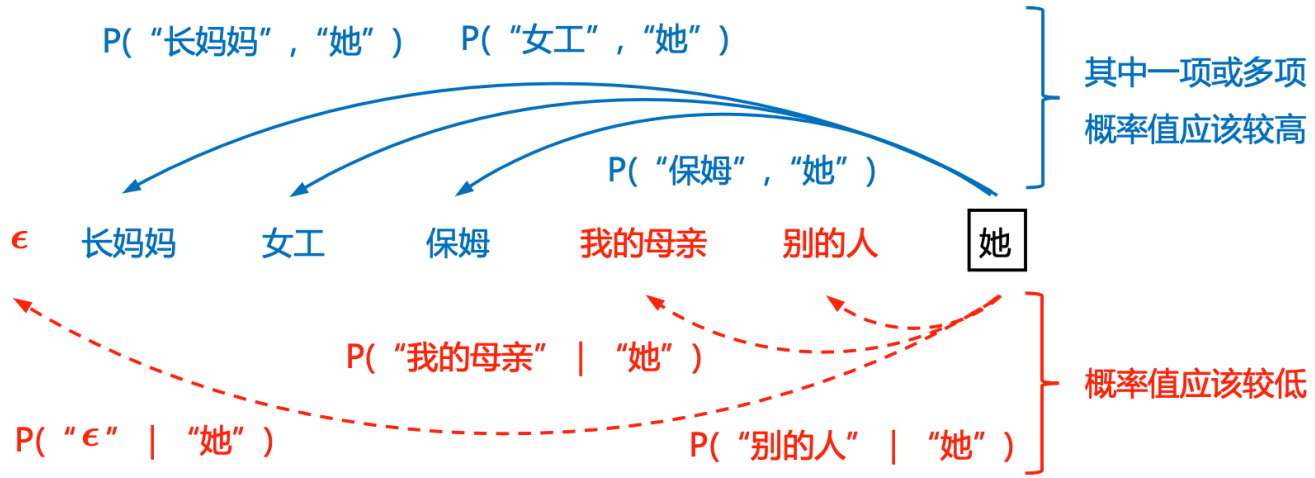

图: 基于表述排序的指代消解示例

基于特征工程和最大熵分类器的表述排序指代消解

- 基于表述排序的指代消解算法 RK[7]将指代消解任务从基于指代对二分类器的多步推理（先分别计算各指代对的分数，再基于某种策略选出最高分的先行词），转化为同时计算并比较所有先行词候选的单步推理过程。
- 对每个先行词候选 α_i，模型计算其为当前照应词 π 的先行词的条件概率 $\Pr(\alpha_i|\pi)$，从而对于每个照应词 π，通过比较多个候选先行词的条件概率即可以选出最可能和 π 构成指代关系的的先行词：

$$\mathrm{P_r}(\alpha_i \mid \pi) = \frac{\exp(\sum_{i=1}^{n} \lambda_i f_i(\pi, \alpha_i))}{\sum_k \exp(\sum_{i=1}^{n} \lambda_i f_i(\pi, \alpha_k))}$$

  特征函数 $f_i(\pi, \alpha_i)$：衡量照应词 π 与候选先行词 α_i 之间的关联强度，可包含多种语言学特征，如：字符串匹配特征、句法角色特征、语义兼容性特征、距离特征。
- 在测试时，考虑到大部分指代为局部指代，为了节约测试时间，RK 算法只选取照应词 π 所在的句子及所在句之前的 3 个句子内的表述作为候选。

[7] A Ranking Approach to Pronoun Resolution, IJCAI, 2007

基于特征工程和最大熵分类器的表述排序指代消解

- RK 算法通过最大熵分类器建模上述条件概率，所用特征包含：

(1) 照应词特征：描述待分类表述的特征，包括其代词类型特征、大小写特征等；

(2) 候选先行词特征：描述候选先行词的特征，包括其词性特征、其左右相关词的词性特征等；

(3) 关系特征：描述两个表述之间关系的特征，包括两个词之间的距离、两个词的语义相符性特征等。

代词特征	
PERS_PRO	如果 π 是人称代词则为 T，否则为 F
POSS_PRO	如果 π 是所有格代名词则为 T，否则为 F
THIRD_PERS_PRO	如果 π 是第三人称代词则为 T，否则为 F
SPEECH_PRO	T 如果 π 是第一或第二人称代词则为 T，否则为 F
PRO_FORM	T 如果 π 是小写字母组成的代词则为 T，否则为 F
候选先行词特征	
ANTE_WD_LEN	α 中单词的数量
PRON_ANTE	如果 α 是代词则为 T，否则为 F
PN_ANTE	如果 α 是专有名词则为 T，否则为 F
INDEF_ANTE	如果 α 是无定名词短语（indefinite NP）则为 T，否则为 F
DEF_ANTE	如果 α 是有定名词短语（definite NP）则为 T，否则为 F
关系特征	
S_DIST	π 和 α 之间句子数量的分桶值（Binned values）
NP_DIST	π 和 α 之间表述（Mention）数量的分桶值
NUM_AGR	如果 π 和 α 在单复数形式上符合则为 T，否则为 F 如果 π 或者 α 的单数复数形式不能确定则为 UNK
GEN_AGR	如果 π 和 α 性别一致则为 T，否则为 F 如果 π 或者 α 的性别不能确定则为 UNK

基于循环神经网络的端到端的表述排序指代消解

- E2E-COREF[8]是基于表述排序的端到端的指代消解模型，在训练时同时学习判断每个片段（Span）是否为实体表述并优化对实体表述的指代聚类。
- 对于每个片段 i，模型的目标是在所有候选先行词中选出一个其指代的先行词 y_i。其中，先行词的候选集合为 $\mathcal{Y}(i) = \{\epsilon, 1, ..., i-1\}$，包括一个虚先行词 ϵ 及所有在 i 之前的片段（需要注意的是，这里的片段可能不是实体表述）。
- 当模型选择虚先行词 ϵ 作为输出时，可能对应两种情况：
  (1) 该片段 i 不是实体表述；
  (2) 该片段 i 是实体表述，但不指代在其之前的任一个片段（例如，可能是该实体在文中的第一次提及）。
  由此，根据对每个片段得到的先行词预测，可构建整个文本中的指代集合。

[8] End-to-end neural coreference resolution, 2017.

基于循环神经网络的端到端的表述排序指代消解

- E2E-COREF 对每个候选先行词，计算其和片段 i 为指代关系的条件概率：

$$P(y_i) = \frac{\exp(s(i, y_i))}{\sum_{y' \in \mathcal{Y}(i)} \exp(s(i, y'))}$$

- $s(i,j)$ 是表示片段 i 和片段 j 之间存在指代关系的分数，这一分数与三个因素相关：
  $s_m(i)$：片段 i 是否为实体表述；
  $s_m(j)$：片段 j 是否为实体表述；
  $s_a(i,j)$：片段 j 是否为 i 的先行词：

$$s(i,j) = \begin{cases} 0 & j = \epsilon \\ s_m(i) + s_m(j) + s_a(i,j) & j \neq \epsilon \end{cases}$$

  通过将虚先行词的分数设为 0，当模型预测任意非虚先行词的分数为正时，则可以选出分数最高的先行词预测；当模型预测所有非虚先行词的分数都为负时，则输出虚先行词。

基于循环神经网络的端到端的表述排序指代消解

- 针对片段编码表示，E2E-COREF 首先基于双向 LSTM 网络和注意力机制编码片段表示。对于每个输入句子，其输入表示 $x_1, \ldots, x_T$ 由预训练词向量及对字符的 1 维卷积组成。模型首先基于双向 LSTM 网络得到每个词的上下文表示 $x_t^* = [h_{t,1}, h_{t,-1}]$，其中 x_t^* 是 LSTM 的前向输出表示 $h_{t,1}$ 和反向输出表示 $h_{t,-1}$ 的拼接。

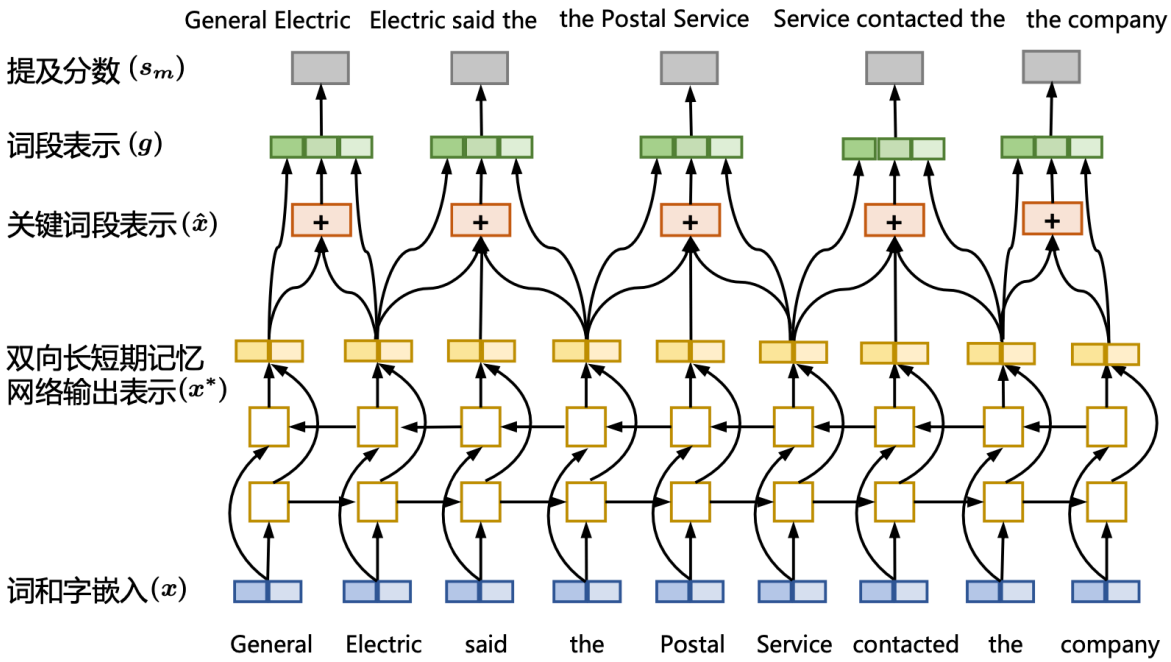

基于循环神经网络的端到端的表述排序指代消解

- 基于词表示 x_t^*，E2E-COREF 通过注意力机制判断片段中每个词的重要性，找出可能的关键词并给予更高权重，适用加权计算得到关键片段表示 $\hat{x}_i$:

$$\alpha_t = w_\alpha \cdot \mathrm{FFNN}_\alpha(x_t^*)$$

$$a_{i,t} = \frac{\exp(\alpha_t)}{\sum_{k=\mathrm{START}(i)}^{\mathrm{END}(i)} \exp(\alpha_k)}$$

$$\hat{x}_i = \sum_{t=\mathrm{START}(i)}^{\mathrm{END}(i)} a_{i,t} \cdot x_t$$

对于每个片段 i，其片段表示由其首尾词表示、关键片段表示及一个表示片段长度的特征向量 $\phi(i)$ 的拼接构成:

$$g_i = [x_{\mathrm{START}(i)}^*, x_{\mathrm{END}(i)}^*, \hat{x}_i, \phi(i)]$$

基于循环神经网络的端到端的表述排序指代消解

- 针对分数计算，E2E-COREF 基于上述得到的片段表示，使用前馈神经网络计算各项分数。分数具体计算公式如下:

$$s_m(i) = w_m \cdot \mathrm{FFNN}_m(g_i)$$

$$s_a(i,j) = w_a \cdot \mathrm{FFNN}_a([g_i, g_j, g_i \circ g_j, \phi(i,j)])$$

其中 $\cdot$ 表示点积运算，$\circ$ 表示逐项乘积运算，$[\cdot]$ 表示向量拼接。可以看到，片段的实体表述分数 $s_m(i)$ 与片段表示相关，而片段对的指代关系预测分数 $s_a(i,j)$ 和两个片段表示、两个片段表示的乘积、及一个与话语主体、文本类别 (从元数据中获得) 和片段对距离相关的特征表示 $\phi(i)$ 相关。

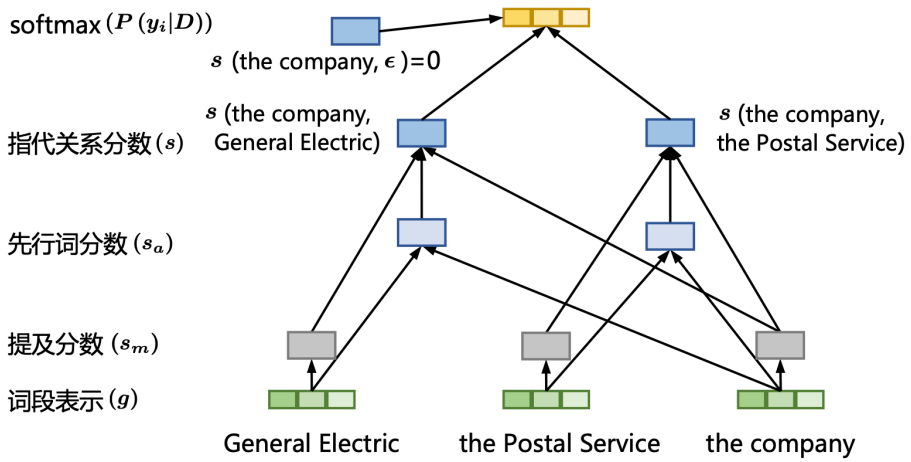

基于循环神经网络的端到端的表述排序指代消解

- 在训练阶段，对于每个片段 i，E2E-COREF 希望最大化与其具有正确指代关系的所有片段的条件概率 $P(y_i)$。假设 GOLD(i) 为与片段 i 的具有正确指代关系的片段集合，$\mathcal{Y}(i)$ 为先行词候选集合，基于交叉熵损失，模型损失函数可以表示为:

$$\mathcal{L} = -\sum_{i=2}^{N} \log \sum_{\hat{y} \in \mathcal{Y}(i) \cap \mathrm{GOLD}(i)} P(\hat{y})$$

如果片段 i 不和任何片段构成指代关系，则其正确指代片段集合 $\mathrm{GOLD}(i) = \{\epsilon\}$。

基于循环神经网络的端到端的表述排序指代消解

- 在测试时，考虑到对所有片段组合计算的效率问题，E2E-COREF 制定了以下策略：
  (1) 只考虑词数小于等于 L 的片段；
  (2) 在计算得到每个片段的实体表述分数 $s_m(i)$ 后，只保留分数最高的 γ_T 个片段进行后续计算；
  (3) 对于每个保留的片段，只考虑其最近的 K 个先行词候选进行片段对的分数计算。

  基于以上策略和条件概率的计算公式，E2E-COREF 能够解码得到最可能的指代关系分布。

基于循环神经网络的端到端的表述排序指代消解

- https://github.com/kentonl/e2e-coref
- 数据及评价指标
  CoNLL-2012 Shared Task: Modeling Multilingual Unrestricted Coreference in OntoNotes
  https://aclanthology.org/W12-4501.pdf

基于实体的指代消解

- 基于表述对和基于表述排序的两种指代消解算法旨在将一个表述与其所指代的一个表述相对应，通常只关注局部的指代信息。
- 基于实体的指代消解则认为将单个表述归类至其指代的实体（通常对应一个表述的等价类）能利用实体级别的全局信息，因此能更好地实现指代消解任务。
- 基于实体的指代消解和基于表述的指代消解算法相似，区别在于基于表述的方法将当前表述分配到一个先行的表述，而基于实体的方法将当前表述分配到先行的实体（表述等价类）上。
- 基于实体的指代消解同样可以分为:
  (1) 基于实体-表述的方法。
  (2) 基于实体排序的方法。

基于 SVM 分类器的实体-表述指代消解

- Entity-mention-coref[9]是一种基于实体-表述的指代消解算法。专注于通过机器学习方法解决文本中实体表述的关联问题。该算法通过构建表述类（mention cluster）并利用分类器进行关联判断，实现了对文本中指代同一实体的不同表述的准确识别和归类。
  该方法关注表述 m_i 是否属于某个表述类 c_j，该表述类由指代同一实体的所有先行词构成。
- Entity-mention-coref 通过训练一个 SVM 二分类器计算 m_i 属于表述类 c_j 的分数 $s(c_j, m_i)$，其中 $c_j \in \mathcal{C}(i)$，$\mathcal{C}(i)$ 代表在 m_i 之前的所有实体（表述类）的集合。

[9] Supervised models for coreference resolution, 2009.

基于 SVM 分类器的实体-表述指代消解

- Entity-mention-coref 中所构建的特征包含两类：
  (1) 描述待分类表述 m_i 的表述级别特征，包括其词性特征等；
  (2) 实体级别的特征，用于描述待分类表述 m_i 和候选实体 c_j 的关系，包括实体级别的性别、数字、语意相符程度，实体级别的距离特征，实体级别的字符串关系特征等。

描述待分类表述 m_i 的表述级别特征	
NUMBER_2	SINGULAR 或 PLURAL, 根据词典确定
GENDER_2	MALE, FEMALE, NEUTER, or UNKNOWN, 根据常见人名列表确认
PRONOUN_2	如果 m_k 是代词则为 Y，否则为 N
待分类表述 m_i 和其候选先行词 m_k 的关系特征	
HEAD_MATCH	如果表述具有相同的中心名词则为 C，否则为 I
STR_MATCH	如果表述具有相同的字符串则为 C，否则为 I
SUBSTR_MATCH	如果一个表述是另一个的子字符串则为 C，否则为 I
PRO_STR_MATCH	如果两个表示都是代词并且相同则为 C，否则为 I
描述待分类表述 m_i 和其候选先行词 m_k 的关系的额外特征	
NUMBER’	m_j 和 m_k 的 NUMBER_2 特征合并
GENDER’	m_j 和 m_k 的 GENDER_2 特征合并
PRONOUN’	m_j 和 m_k 的 PRONN_2 特征合并

基于 SVM 分类器的实体-表述指代消解

- 在训练时，对于每个表述 m_i，Entity-mention-coref 使用 m_i 之前的实体分别组成正、负样本，其中
  正样本由 m_i 和其所属的实体 c_j 组成，
  负样本由 m_j 到其所属实体距离 m_i 最近的先行词 m_j(也即实体 c_j 的最后一个表述) 之间的表述和 m_i 组成。

  例如: $[\text{Barack Obama}]_1^1$ nominated $[\text{Hillary Rodham Clinton}]_2^2$ as $[\text{his}]_3^1$ $[\text{secretary of state}]_4^3$ on $[\text{Monday}]_5^4$. $[\text{He}]_6^1$...
  其中，每个表述的下标代表其出现的次序，上标代表其所属的实体。当对表述 “He” 进行分类时，将产生三条训练样本：
  $\mathbf{i}(\{\text{Monday}\}, \text{He})$
  $\mathbf{i}(\{\text{secretary of state}\}, \text{He})$
  $\mathbf{i}(\{\text{Barack Obama}, \text{his}\}, \text{He})$。
  其中，前两条样本为负样本，最后一条为正样本。

基于 SVM 分类器的实体-表述指代消解

- 在测试时，同样考虑 m_i 之前出现的所有实体，并基于最近原则，将 m_i 分配至与其距离最近的被分类器判别为存在指代关系的实体。
  相反，如果 m_i 和之前的所有实体都不存在指代关系，则其将被认为是一个新的实体。

基于循环神经网络的实体排序指代消解

- Global-rank[10]是基于循环神经网络的实体排序指代消解模型。
  具体来说，对于当前待分类表述 x_n，模型通过对其之前出现的所有实体 (表述类)$\{X^{(m)}\}_{m=1}^{M}$ 计算分数并排序，选出 x_n 所属的表述类。
- 由于 Global-rank 是基于表述类的算法，首先定义相关符号：
  $X^{(m)}$ 为第 m 个表述类，
  $X_j(m)$ 为第 m 个表述类中的第 j 个表述，其中表述的排序由其在文档中出现的顺序确定。
  由于一个有效的文档表述聚类会将每个表述都分入一个确定的表述类，定义一组表述-表述类映射 $z \in \{1, ..., M\}^N$，当 x_n 属于第 m 个表述类时 $z_n = m$。

[10] Learning global features for coreference resolution, 2016.

基于循环神经网络的实体排序指代消解

- 基于表述排序的指代消解，其基本思路是对每个 x_n 和候选先行词 $y \in \mathcal{Y}(x_n)$ 计算其为指代关系的分数 $f(x_n, y)$，其中 $\mathcal{Y}(x_n) = \{1, ..., n-1, \epsilon\}$ 为 x_n 的候选先行词集合，ϵ 为虚先行词，表示当前表述为该实体在文中的第一次提及。这样可以使得基于表述排序的算法能够高效计算和解码。然而，这种方式使用单个指代代表整个表述类，只能计算局部的表述分数，无法利用整个表述类的全局信息。
- 因此，Global-rank 在局部表述分数 $f(x_n, y)$ 的基础上，增添了一项全局实体-表述分数 $g(x_n, y, z_{1:n-1})$ 的计算，其中 $z_{1:n-1}$ 代表当前表述 x_n 之前所有表述所属的表述类的映射。具体实现时，为了保留基于表述排序的方法的优势，并简化测试过程，Global-rank 在解码时同时计算局部和全局的分数，并寻找使该分数最大的表述类分配方式:

$$\underset{y_1,\ldots,y_N}{\operatorname{argmax}} \sum_{n=1}^{N} f(x_n, y_n) + g(x_n, y_n, z_{1;n-1})$$

基于循环神经网络的实体排序指代消解

- 局部表述分数计算和表述排序分数计算相似，Global-rank 的特征映射：

  表述级别特征：给定一个表述 x_n，通过函数 $\phi_a(x_n) : \mathcal{X} \to \{0,1\}^F$ 将其映射为一个二值化的特征向量，其中 F 是特征维度。

  表述对级别特征：对于一对表述 (x_n, y)，通过函数 $\phi_p(x_n, y) : (\mathcal{X}, \mathcal{X}) \to \{0,1\}^F$ 将表述对 (x_n, y) 表示成表述对级别的特征向量，这里 y 可以是另一个表述（用于排序）或空标签 ϵ（表示无相关表述）。

- 接着使用非线性特征映射 h_a 和 h_p 将该特征向量映射到连续的特征空间:

$$h_a(x_n) = \tanh(W_a \phi_a(x_n) + b_a)$$

$$h_p(x_n, y) = \tanh(W_p \phi_p(x_n, y) + b_p)$$

- 局部表述分数计算定义如下: 分数函数 $f(x_n, y)$ 根据 y 是否为 ϵ 分为两种情况：$y \neq \epsilon$ 即存在相关表述对；$y = \epsilon$ 即无相关表述。

$$f(x_n, y) = \begin{cases} u^\top [h_a(x_n), h_p(x_n, y)] + u_0 & \text{if } y \neq \epsilon \\ v^\top h_a(x_n) + v_0 & \text{if } y = \epsilon \end{cases}$$

基于循环神经网络的实体排序指代消解

- Global-rank 是一种利用 RNN 对表述类进行编码并计算整体表示的方法。该框架通过 RNN 依次编码每个表述类中包含的表述，从而构建实体表述类的全局表示。与局部表述分数计算相比，Global-rank 能够捕捉序列中表述之间的长期依赖关系，从而获得更全面的语义表示。
- 全局的实体-表述分数计算，Global-rank 使用 RNN 对每个表述类所包含的表述进行依次编码，从而计算该实体表述类的整体表示。

$$h_c(x_n) = \tanh(W_c \phi_a(x_n) + b_c)$$

对于表述类 m 中的第 j 个表述，基于 RNN 的表示计算可以表示成:

$$h_j^{(m)} \leftarrow \mathrm{RNN}(h_c(X_j^{(m)}), h_{j-1}^{(m)}; \theta)$$

在对全局实体-表述分数进行计算时，使用 $h_{<n}^{(zy)}$ 表示表述类 z_y 在对 x_n 之前所有的表述依次编码后得到的表述类表示。$y \neq \epsilon$ 非首次出现表述；$y = \epsilon$ 首次出现表述。

$$g(x_n, y, z_{1:n-1}) = \begin{cases} h_c(x_n)^\top h_{<n}^{(z_y)} & \text{if } y \neq \epsilon \\ \mathrm{NA}(x_n) & \text{if } y = \epsilon \end{cases}$$

使用 NA 函数对该表述为首次出现的情况进行了分别计算:

$$\mathrm{NA}(x_n) = q^\top \tanh(W_s[\phi_a(x_n), \sum_{m=1}^{M} h_{<n}^{(m)}] + b_s)$$

q 是一个权重向量。

基于循环神经网络的实体排序指代消解

- 在训练时，每个表述所属的实体由训练集的标注所给定，但每个表述所指代的先行词可以有多个。因此，Global-rank 对每个表述，选取使其分数最高的先行词作为隐式目标先行词，并定义了最大间隔的目标函数:

$$\mathcal{L} = \sum_{n=1}^{N} \max_{\hat{y} \in \mathcal{Y}(x_n)} \Delta(x_n, \hat{y})(1 + f(x_n, \hat{y}) + g(x_n, \hat{y}, z^{(o)}) - f(x_n, y_n^l) - g(x_n, y_n^l, z^{(o)}))$$

  其中，当 x_n 为前指项时，隐式目标先行词定义为使局部和全局分数之和最高的先行词，否则为 ϵ:

$$y_n^l = \underset{y \in \mathcal{Y}(x_n): z_y^{(o)} = z_n^{(o)}}{\operatorname{argmax}} f(x_n, y) + g(x_n, y, z^{(o)})$$

  约束条件：$z_y^{(o)} = z_n^{(o)}$ 即 y 和 x_n 必须属于同一实体类。若 x_n 不是前指项（即无先行词），则 $y_n^l = \epsilon$。

- $\Delta(x_n, \hat{y})$ 表示错误类型权重（惩罚不同错误类型），针对不同错误类型“假链接 (False link)”、“假新实体 (False new)”、“错误链接 (Wrong link)”定义不同的损失权重 $(\alpha_1, \alpha_2, \alpha_3)$，其中，“假链接”表示预测当前表述为前指，实际为新实体的错误；“假新实体”表示预测表述为新实体，实际为前指；“错误链接”为预测了错误的指代先行词。通过调整 $\alpha_1, \alpha_2, \alpha_3$，可以控制模型对不同错误的敏感度。

基于循环神经网络的实体排序指代消解

- Global-rank 的解码算法。对于每个待分类表述 x_n，首先计算得到使得局部和全局分数之和最高的先行词 y^*，并得到 y^* 所属的表述类 m。当 $y^* = \epsilon$ 时，表示当前表述不属于任何表述类，则建立一个新的表述类。接着，更新表述类 m，表述类映射及表述类 m 的表示，以用于下次解码计算。对所有表述 x_n 遍历分类后，返回所有表述类。

输入: 待解码文本序列 $(x_1, \ldots, x_N)$
输出: 实体表述类 $X^{(1)}, \ldots, X^{(M)}$
// 初始化
foreach $X^{(i)}$ **do**
  $X^{(i)} \leftarrow []$; // 初始化每个表述类 $X^{(i)}$ 为空列表；
end
foreach $\boldsymbol{h}_0^{(i)}$ **do**
  $\boldsymbol{h}_0^{(i)} \leftarrow \mathbf{0} \in \mathbb{R}^D$; // 初始化每个表述类的 RNN 初始输入 $\boldsymbol{h}_0^{(0)}$ 为 0 向量；
end
$\boldsymbol{z} \leftarrow \mathbf{0}$; // 初始化表述类映射向量；
$M \leftarrow 0$; // 初始化表述类计数；
// 解码过程
for $n = 2$ **to** N **do**
  $y^* \leftarrow \arg\max_{y \in \mathcal{Y}(x_n)} f(x_n, y) + g(x_n, y, \boldsymbol{z}_{1:n-1})$；// 计算使局部和全局分数之和最高的先行词；
  $m \leftarrow z_{y^*}$; // 得到 y^* 所属的表述类；
  if $y^* = \epsilon$ **then**
    // 建立一个新的表述类
    $M \leftarrow M + 1$；
    $m \leftarrow M$；
  end
  $X^{(m)} \leftarrow X^{(m)} + [x_n]$；
  $z_n \leftarrow m$；
  $\boldsymbol{h}^{(m)} \leftarrow \mathrm{RNN}(\boldsymbol{h}_c(x_n), \boldsymbol{h}^{(m)})$; // 更新表述类 m 的表示；
end
return $X^{(1)}, \ldots, X^{(M)}$

基于循环神经网络的实体排序指代消解

- https://github.com/swiseman/nn_coref

本章小结

第五章篇章分析

5.1 篇章理论概述

5.2 话语分割

5.3 篇章结构分析

5.4 指代消解