

自然语言处理

王刚

统计与数据科学学院

2026 年春季学期

目录

第七章信息抽取

7.5 主题模型概述

7.5.1 潜在语义分析

7.5.2 文本的生成过程

7.5.3 概率潜在语义分析

7.5.4 潜在狄利克雷分布

7.5.5 主题模型工具

第七章信息抽取

引言

- ▶ 向量空间模型作为显式的文本表示方法，将一个文本表示为词项对应的权重向量，并假设各词项之间相互独立。但破坏了文本的词序信息和句法结构，无法深入挖掘文本中的多义性和同义性等隐式语义关系。
- ▶ 文本的生成过程是极其复杂的，人们在撰写文本时通常首先拟定“主题思想”等抽象概念，然后再形成具体的文字。
- ▶ 为此，研究者提出了一系列称为主题模型 (topic model) 的统计模型：

潜在语义分析 (latent semantic analysis, LSA) ；

概率潜在语义分析 (probabilistic latent semantic analysis, PLSA) ；

潜在狄利克雷分布 (latent Dirichlet allocation, LDA)。

- ▶ 建立主题模型的目的是就要从文本语料中发现隐藏在词汇表面之下的潜在语义。

7.5 主题模型概述

概述

- ▶ 如果一篇文章有一个中心思想，那么一些特定词语会更频繁的出现：


如果文章讲狗，那“狗”和“骨头”等词出现的频率会高些。

如果文章讲猫，那“猫”和“鱼”等词出现的频率会高些。

而有些词例如“这个”、“和”大概在两篇文章中出现的频率会大致相等。

真实的情况，一篇文章通常包含多种主题，而且每个主题所占比例各不相同。

什么是Topic Model?




Seeking Life's Bare (Genetic) Necessities

COLD SPRING HARBOR, NEW YORK—How many genes does an organism need to survive? Last week at the genome meeting here,* two genome researchers with radically different approaches presented complementary views of the basic genes needed for life. One research team, using computer analyses to compare known genomes, concluded that today's organisms can be sustained with just 250 genes, and that the earliest life forms required a mere 128 genes. The other researcher mapped genes in a simple parasite and estimated that for this organism, 800 genes are plenty to do the job—but that anything short of 100 wouldn't be enough.

Although the numbers don't match precisely, those predictions

"are not all that far apart," especially in comparison to the 75,000 genes in the human genome, notes Siv Andersson of Uppsala University in Sweden, who arrived at the 800 number. But coming up with a consensus answer may be more than just a genetic numbers game, particularly as more and more genomes are completely mapped and sequenced. "It may be a way of organizing any newly sequenced genome," explains Arcady Mushegian, a computational molecular biologist at the National Center for Biotechnology Information (NCBI) in Bethesda, Maryland. Comparing an



* Genome Mapping and Sequencing, Cold Spring Harbor, New York, May 8 to 12.


Stripping down. Computer analysis yields an estimate of the minimum modern and ancient genomes.

SCIENCE • VOL. 272 • 24 MAY 1996

图: 文档呈现出多个主题


概述

- ▶ 每一个话题都是一个词的分布
- ▶ 每个文档都是语料库范围内的主题的混合
- ▶ 每一个单词都来自其中一个主题




概述

- ▶ 实际上，只有文档是可见的；
- ▶ 其他的结构是隐藏的；
- ▶ 给定一个文档集合，这些潜在变量的后验概率决定了将集合隐藏分解为主题。



概述



概述

- ▶ 主题模型的思想最早源自于信息检索领域

潜在语义索引模型 (LSA) 利用奇异值分解 (SVD) 将文档向量从高维词项空间映射到低维的语义空间 (主题空间)。LSA 可以发掘文本隐含的主题信息，而且不需要依赖任何先验知识，从而能够对“一词多义”和“一义多词”语言现象进行建模，最终使得搜索引擎返回的结果不仅在词汇层面，而且在语义层面上与用户的查询相匹配。

- ▶ LSA 模型建立在矩阵分解框架之上，而概率潜在语义索引模型 PLSA 则通过概率生成模型模拟文档中词的产生过程，将 LSA 模型扩展到概率统计的框架下。

PLSA 模型只针对训练集中的有限文档进行拟合，其参数空间随着训练集中文档数目线性增加。

- ▶ 为此，LDA 模型在 PLSA 的基础上引入了参数的先验分布，LDA 模型不仅作为一种文本表示方法，也可以视为一种数据降维和聚类算法，在文本挖掘的诸多任务上得到了广泛而成功的应用。

7.5.1 潜在语义分析

潜在语义分析

- ▶ 潜在语义分析 (LSA) 技术用于分布式语义表示，其目标是将文本表示为一组隐式的语义概念，而不是向量空间模型 (VSM) 中一组显式的词项。

LSA 假设语义接近的词更容易出现在相似的文本片段中，与 VSM 中的高维、稀疏文本表示方法不同，LSA 利用奇异值分解将文档和词汇的高维表示映射在低维的潜在语义空间中，缩小了问题的规模，得到不再稀疏的低维表示；低维表示揭示出了词汇 (文档) 在语义上的联系。

- ▶ 这种潜在的语义概念称为主题。

潜在语义分析

- **奇异值分解**：假设矩阵 $X \in \mathbb{R}^{m \times n}$ 为任意的 $m \times n$ 阶矩阵，矩阵的秩为 r ($r > 0$)，则 X 一定可分解为

$$X = U\Sigma V^T$$

其中， $U \in \mathbb{R}^{m \times m}$ 为满足 $U^T U = I$ 的 m 阶酉矩阵， $V \in \mathbb{R}^{n \times n}$ 为满足 $V^T V = I$ 的 n 阶酉矩阵， Σ 为左上角为 r 阶的对角阵，其余位置全部为 0 的 $m \times n$ 阶非负矩阵。
 $U = [u_1 \dots u_m]$ 的列向量 $u_i \in \mathbb{R}^m$ 称为 X 的左奇异向量，
 $V = [v_1 \dots v_n]$ 的列向量 $v_i \in \mathbb{R}^n$ 称为 X 的右奇异向量， Σ 的左上角对角元素 $(\Sigma)_{ii} = \delta_i$ 称为 X 的非零奇异值。

潜在语义分析

- **奇异值分解**：矩阵 X 可以分解为以下形式：

$$X = \delta_1 u_1 v_1^T + \cdots + \delta_r u_r v_r^T$$

奇异值分解可以将高维向量空间中的数据投影到低维的正交空间中，奇异值 (及其对应的奇异向量) 可以用于度量各正交分量的形态和信息量大小。

- **截断奇异值分解** 保留较大的奇异分量，去除较小的奇异分量，从而在低维正交空间中实现对高维原始数据的约减和近似。对 X 进行截断奇异值分解时截取前 k 个最大的奇异值，得到近似矩阵：

$$\tilde{X} = \delta_1 u_1 v_1^T + \cdots + \delta_k u_k v_k^T$$

潜在语义分析

► 词项-文档矩阵的奇异值分解

对于给定的文本集合，基于向量空间模型构造出“词项-文档矩阵” (term-by-document matrix):

$$\begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$$

其中， m 表示词项个数， n 表示文档数， X 的每一行表示第 i 个词项在各文档中的取值，每一列 $[x_{1,j}, \dots, x_{m,j}]^T$ 表示第 j 个文档对应的词项权重向量。

潜在语义分析

► 词项-文档矩阵的奇异值分解

对 X 进行 SVD 分解:

$$X = T \Sigma D^T = \sigma_1 t_1 d_1^T + \cdots + \sigma_r t_r d_r^T$$

其中, Σ 是由非零奇异值 $\sigma_1, \dots, \sigma_r (\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0)$ 构成的 r 阶对角矩阵 $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $m \times r$ 阶矩阵 T 和 $n \times r$ 阶矩阵 D 中的列向量 $t_1, t_2, \dots, t_r$ 和 $d_1, d_2, \dots, d_r$ 分别构成一组单位正交向量, 即满足 $T^T T = I_r$ 和 $D^T D = I_r$ 。

奇异值 $\sigma_1, \dots, \sigma_r$ 反映了词项-文档矩阵 X 中隐含的 r 个独立概念的强度。

对应第 j 个概念, t_j 表示构成此概念的 m 个词项的权重, d_j 表示 n 个文档包含此概念的权重, $t_j d_j^T$ 则表示此概念所对应的词项-文档关联信息。

潜在语义分析

► 词项-文档矩阵的奇异值分解

在文本表示任务中，由于特征空间维度高并且单个文档长度短，传统的词项-文档矩阵呈现高度的稀疏性。同时，高维词项之间具有较高的线性相关性。

LSA 通过对词项-文档矩阵 X 进行截断奇异值分解，选择保留前 k ($k < r$) 个最大的奇异值，并将这 k 个奇异值及对应的奇异向量构成的正交空间视为文本的潜在语义空间。


潜在语义分析

► 词项-文档矩阵的奇异值分解

通过选择 k 个潜在语义空间中的主题代替 m 个显式的词项表示文本，从而实现了文本表示从 m 维到 k 维的降维，并得到原始矩阵 X 的低秩近似 (low rank approximation):

$$\tilde{X} = T_k \Sigma_k D_k^T = \sigma_1 t_1 d_1^T + \cdots + \sigma_k t_k d_k^T$$

其中， T_k 称作词项主题矩阵， D_k 称作文档主题矩阵。



7.5.2 文本的生成过程

Unigram Model

- ▶ unigram model 假设文本中的词服从多项分布，而多项分布的先验分布为 Dirichlet 分布。




图: 掷具有 V 个面的骰子 (假设只有一个骰子), 每面对应产生一个词

Unigram Model

- unigram model 假设文本中的词服从多项分布，而多项分布的先验分布为 Dirichlet 分布。




图: 贝叶斯观点下的 (Dirichlet 先验下) Unigram Model (假设有多个骰子)

Unigram Model

► Unigram Model 的概率图模型




图: 双线圆圈 w_n 表示在文本中观察到的第 n 个词, $n \in [1, N]$ 表示文本中一共有 N 个词。加上方框表示重复, 即一共有 N 个这样的随机变量 w_n 。 p 和 α 是隐含未知变量, 分别是词服从的多项分布的参数和该多项分布的先验 Dirichlet 分布的参数。一般 α 由经验事先给定, p 由观察到的文本中出现的词学习得到, 表示文本中出现每个词的概率。

Mixture of Unigrams Model

- 该模型的生成过程是：给某个文档先选择一个主题，再根据该主题生成文档，该文档中的所有词都来自一个主题。假设主题有，生成文档的概率为：

$$\begin{aligned} p(\mathbf{w}) &= p(z_1) \prod_{n=1}^N p(w_n|z_1) + \dots + p(z_k) \prod_{n=1}^N p(w_n|z_k) \\ &= \sum_z p(z) \prod_{n=1}^N p(w_n|z) \end{aligned}$$

对应的概率图模型：




图: 被涂色的 w 表示可观测变量，未被涂色的 z 表示未知的隐变量， N 表示一篇文档中总共 N 个单词， M 表示 M 篇文档


7.5.3 概率潜在语义分析

概率潜在语义分析

- ▶ Mixture of unigrams model 假定一篇文档只由一个主题生成，实际一篇文章往往由多个主题构成，每一个主题大概可以用与该主题相关的频率最高的一些词来描述。
比如介绍一个国家的文档中，往往会分别从教育、经济、交通等多个主题进行介绍。
那么在 PLSA 中，文档是怎样生成的呢？
- ▶ 概率潜在语义分析 PLSA 认为一篇文档 (Document) 可以由多个主题 (Topic) 混合而成，而每个 Topic 都是词汇上的概率分布，文章中的每个词都是由一个固定的 Topic 生成的。

概率潜在语义分析

► PLSA 模型的文档生成过程



概率潜在语义分析

- ▶ PLSA 生成文档的过程：选定文档生成主题，确定主题生成词。
- ▶ 若文档已经产生，那么如何根据文档反推其主题呢？
利用文档推断其隐藏的主题（分布）的过程，便是主题建模的目的：自动地发现文档集中的主题（分布）。
- ▶ 文档 d 和单词 w 是可观察到的，但主题 z 却是隐藏的。




图: 涂色的 d 、 w 表示可观测变量，未被涂色的 z 表示未知的隐变量， N 表示一篇文档中总共 N 个单词， M 表示 M 篇文档

概率潜在语义分析

- ▶ 可以根据大量已知的文档-词项信息 $p(w_j|d_i)$ ，训练出文档-主题 $p(z_k|d_i)$ 和主题-词项 $p(w_j|z_k)$ ，如下公式所示：

$$p(w_j|d_i) = \sum_{k=1}^K p(w_j|z_k)p(z_k|d_i)$$

得到文档中每个词的生成概率为：

$$p(d_i, w_j) = p(d_i)p(w_j|d_i) = p(d_i) \sum_{k=1}^K p(w_j|z_k)p(z_k|d_i)$$

其中 $p(d_i)$ 可事先计算求出，而 $p(z_k|d_i)$ 和 $p(w_j|z_k)$ 未知，所以 $\theta = \{p(z_k|d_i), p(w_j|z_k)\}$ 就是要估计的参数。


可采用 EM 算法求解 PLSA 模型的参数。

7.5.4 潜在狄利克雷分布


潜在狄利克雷分布

- ▶ 贝叶斯学派认为 PLSA 模型中 doc-topic 骰子 $\vec{\theta}_m$ 和 topic-word 骰子 $\vec{\psi}_k$ 都是模型中的参数 (随机变量), 需要有先验分布。加上先验分布从而把 PLSA 对应的过程改造为贝叶斯框架下的。

由于 $\vec{\theta}_m$ 和 $\vec{\psi}_k$ 对应多项分布, 故选择 Dirichlet 分布作为先验分布, 于是得到了 LDA 主题模型。



潜在狄利克雷分布



1. $\vec{\alpha} \rightarrow \vec{\theta}_m \rightarrow \mathbf{z}_{m,n}$

在生成第 m 篇文档的时候，先从第一个坛子中抽一个 doc-topic 骰子 $\vec{\theta}_m$ ，然后投掷这个骰子生成了文档中第 n 个词的 topic 编号 $z_{m,n}$ ；

2. $\vec{\beta} \rightarrow \vec{\psi}_k \rightarrow (\mathbf{w}_{m,n} | k = z_{m,n})$

生成语料中的第 m 篇文档的第 n 个词：
在 K 个 topic-word 骰子 $\vec{\psi}_k$ 中，选编号为 $k = z_{m,n}$ 的那个骰子投掷生成 word $w_{m,n}$ 。

潜在狄利克雷分布

► LDA 的解释：

- 假定语料库中共有 m 篇文章，一共涉及了 K 个 Topic，每个 Topic 下的词分布为一个从参数为 β 的 Dirichlet 先验分布中采样得到的多项分布。

其中：词典由 term 词项构成，每篇文章由 word 构成，前者 (term) 不能重复，后者 (word) 可以重复。

- 每篇文章的长度记做 N_m ，从一个参数为 α 的 Dirichlet 先验分布中采样得到一个多项分布作为该文章中每个 Topic 的概率分布；
- 对于某篇文章中的第 n 个词，首先从该文章中出现每个 Topic 的多项分布中采样一个 Topic，然后再在这个 Topic 对应的词的多项分布中采样一个词。不断重复这个随机生成过程，直到 m 篇文章全部完成上述过程。

PLSA 与 LDA 的联系与区别

- ▶ LDA 在 PLSA 基础上将狄利克雷先验分布引入到“文档-主题”分布和“主题-词项”分布，模型的学习和推断算法也从最大似然估计转化为了贝叶斯估计。
- ▶ 在 PLSA 中，“文档-主题”分布 $p(z|d)$ 和“主题词项”分布 $p(w|z)$ 都是事先确定的，可以利用最大似然估计从数据集中得到。生成文本时，PLSA 首先根据文档对应的“文档-主题”分布 $p(z|d)$ 为每个词选择一个主题，再根据“主题-词项”分布 $p(w|z)$ 产生一个具体的词。
- ▶ 在 LDA 中，“文档-主题”分布参数不是确定的，它是一个随机变量， θ_m 是根据超参数 α 由 Dirichlet 分布抽取出来，它不是必须学习的参数，因此参数空间不会随着文档数的增加而增加。但是，在实际应用中仍需要计算 θ_m 的统计量(如期望)作为对“文档-主题”分布的估计。同时，“主题-词项”分布参数 ϕ_k 也不是事先确定的，是根据超参数 β 由 Dirichlet 先验分布抽取得到的。

7.5.5 主题模型工具

主题模型工具

- **Gensim**是一款开源的第三方 Python 工具包，用于从原始的非结构化的文本中，无监督地学习到文本隐层的主题向量表达。它支持包括 LSA、LDA 在内的多种主题模型算法，并提供了诸如相似度计算，信息检索等一些常用任务的 API 接口。



主题模型工具

► 使用 LDA 发掘电影概要文本中的主题

```
from gensim import corpora, models, similarities

# 用文本构建Gensim字典
dictionary = corpora.Dictionary(texts)
# 去除极端的词
dictionary.filter_extremes(no_below=1, no_above=0.8)
# 将字典转化为 (bag of words) 模型
corpus = [dictionary.doc2bow(text) for text in texts
           ]

# 运行LDA模型
%time lda = models.LdaModel(corpus, num_topics=5,
                             id2word=dictionary,
                             update_every=5,
                             chunksize=10000,
                             passes=100)

# CPU times: user 9min 53s, sys: 5.87 s, total: 9min
#              59s
# 为保证收敛, 将passes设置为100
# Gensim支持并行 (parallel) 运算, 有助于处理更大的语料库。
```

示例——影片剧情主题模型 LDA

► 使用 LDA 发掘电影概要文本中的主题

每个主题包含一系列的词及其分布

```
lda.show_topics()
```

```
# [u'0.006*men + 0.005*kill + 0.004*soldier + 0.004*
    order +
# 0.004*patient + 0.004*night + 0.003*priest +
# 0.003*becom + 0.003*new + 0.003*speech',
# u"0.006*n't + 0.005*go + 0.005*fight + 0.004*doe +
# 0.004*home + 0.004*famili + 0.004*car + 0.004*
    night + 0.004*say + 0.
    004*next",
# u"0.005*ask + 0.005*meet + 0.005*kill + 0.004*say
    +
# 0.004*friend + 0.004*car + 0.004*love + 0.004*
    famili + 0.004*arriv + 0.
    .004*n't",
# u'0.009*kill + 0.006*soldier + 0.005*order + 0.005
    *men +
# 0.005*shark + 0.004*attempt + 0.004*offic + 0.004*
    son+
# 0.004*command + 0.004*attack',
```

本章小结

第七章信息抽取

7.5 主题模型概述

7.5.1 潜在语义分析

7.5.2 文本的生成过程

7.5.3 概率潜在语义分析

7.5.4 潜在狄利克雷分布

7.5.5 主题模型工具